Intelligence Artificielle Connexionniste

Perceptron

Julien SEINTURIER
Maître de Conférences

Université de Toulon
julien.seinturier@univ-tln.fr
https://web.seinturier.fr/teaching

©2026 / 2027

But

- Répondre à une problématique de classification binaire
- Être capable d'apprendre automatiquement à classer

But

- Répondre à une problématique de classification binaire
- Être capable d'apprendre automatiquement à classer

Exemple

- Classer des plantes selon leur toxicité en fonction de caractéristiques





But

- Répondre à une problématique de classification binaire
- Être capable d'apprendre automatiquement à classer

Exemple

- Classer des plantes selon leur toxicité en fonction de caractéristiques
  - Une plante peut être toxique ou non toxique
  - Une plante est caractérisée par la longueur et la largeur de ses feuilles





Définition[Individu]

Dans le cadre de classification d’objets, un **individu** désigne l'unité élémentaire d'observation sur laquelle portent les données à analyser.

Définition[Individu]

Dans le cadre de classification d'objets, un **individu** désigne l'unité élémentaire d'observation sur laquelle portent les données à analyser.

Exemple[Individu]

Classification de plantes



Monstera



Lys de la paix



Muguet



Menthe



Persil

Définition[Individu]

Dans le cadre de classification d'objets, un **individu** désigne l'unité élémentaire d'observation sur laquelle portent les données à analyser.

Exemple[Individu]

Classification de plantes


Monstera


Lys de la paix


Muguet


Menthe


Persil

Individus

Définition[Classe]

Dans le cadre de classification d'objets, une **classe** (ou **cluster**) désigne un ensemble d'individus regroupés selon des propriétés partagées.

Définition[Classe]

Dans le cadre de classification d'objets, une **classe** (ou **cluster**) désigne un ensemble d'individus regroupés selon des propriétés partagées.

Exemple[Classe]

Classification de plantes



Monstera



Lys de la paix



Muguet



Menthe



Persil

Définition[Classe]

Dans le cadre de classification d'objets, une **classe** (ou **cluster**) désigne un ensemble d'individus regroupés selon des caractéristiques partagées.

Exemple[Classe]

Classification de plantes



Monstera



Lys de la paix



Muguet

Toxique



Menthe



Persil

Définition[Classe]

Dans le cadre de classification d'objets, une **classe** (ou **cluster**) désigne un ensemble d'individus regroupés selon des caractéristiques partagées.

Exemple[Classe]

Classification de plantes



Monstera



Lys de la paix



Muguet

Toxique



Menthe



Persil

Non toxique

Définition[Classe]

Dans le cadre de classification d'objets, une **classe** (ou **cluster**) désigne un ensemble d'individus regroupés selon des caractéristiques partagées.

Exemple[Classe]

Classification de plantes







Monstera — Lys de la paix — Muguet — Menthe — Persil

Toxique → Classes ← Non toxique

Exemple

- Données récoltées sur le terrain

Toxicité	Longueur feuille (cm)	Largeur feuille (cm)
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

- Est-il possible de trouver un lien entre les caractéristiques d'une plante et sa toxicité ?

Définition[Vecteur de caractéristiques / Features Vector]

On appelle **caractéristiques** (ou **features**) les données caractérisant un individu.

Un **vecteur de caractéristiques** (ou **features vector**), noté $X = (x_1, \dots, x_n)$, est un vecteur contenant les n **caractéristiques** (**features**) d'un individu.

Définition[Vecteur de caractéristiques / Features Vector]

On appelle **caractéristiques** (ou **features**) les données caractérisant un individu.

Un **vecteur de caractéristiques** (ou **features vector**), noté $X = (x_1, \dots, x_n)$, est un vecteur contenant les n **caractéristiques** (**features**) d'un individu.

Exemple[Vecteur de caractéristiques]

Toxicité	Longueur feuille (cm)	Largeur feuille (cm)
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

Définition[Vecteur de caractéristiques / Features Vector]

On appelle **caractéristiques** (ou **features**) les données caractérisant un individu.

Un **vecteur de caractéristiques** (ou **features vector**), noté $X = (x_1, \dots, x_n)$, est un vecteur contenant les n **caractéristiques** (**features**) d'un individu.

Exemple[Vecteur de caractéristiques]

Toxicité	Longueur feuille (cm)	Largeur feuille (cm)
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

x_1: Longueur feuille (cm)

x_2: Largeur feuille (cm)

Caractéristiques (Features)

Toxicité	x_1	x_2
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

Définition[Vecteur de caractéristiques / Features Vector]

On appelle **caractéristiques** (ou **features**) les données caractérisant un individu.

Un **vecteur de caractéristiques** (ou **features vector**), noté $X = (x_1, \dots, x_n)$, est un vecteur contenant les n **caractéristiques** (**features**) d'un individu.

Exemple[Vecteur de caractéristiques]

Vecteurs de caractéristiques

(Features Vectors)

$X = (x_1, x_2) = (0.5, 2.0)$

$X = (x_1, x_2) = (0.7, 2.6)$

$X = (x_1, x_2) = (2.2, 0.3)$

Toxicité	x_1	x_2
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

Définition[Valeur cible / Target Value]

On appelle **valeur cible** **(ou** **target value**), notée t, la valeur représentant la classe d'un individu.

Définition[Valeur cible / Target Value]

On appelle **valeur cible** (**ou** **target value**), notée t, la valeur représentant la classe d'un individu.

Exemple[Valeur cible]

Caractérisation de plantes

Toxicité	Longueur feuille (cm)	Largeur feuille (cm)
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

Définition[Valeur cible / Target Value]

On appelle **valeur cible** (**ou target value**), notée t, la valeur représentant la classe d'un individu.

Exemple[Valeur cible]

Caractérisation de plantes

Toxicité	Longueur feuille (cm)	Largeur feuille (cm)
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

Toxique = 1

Non toxique = 0

t	Longueur feuille (cm)	Largeur feuille (cm)
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

Définition[Valeur cible / Target Value]

On appelle **valeur cible** (**ou target value**), notée t, la valeur représentant la classe d'un individu.

Exemple[Valeur cible]

Caractérisation de plantes

Toxicité	Longueur feuille (cm)	Largeur feuille (cm)
Toxique	0.5	2.0
Toxique	1.1	2.1
Toxique	0.7	2.6
Non toxique	2.0	1.0
Non toxique	2.5	0.7
Non toxique	2.2	0.3

Target Values

Toxique = 1

Non toxique = 0

t	Longueur feuille (cm)	Largeur feuille (cm)
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

Définition[Exemple / Sample]

Soit $X = (x_1, \dots, x_n)$ le vecteur de caractéristiques d'un individu et soit t la valeur cible associée. On appelle **exemple** (ou **sample**), noté S, le vecteur composé de la concaténation de t et X Plus formellement:

$$S = t.X = (t, x_1, \dots, x_n)$$

Définition[Exemple / Sample]

Soit $X = (x_1, \dots, x_n)$ le vecteur de caractéristiques d'un individu et soit t la valeur cible associée. On appelle **exemple** (ou **sample**), noté S, le vecteur composé de la concaténation de t et X Plus formellement:

$$S = t.X = (t, x_1, \dots, x_n)$$

Exemple[Exemple]

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

Définition[Exemple / Sample]

Soit $X = (x_1, \dots, x_n)$ le vecteur de caractéristiques d'un individu et soit t la valeur cible associée. On appelle **exemple** (ou **sample**), noté S, le vecteur composé de la concaténation de t et X Plus formellement:

$$S = t.X = (t, x_1, \dots, x_n)$$

Exemple[Exemple]

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

$S = (t, x_1, \dots, x_n) = (1, 0.5, 2.0)$

$S = (t, x_1, \dots, x_n) = (1, 0.7, 2.6)$

$S = (t, x_1, \dots, x_n) = (0, 2.2, 0.3)$

Samples

Définition[Jeux de données / Dataset]

Un jeu de données (ou dataset), noté $\mathcal{D}$, est l'ensemble des données décrivant des individus. Plus formellement, il s'agit de l'ensemble des exemples pour tous les m individus étudiés:

$$\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m, \; S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \ldots, x_n^{(k)}\right)$$

Où

- $S^{(k)}$ est l'exemple pour l'individu k
- $X^{(k)} = \left(x_1^{(k)}, \ldots, x_n^{(k)}\right)$ est le vecteur de caractéristiques pour l'individu k
- $t^{(k)}$ est la valeur cible pour l'individu k

Exemple[Jeux de données / Dataset]

Pour m individus partageants n caractéristiques

t	x_1	...	x_i	...	x_n
$t^{(1)}$	$x_1^{(1)}$	...	$x_i^{(1)}$	...	$x_n^{(1)}$
...	...	...	...	...	...
$t^{(k)}$	$x_1^{(k)}$	...	$x_i^{(k)}$	...	$x_n^{(k)}$
...	...	...	...	...	...
$t^{(m)}$	$x_1^{(m)}$	...	$x_i^{(m)}$	...	$x_n^{(m)}$

Exemple[Jeux de données / Dataset]

Pour m individus partageants n caractéristiques

Features

t	x_1	...	x_i	...	x_n
$t^{(1)}$	$x_1^{(1)}$	...	$x_i^{(1)}$	...	$x_n^{(1)}$
...	...	...	...	...	...
$t^{(k)}$	$x_1^{(k)}$	...	$x_i^{(k)}$	...	$x_n^{(k)}$
...	...	...	...	...	...
$t^{(m)}$	$x_1^{(m)}$	...	$x_i^{(m)}$	...	$x_n^{(m)}$

Exemple[Jeux de données / Dataset]

Pour m individus partageants n caractéristiques

Target values →

t	x_1	...	x_i	...	x_n
$t^{(1)}$	$x_1^{(1)}$	...	$x_i^{(1)}$	...	$x_n^{(1)}$
...	...	...	...	...	...
$t^{(k)}$	$x_1^{(k)}$	...	$x_i^{(k)}$	...	$x_n^{(k)}$
...	...	...	...	...	...
$t^{(m)}$	$x_1^{(m)}$	...	$x_i^{(m)}$	...	$x_n^{(m)}$

Exemple[Jeux de données / Dataset]

Pour m individus partageants n caractéristiques

t	x_1	...	x_i	...	x_n
$t^{(1)}$	$x_1^{(1)}$	...	$x_i^{(1)}$	...	$x_n^{(1)}$
...	...	...	...	...	...
$t^{(k)}$	$x_1^{(k)}$	...	$x_i^{(k)}$	...	$x_n^{(k)}$
...	...	...	...	...	...
$t^{(m)}$	$x_1^{(m)}$	...	$x_i^{(m)}$	...	$x_n^{(m)}$

$$X^{(1)} = \left(x_1^{(1)}, \dots, x_i^{(1)}, \dots, x_n^{(1)}\right)$$

...

$$X^{(k)} = \left(x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right)$$

...

$$X^{(m)} = \left(x_1^{(m)}, \dots, x_i^{(m)}, \dots, x_n^{(m)}\right)$$

$$\mathcal{X} = \left\{X^{(1)}, \dots, X^{(k)}, \dots, X^{(m)}\right\}$$

Features vectors

Exemple[Jeux de données / Dataset]

Pour m individus partageants n caractéristiques

t	x_1	...	x_i	...	x_n
$t^{(1)}$	$x_1^{(1)}$	...	$x_i^{(1)}$	...	$x_n^{(1)}$
...	...	...	...	...	...
$t^{(k)}$	$x_1^{(k)}$	...	$x_i^{(k)}$	...	$x_n^{(k)}$
...	...	...	...	...	...
$t^{(m)}$	$x_1^{(m)}$	...	$x_i^{(m)}$	...	$x_n^{(m)}$

$$S^{(1)} = \left(t^{(1)}, x_1^{(1)}, \dots, x_i^{(1)}, \dots, x_n^{(1)}\right)$$

...

$$S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right)$$

...

$$S^{(m)} = \left(t^{(m)}, x_1^{(m)}, \dots, x_i^{(m)}, \dots, x_n^{(m)}\right)$$

Samples

Exemple[Jeux de données / Dataset]

Pour m individus partageants n caractéristiques

t	x_1	…	x_i	…	x_n
$t^{(1)}$	$x_1^{(1)}$	…	$x_i^{(1)}$	…	$x_n^{(1)}$
…	…	…	…	…	…
$t^{(k)}$	$x_1^{(k)}$	…	$x_i^{(k)}$	…	$x_n^{(k)}$
…	…	…	…	…	…
$t^{(m)}$	$x_1^{(m)}$	…	$x_i^{(m)}$	…	$x_n^{(m)}$

$$S^{(1)} = \left(t^{(1)}, x_1^{(1)}, \dots, x_i^{(1)}, \dots, x_n^{(1)}\right)$$

…

$$S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right)$$

…

$$S^{(m)} = \left(t^{(m)}, x_1^{(m)}, \dots, x_i^{(m)}, \dots, x_n^{(m)}\right)$$

$$\mathcal{D} = \left\{S^{(1)}, \dots, S^{(k)}, \dots, S^{(m)}\right\}$$

Dataset

Samples

Définition[Echantillon]

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données pour m individus. On appelle **échantillon**, noté $\mathcal{S}$, de $\mathcal{D}$ un sous ensemble non vide de $\mathcal{D}$.

Définition[Echantillon]

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données pour m individus. On appelle échantillon, noté $\mathcal{S}$, de $\mathcal{D}$ un sous ensemble non vide de $\mathcal{D}$.

Exemple[Echantillon]

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

Définition[Echantillon]

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données pour m individus. On appelle échantillon, noté $\mathcal{S}$, de $\mathcal{D}$ un sous ensemble non vide de $\mathcal{D}$.

Exemple[Echantillon]

Jeux de données

	t	x_1	x_2
$S^{(1)}$	1	0.5	2.0
$S^{(2)}$	1	1.1	2.1
$S^{(3)}$	1	0.7	2.6
$S^{(4)}$	0	2.0	1.0
$S^{(5)}$	0	2.5	0.7
$S^{(6)}$	0	2.2	0.3

$$\mathcal{D} = \{S^{(1)}, S^{(2)}, S^{(3)}, S^{(4)}, S^{(5)}, S^{(6)}\}$$

Définition[Echantillon]

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données pour m individus. On appelle échantillon, noté $\mathcal{S}$, de $\mathcal{D}$ un sous ensemble non vide de $\mathcal{D}$.

Exemple[Echantillon]

Jeux de données

	t	x_1	x_2
$S^{(1)}$	1	0.5	2.0
$S^{(2)}$	1	1.1	2.1
$S^{(3)}$	1	0.7	2.6
$S^{(4)}$	0	2.0	1.0
$S^{(5)}$	0	2.5	0.7
$S^{(6)}$	0	2.2	0.3

Echantillon

t	x_1	x_2
1	0.5	2.0
1	0.7	2.6
0	2.0	1.0
0	2.2	0.3

$$\mathcal{D} = \{S^{(1)}, S^{(2)}, S^{(3)}, S^{(4)}, S^{(5)}, S^{(6)}\} \qquad \mathcal{S} = \{S^{(1)}, S^{(3)}, S^{(4)}, S^{(6)}\}$$

Représentation géométrique

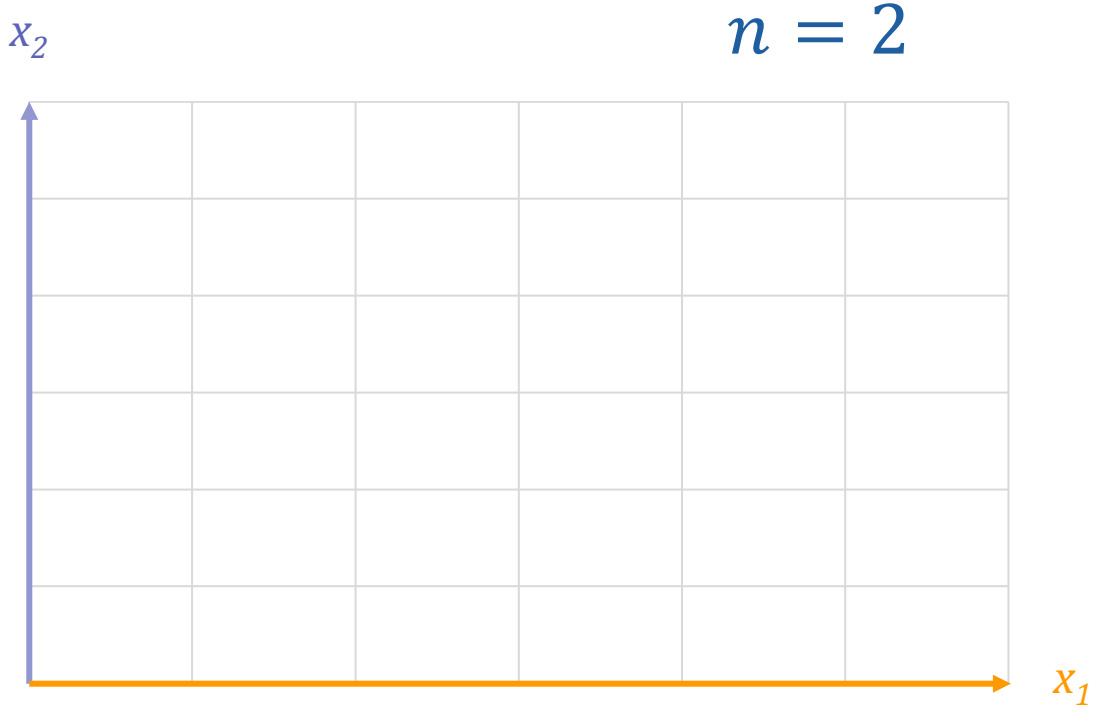
x_1	x_2
0.5	2.0
1.1	2.1
0.7	2.6
2.0	1.0
2.5	0.7
2.2	0.3

Représentation géométrique

- Espace à n dimensions

x_1	x_2
0.5	2.0
1.1	2.1
0.7	2.6
2.0	1.0
2.5	0.7
2.2	0.3

$n = 2$

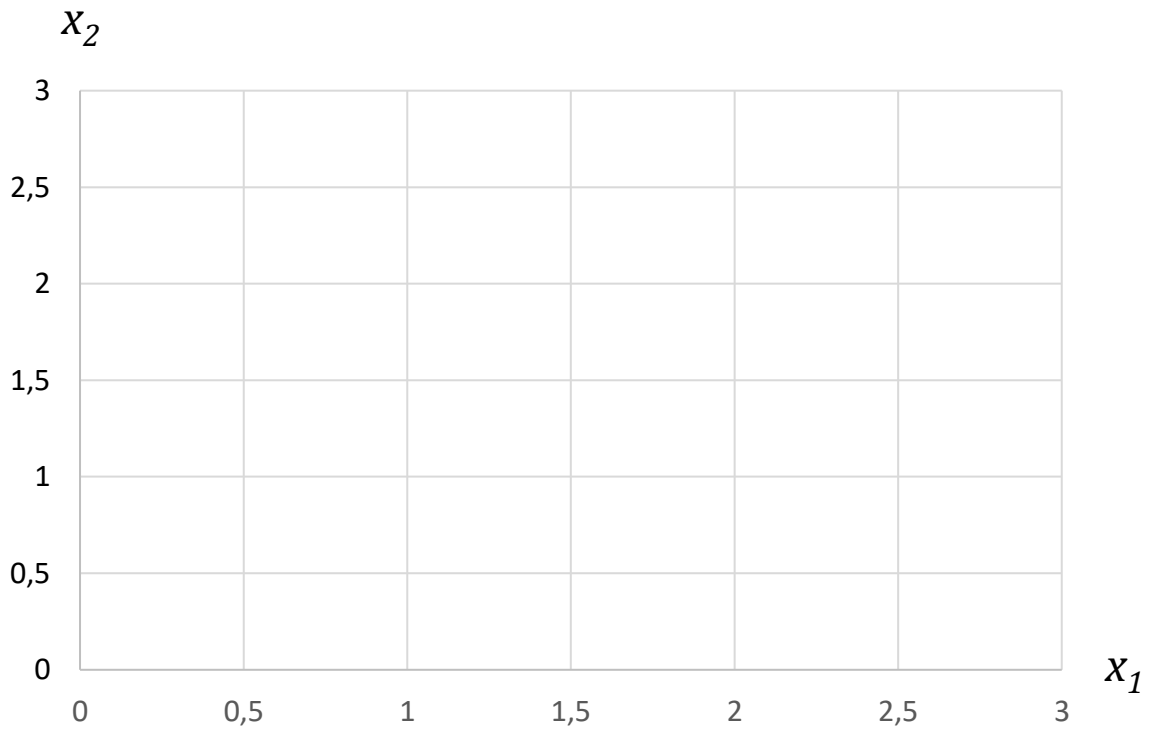


Représentation géométrique

- Espace à n dimensions
- Valeur de caractéristique n

  ↳ Coordonnée x_n

x_1	x_2
0.5	2.0
1.1	2.1
0.7	2.6
2.0	1.0
2.5	0.7
2.2	0.3



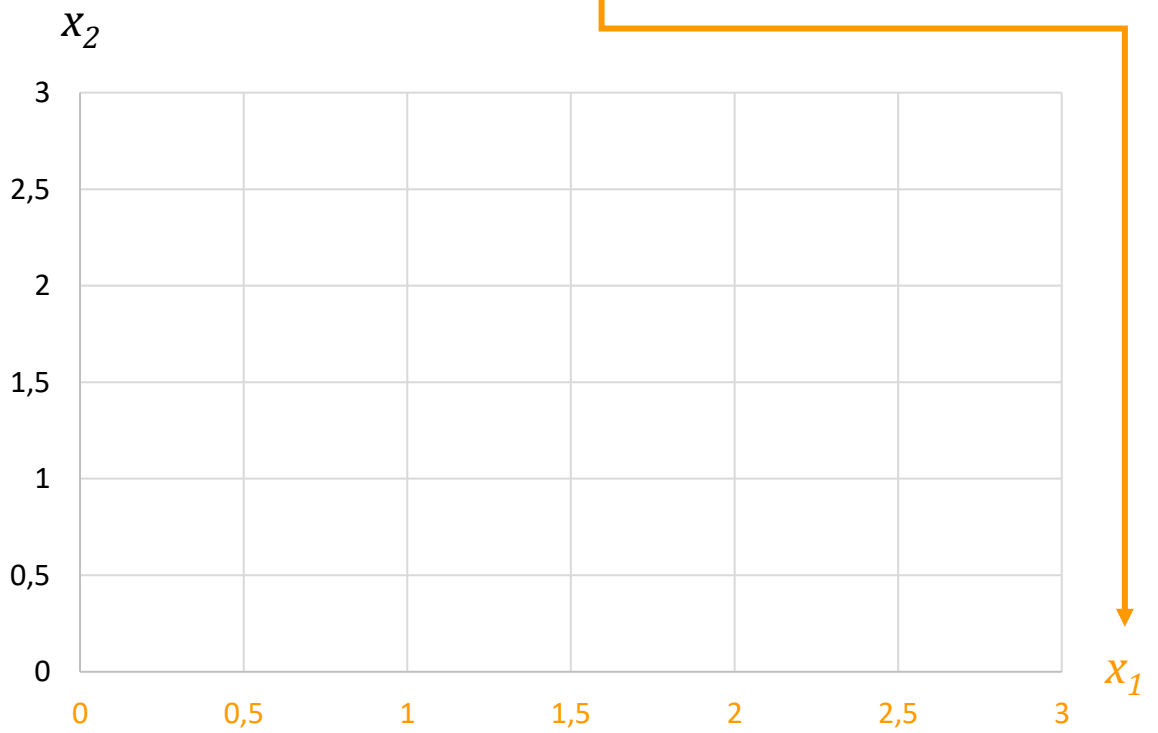
Représentation géométrique

- Espace à n dimensions
- Valeur de caractéristique n

  ↳ Coordonnée x_n

X_1 : Longueur de feuille

x_1	x_2
0.5	2.0
1.1	2.1
0.7	2.6
2.0	1.0
2.5	0.7
2.2	0.3



Représentation géométrique

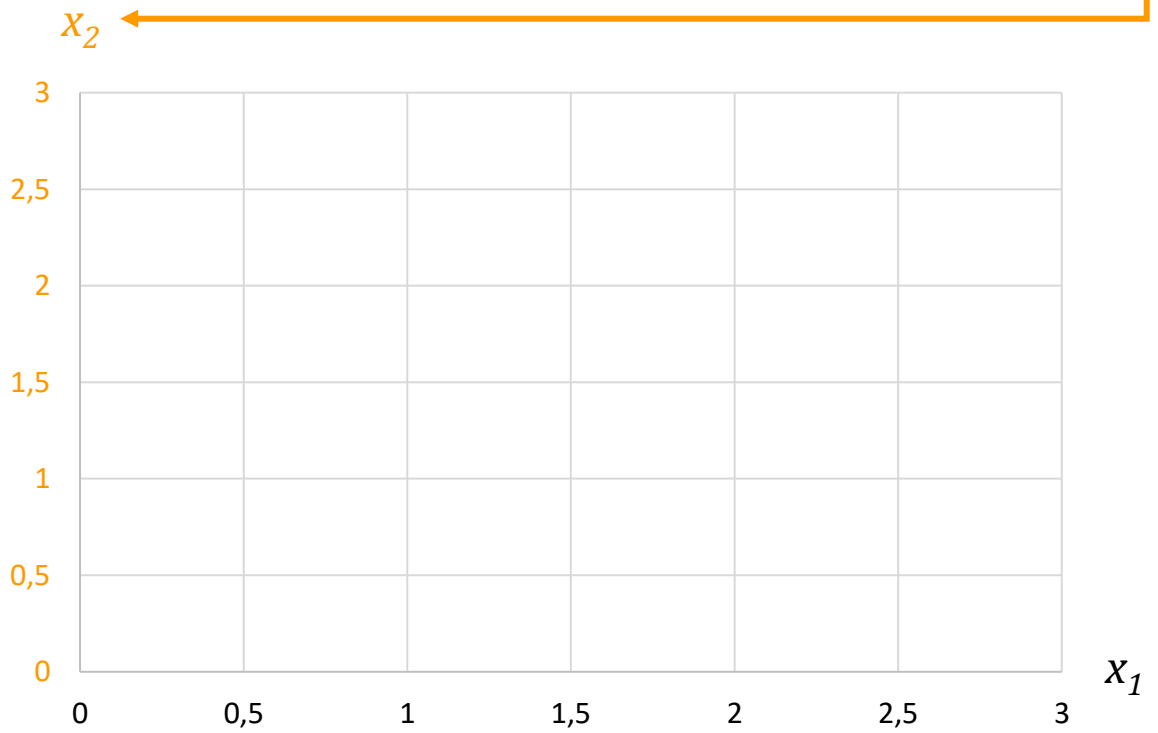
- Espace à n dimensions
- Valeur de caractéristique n

  ↳ Coordonnée x_n

X_1 : Longueur de feuille

X_2 : Largeur de feuille

x_1	x_2
0.5	2.0
1.1	2.1
0.7	2.6
2.0	1.0
2.5	0.7
2.2	0.3



Représentation géométrique

- Espace à n dimensions
- Valeur de caractéristique n

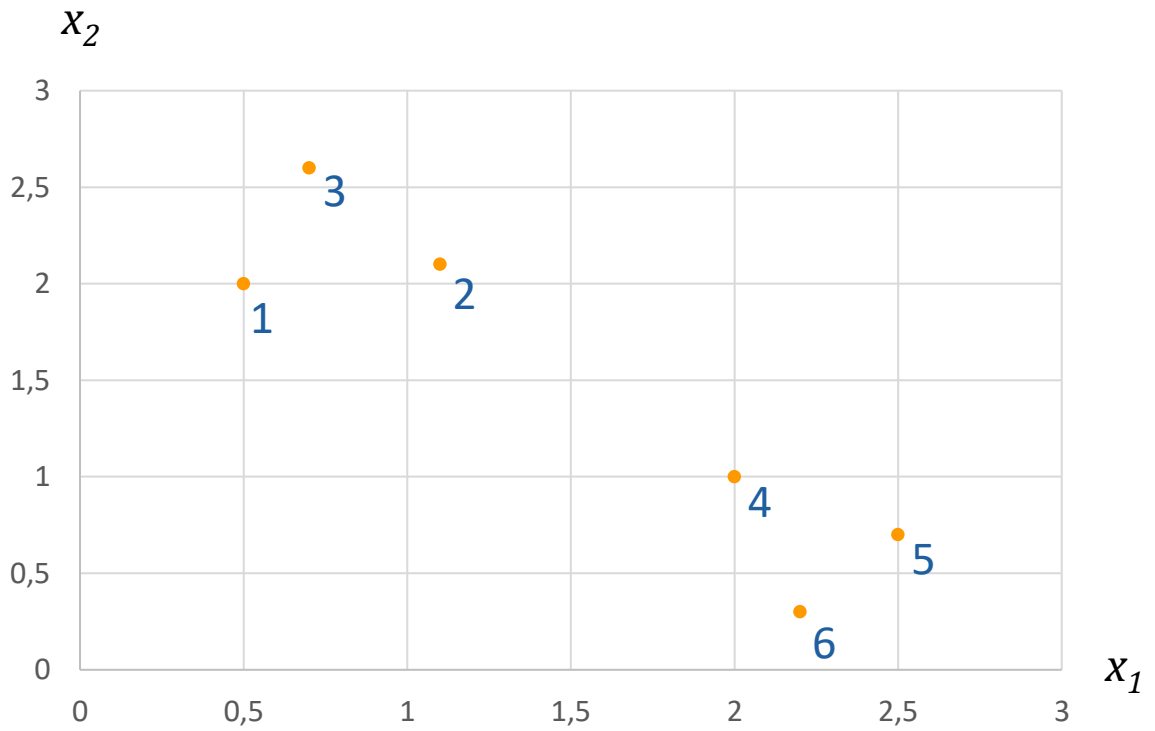
  ↳ Coordonnée x_n

X_1 : Longueur de feuille

X_2 : Largeur de feuille

	x_1	x_2
1	0.5	2.0
2	1.1	2.1
3	0.7	2.6
4	2.0	1.0
5	2.5	0.7
6	2.2	0.3

Chaque plante i est représentée comme un point $\left(x_1^i, x_2^i\right)$



Représentation géométrique

- Espace à n dimensions
- Valeur de caractéristique n

  ↳ Coordonnée x_n

- Toxicité notée t telle que:
  - $t = 1$ si toxique
  - $t = 0$ si non toxique

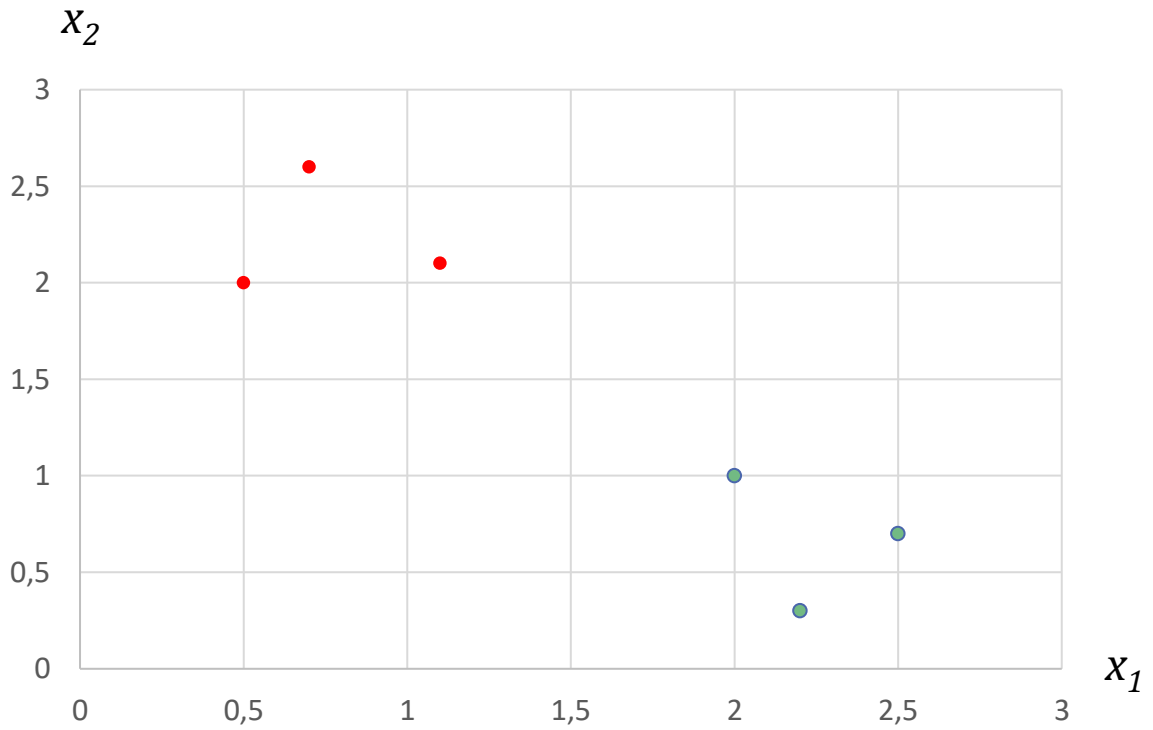
Comment classer les plantes ?

x_1 : Longueur de feuille

x_2 : Largeur de feuille

t : Toxicité

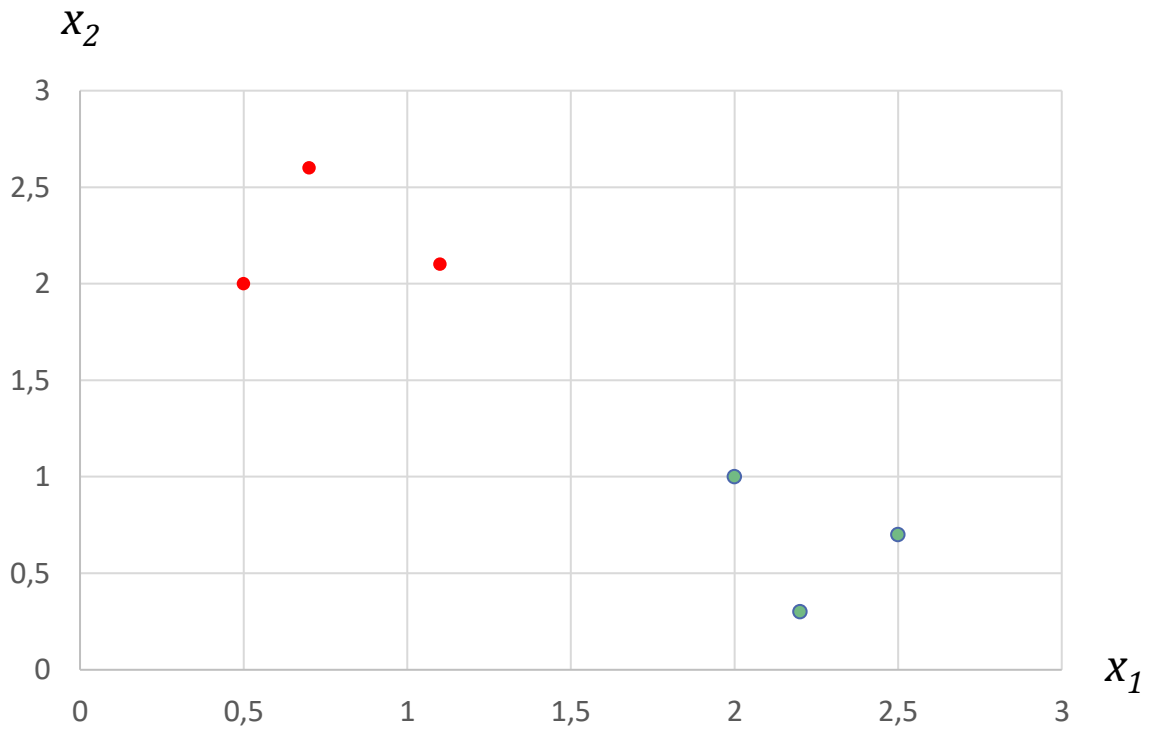
t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Représentation géométrique

- Classer = partitionner l'espace

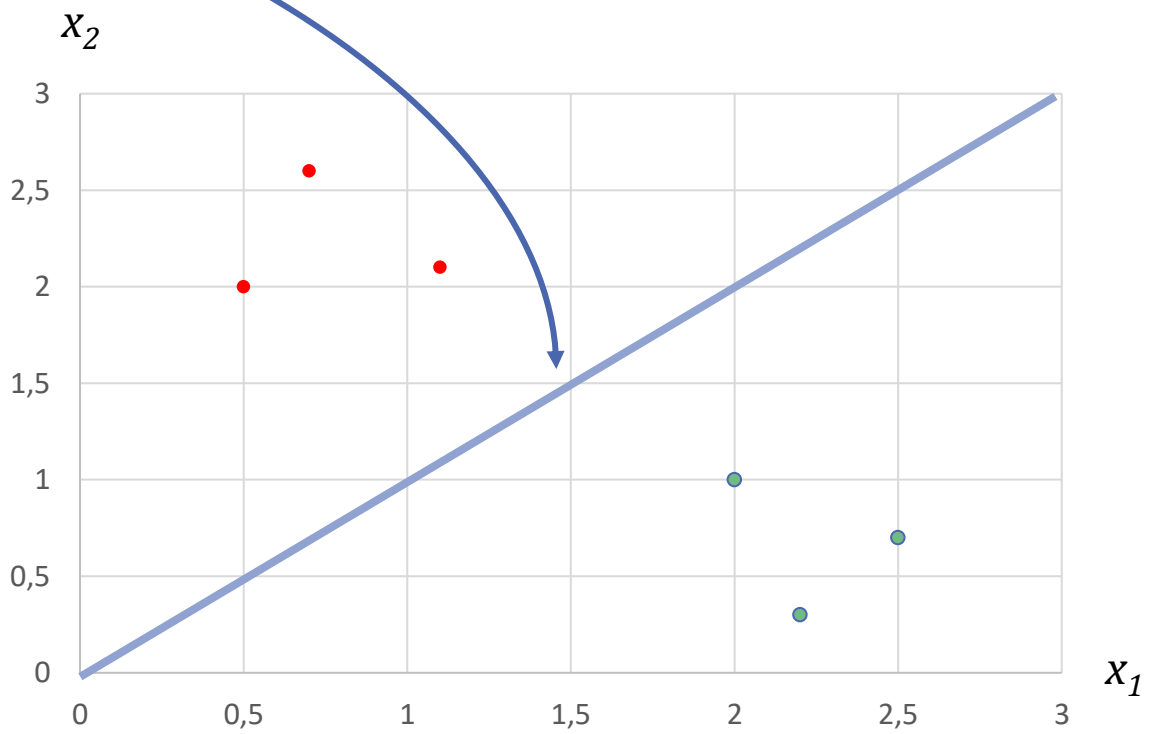
t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Représentation géométrique

- Classer = partitionner l'espace
- Quand $n = 2$: une droite

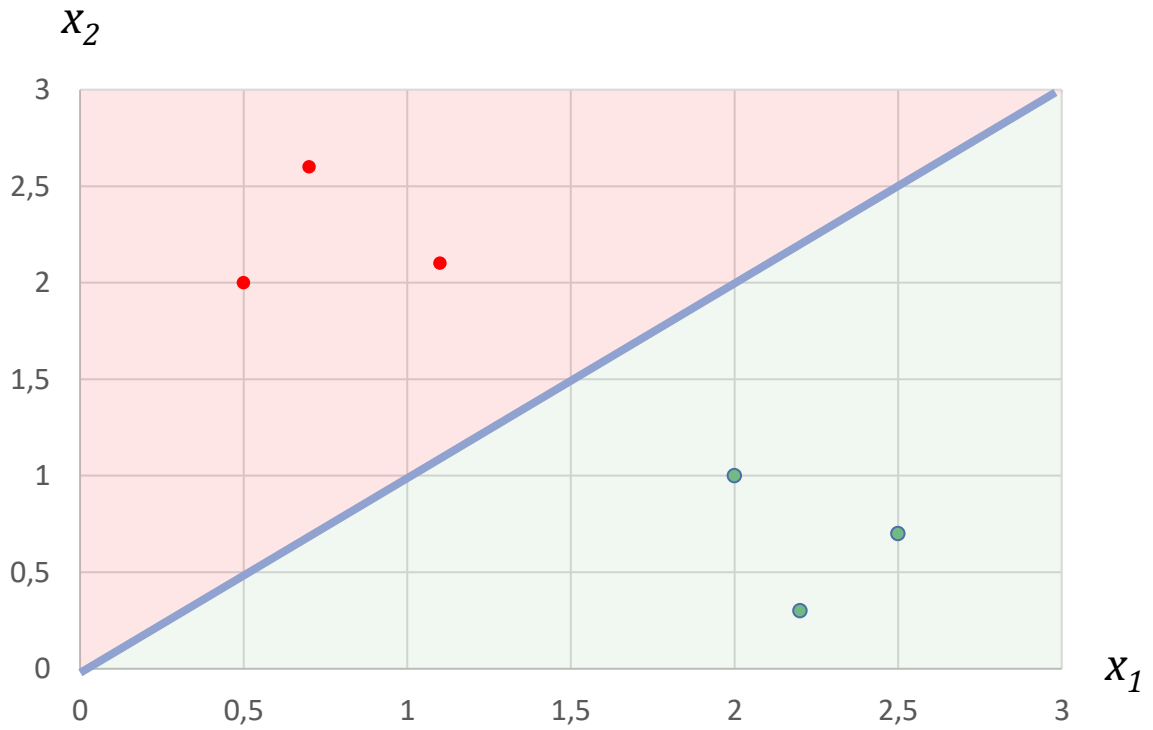
t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Représentation géométrique

- Classer = partitionner l'espace
- Quand $n = 2$: une droite
- Classification:
  - $y = 1$ si au dessus de la droite
  - $y = 0$ si au dessous de la droite

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Définition[Frontière de décision]

Dans le cadre de classification d'objets, une **frontière de décision** est l'outil qui permet de séparer l'espace en différentes classes.

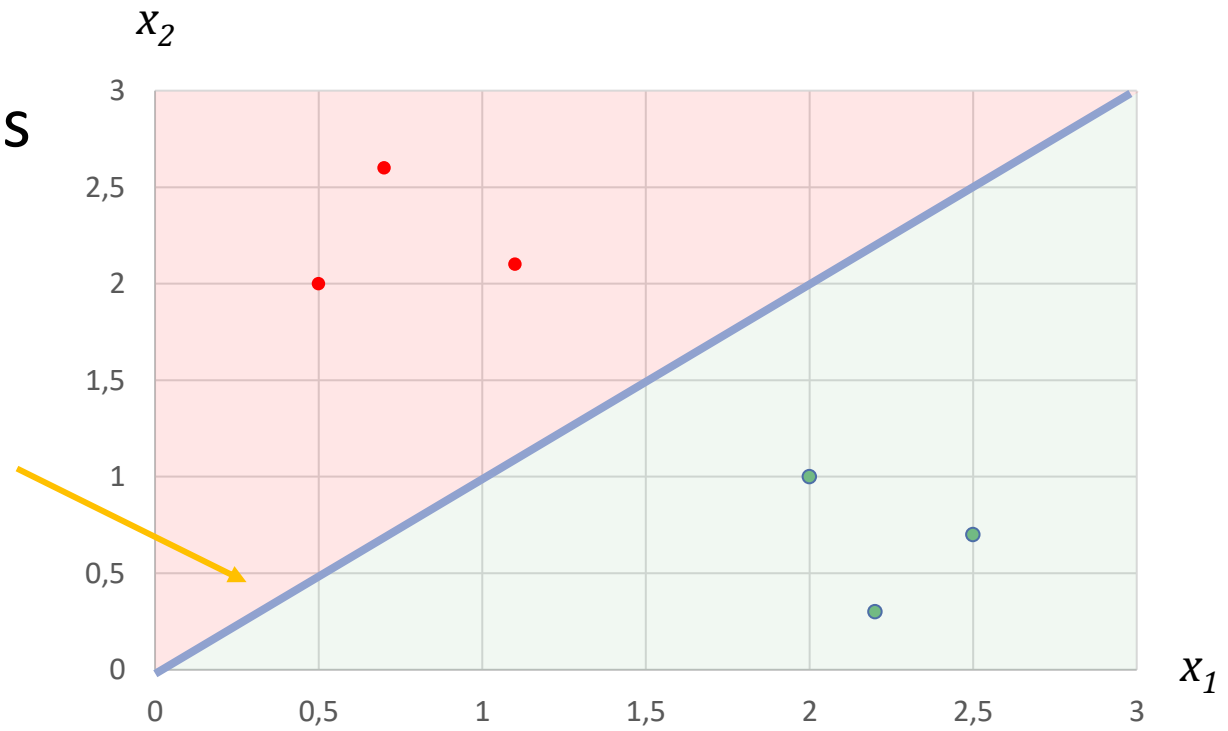
Définition[Frontière de décision]

Dans le cadre de classification d'objets, une **frontière de décision** est l'outil qui permet de séparer l'espace en différentes classes

Exemple

- Classification binaire à 2 dimensions
- Frontière de décision ≡ Droite

Frontière de décision

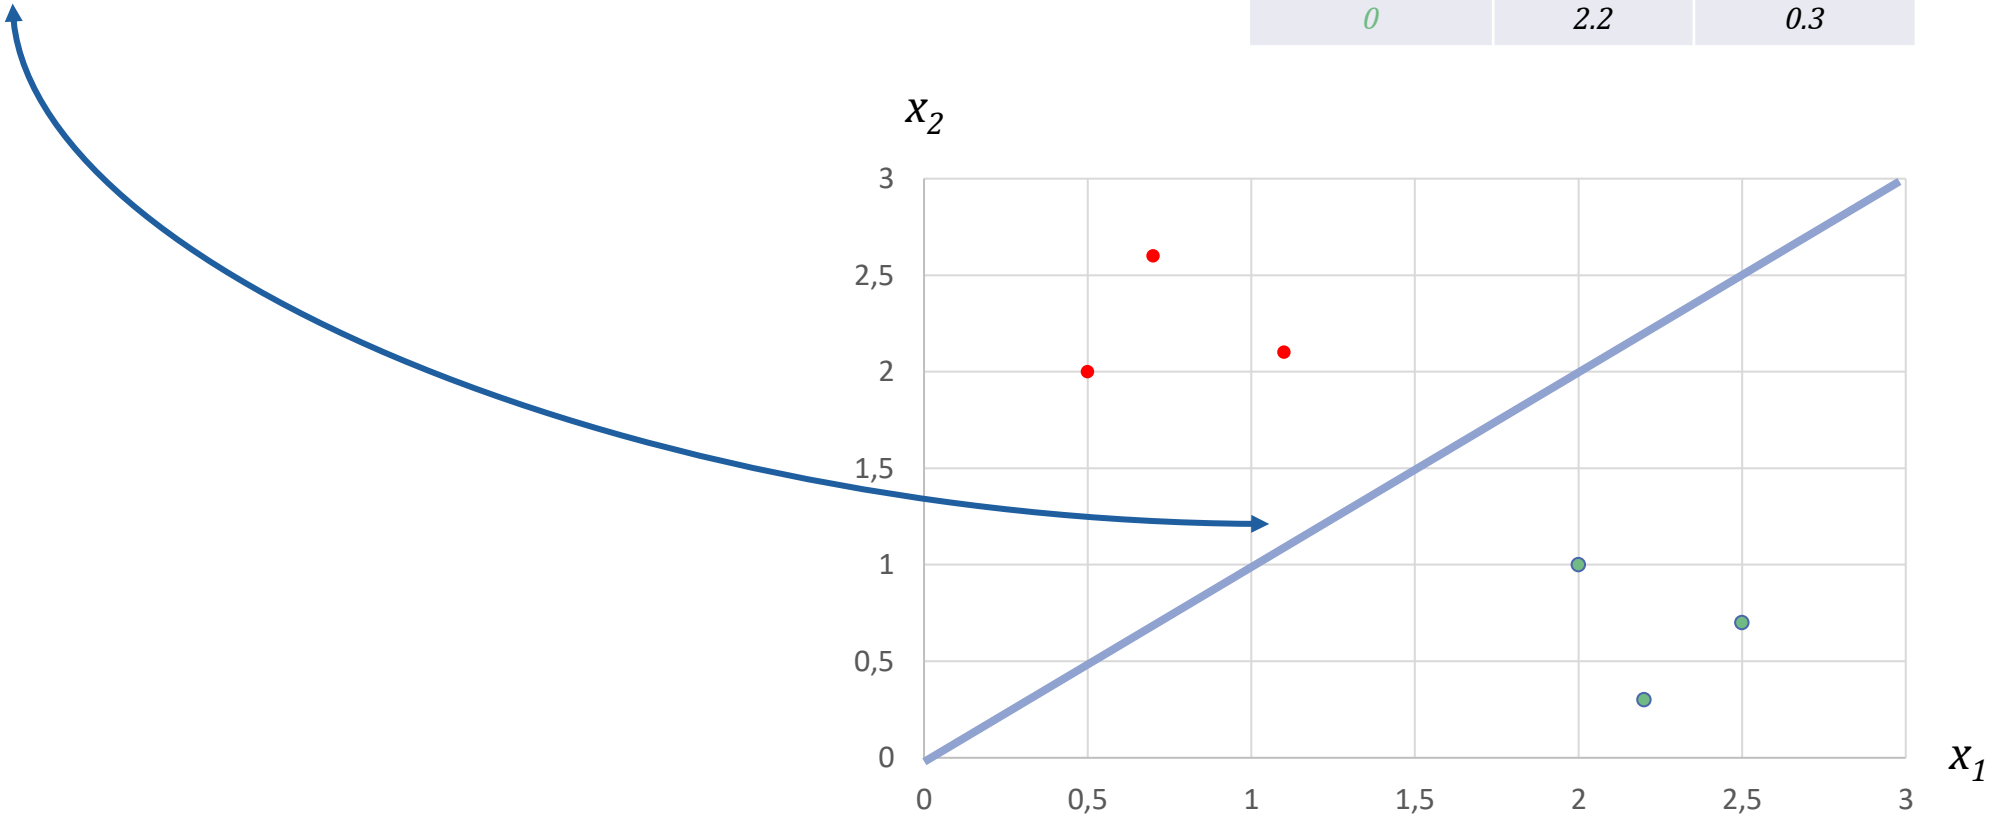


Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

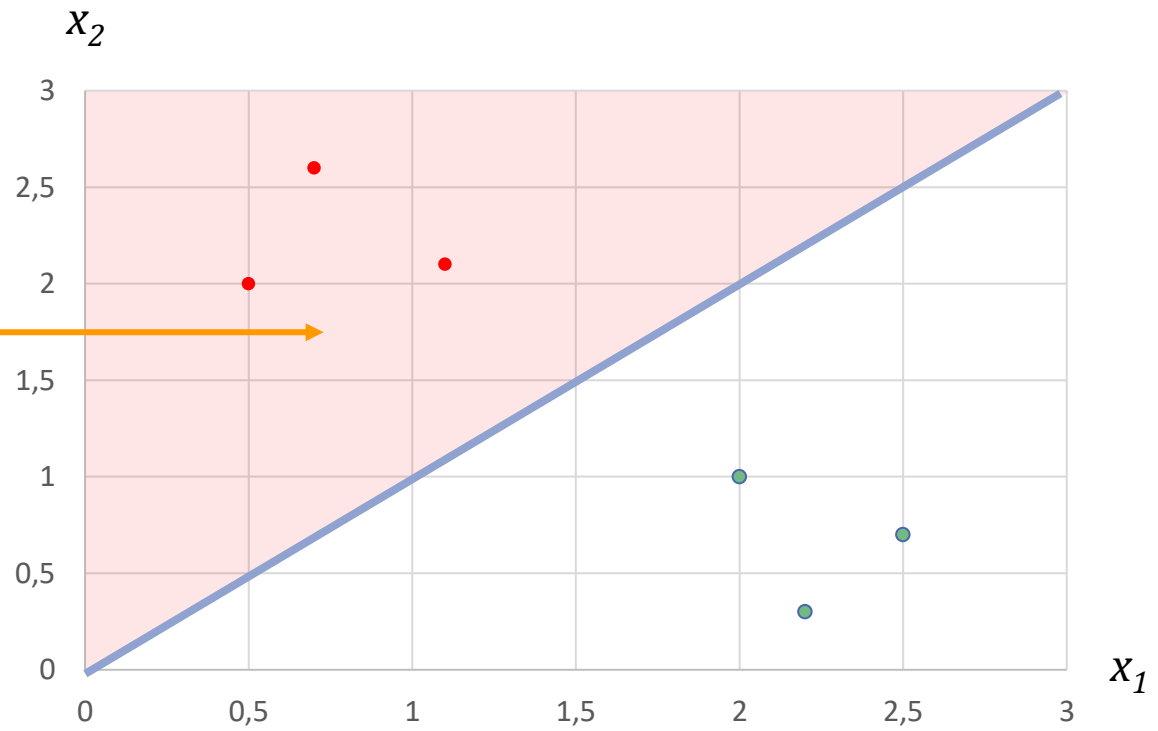
- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

- Demi-plan positif

$$\alpha x_1 + \beta x_2 + \gamma > 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

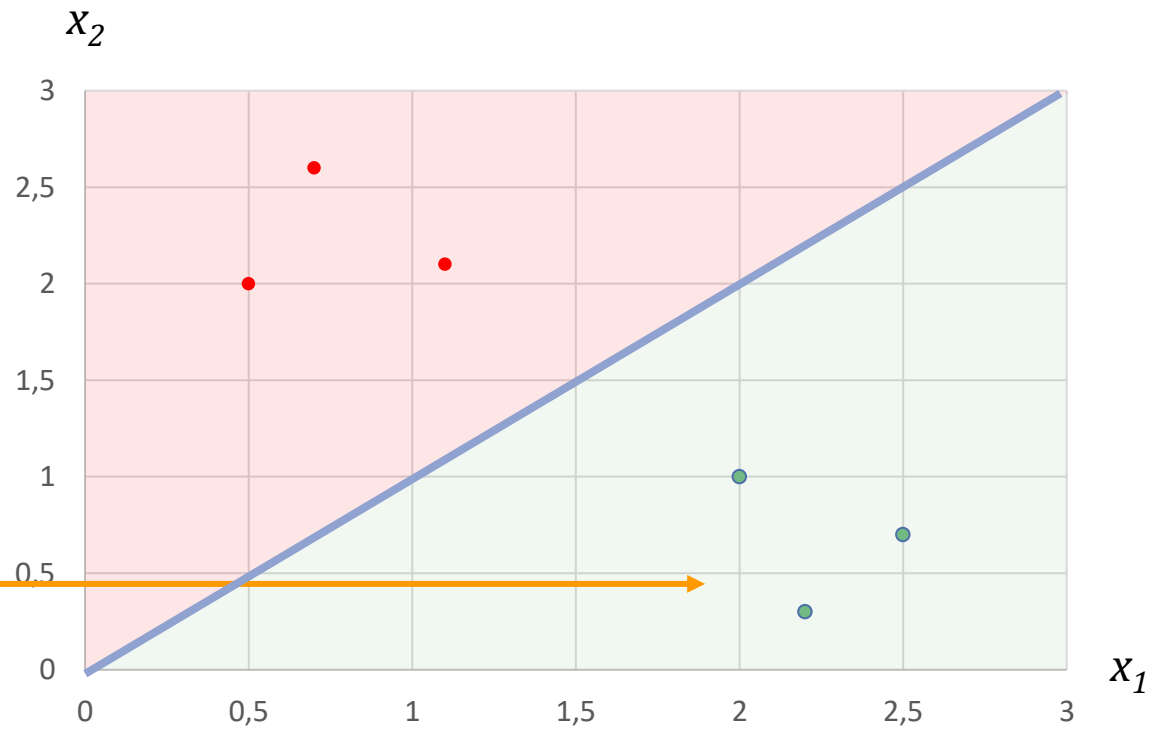
- Demi-plan positif

$$\alpha x_1 + \beta x_2 + \gamma > 0$$

- Demi-plan négatif

$$\alpha x_1 + \beta x_2 + \gamma < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

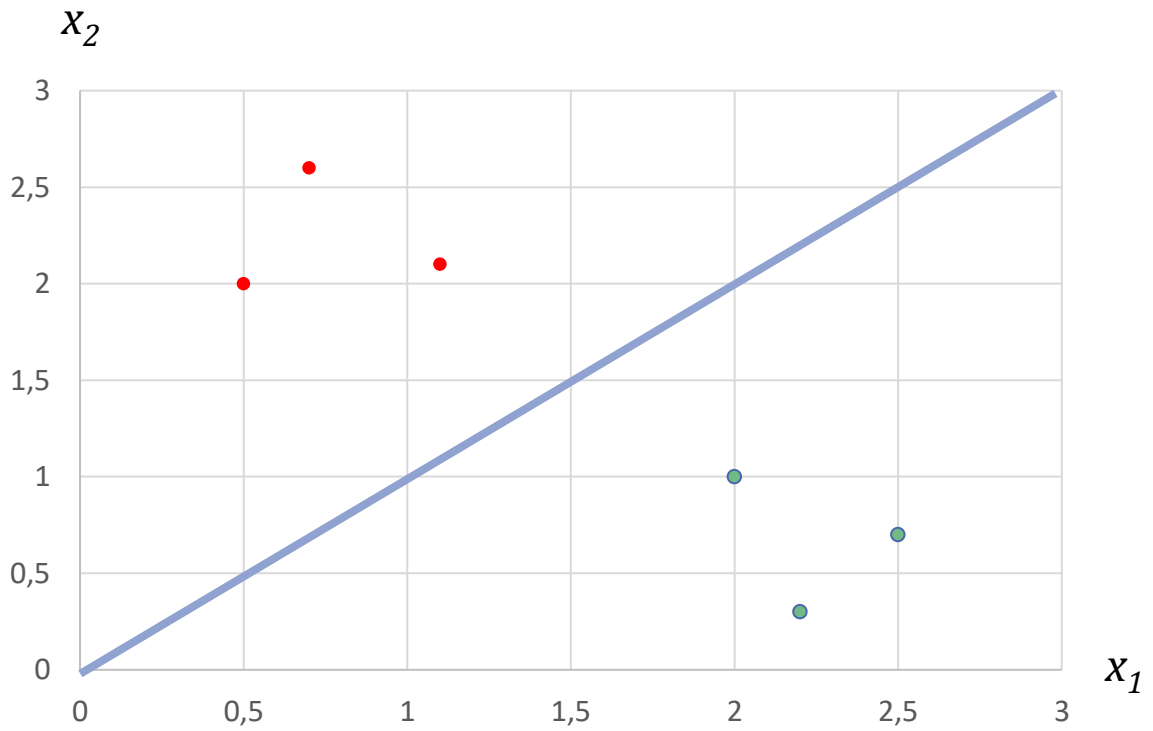


Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



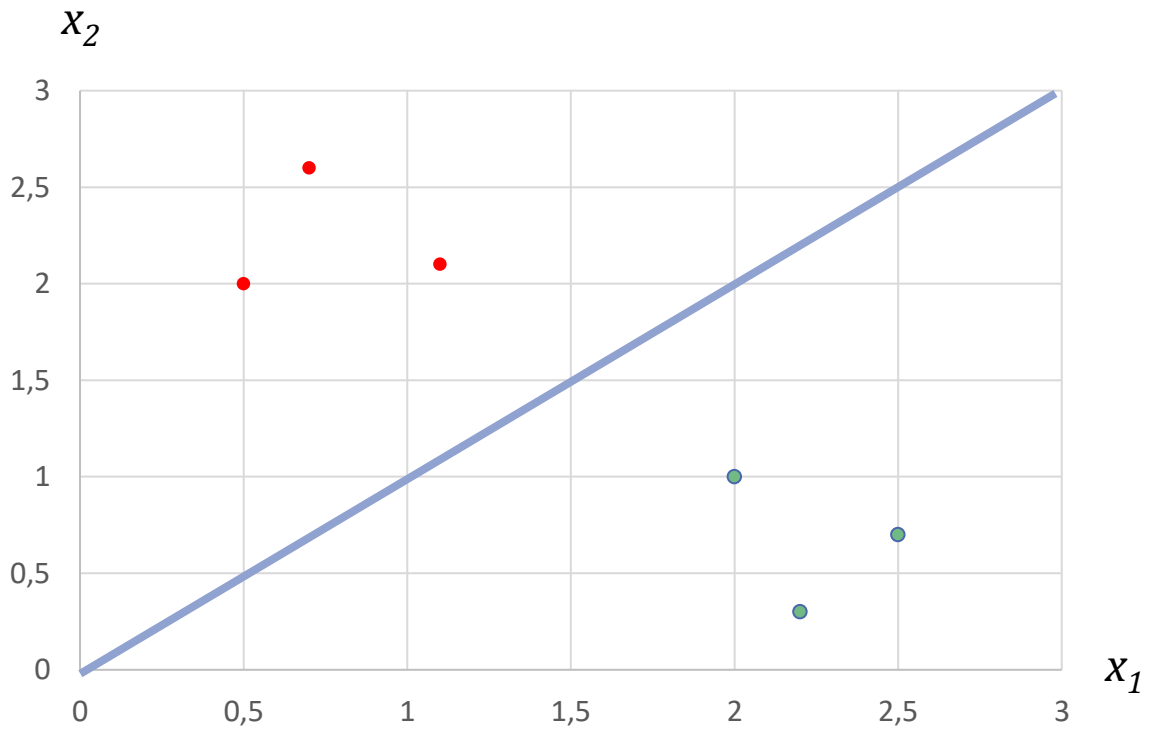
Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

$$w_1 x_1 + \beta x_2 + \gamma = 0 \quad \text{avec } w_1 = \alpha$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

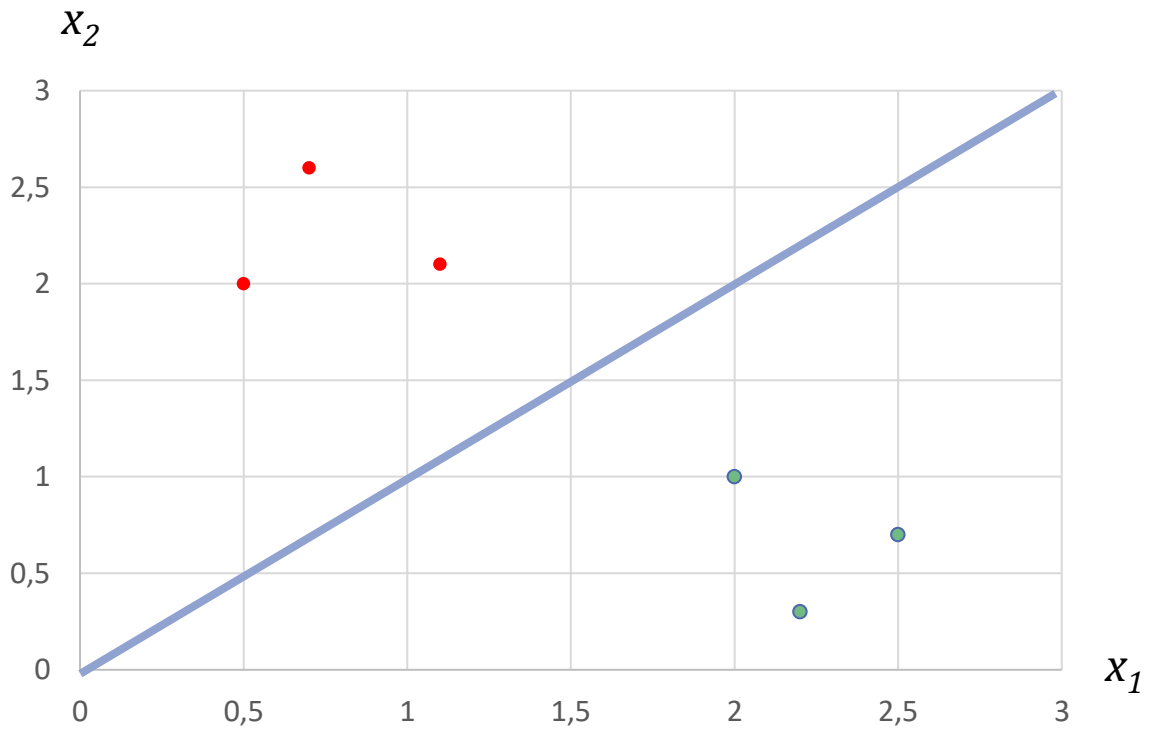
$$w_1 = \alpha$$

$$w_1 x_1 + \beta x_2 + \gamma = 0$$

$$w_2 = \beta$$

$$w_1 x_1 + w_2 x_2 + \gamma = 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

$w_1 = \alpha$

$$w_1 x_1 + \beta x_2 + \gamma = 0$$

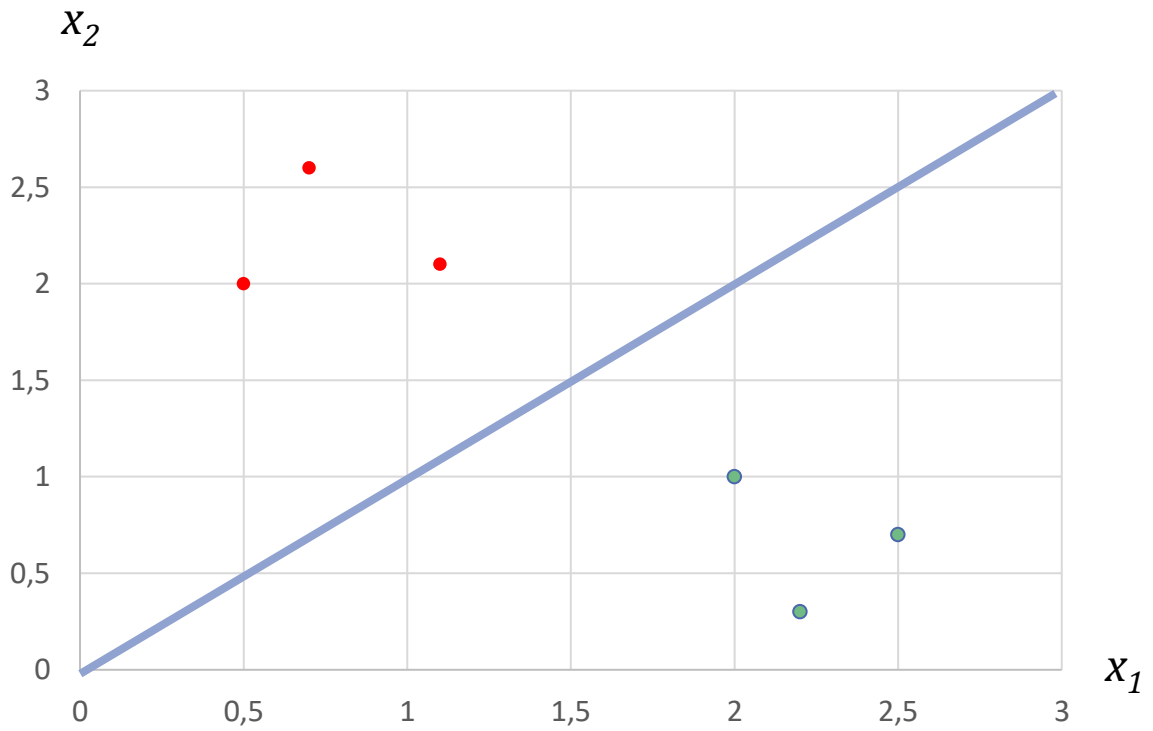
$w_2 = \beta$

$$w_1 x_1 + w_2 x_2 + \gamma = 0$$

$b = \gamma$

$$w_1 x_1 + w_2 x_2 + b = 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Equation de la frontière de décision

$$\alpha x_1 + \beta x_2 + \gamma = 0$$

$w_1 = \alpha$

$$w_1 x_1 + \beta x_2 + \gamma = 0$$

$w_2 = \beta$

$$w_1 x_1 + w_2 x_2 + \gamma = 0$$

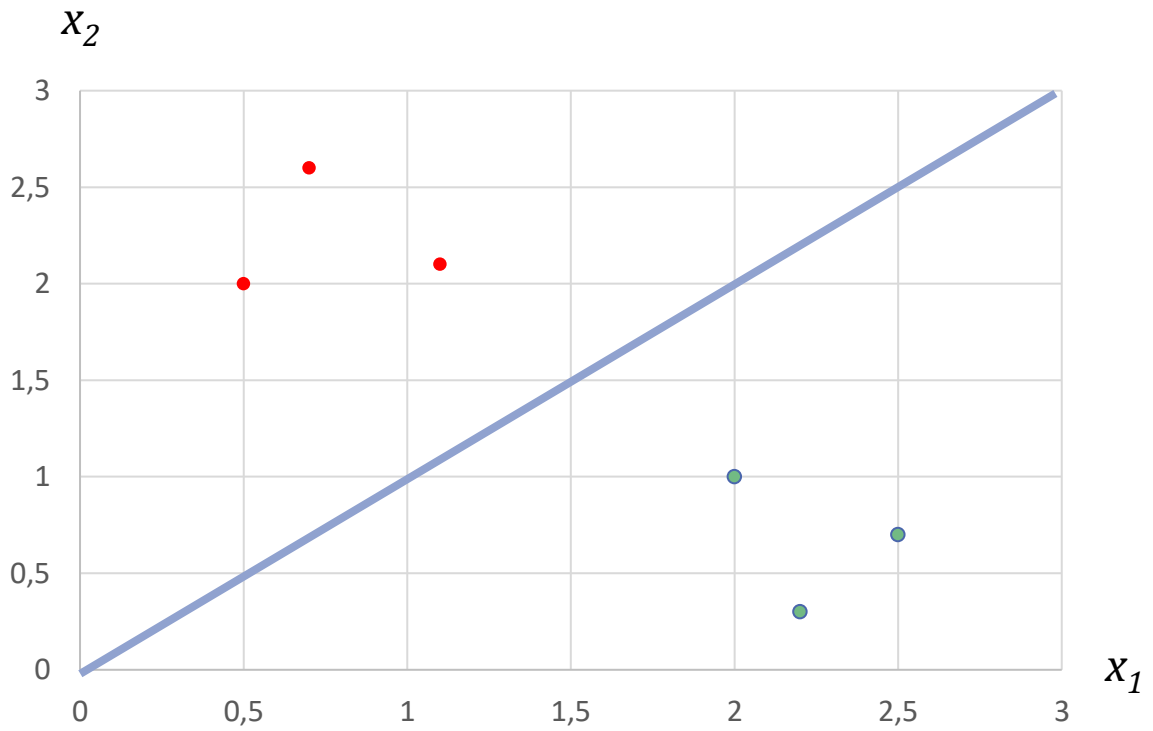
$b = \gamma$

$$w_1 x_1 + w_2 x_2 + b = 0$$

Forme générale pour n

$$\sum_{i=1}^{n} w_i x_i + b = 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

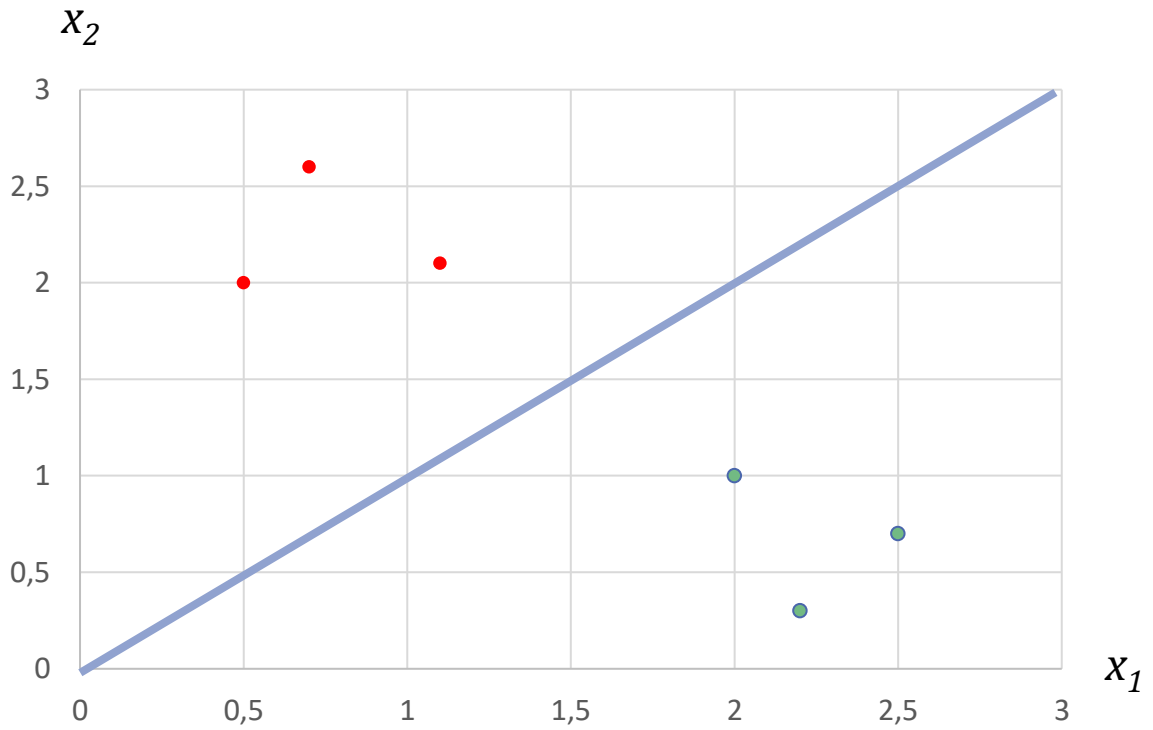


Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$\sum_{i=1}^{n} w_i x_i + b = 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

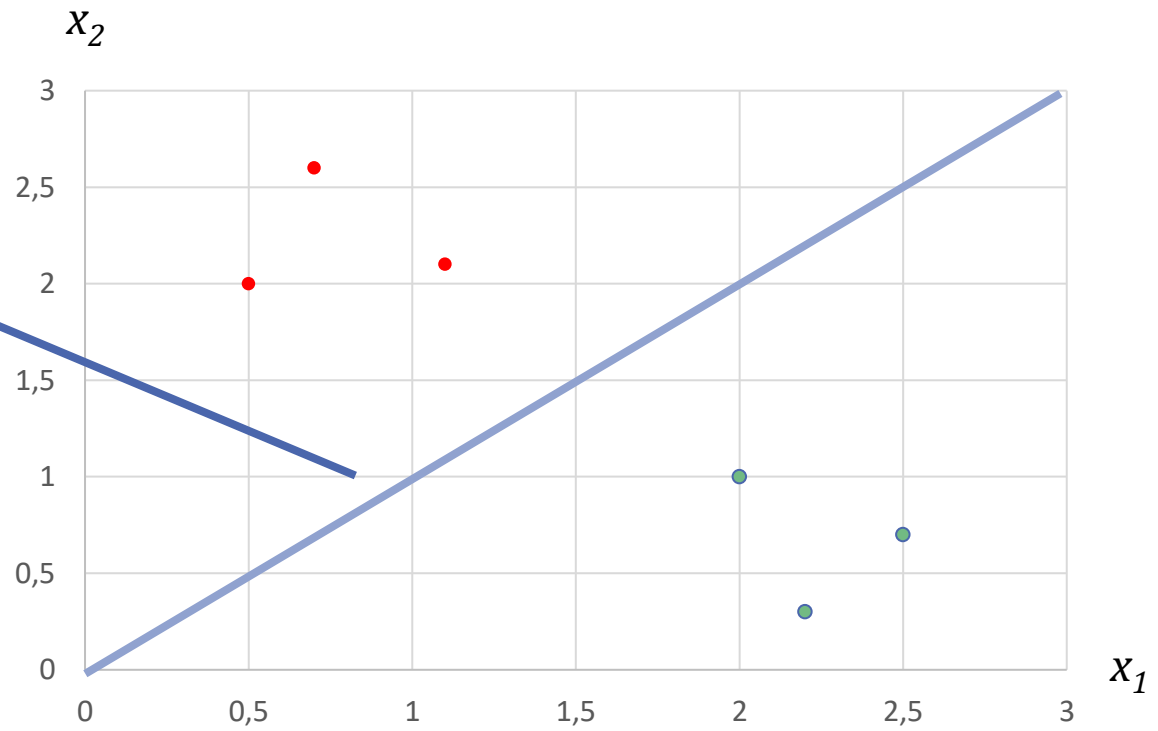
- Partition de l'espace
  - Equation de la frontière de décision

$$\sum_{i=1}^{n} w_i x_i + b = 0$$

Hyperplan de dimension $n - 1$

Pour $n = 2$ une droite

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

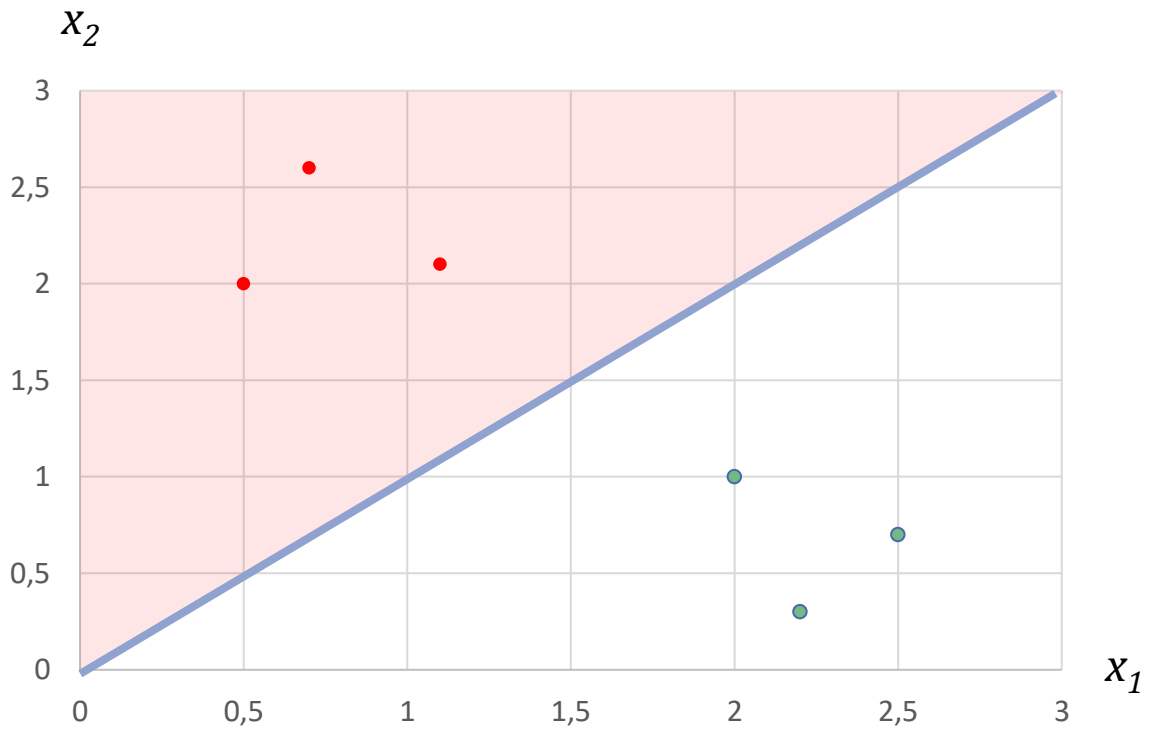
- Partition de l'espace
  - Equation de la frontière de décision

$$\sum_{i=1}^{n} w_i x_i + b = 0$$

  - Demi-plan positif

$$\sum_{i=1}^{n} w_i x_i + b > 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$\sum_{i=1}^{n} w_i x_i + b = 0$$

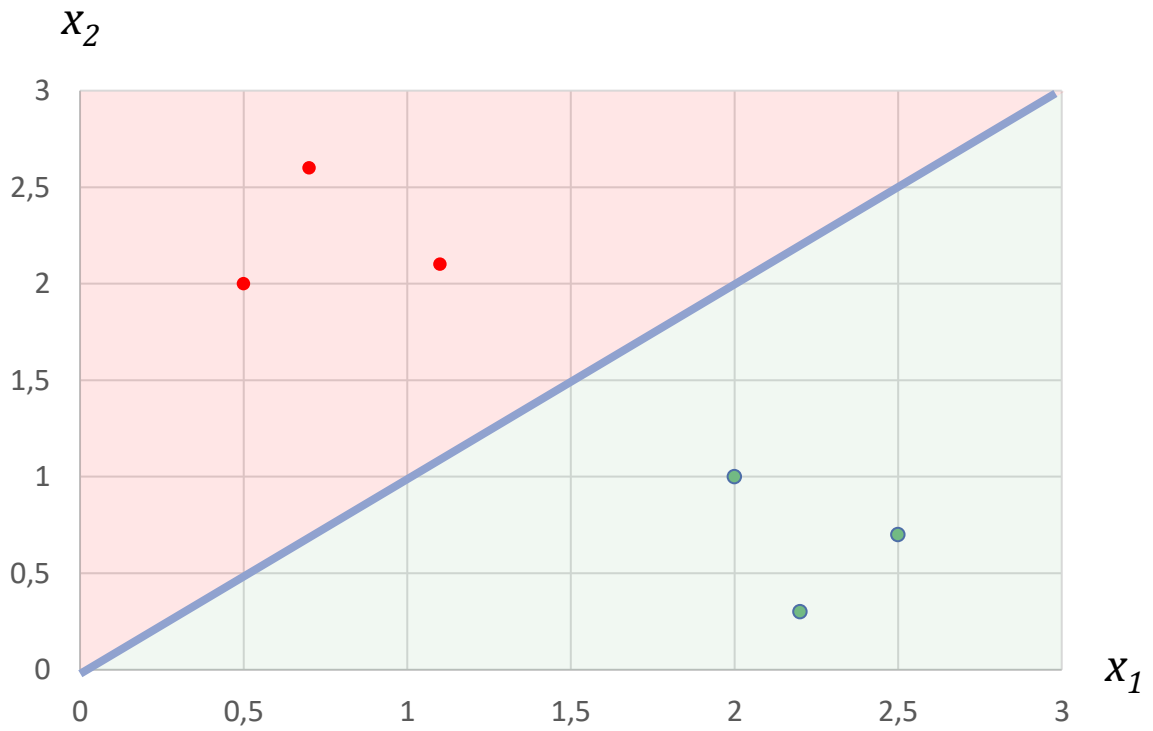
  - Demi-plan positif

$$\sum_{i=1}^{n} w_i x_i + b > 0$$

  - Demi-plan négatif

$$\sum_{i=1}^{n} w_i x_i + b < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

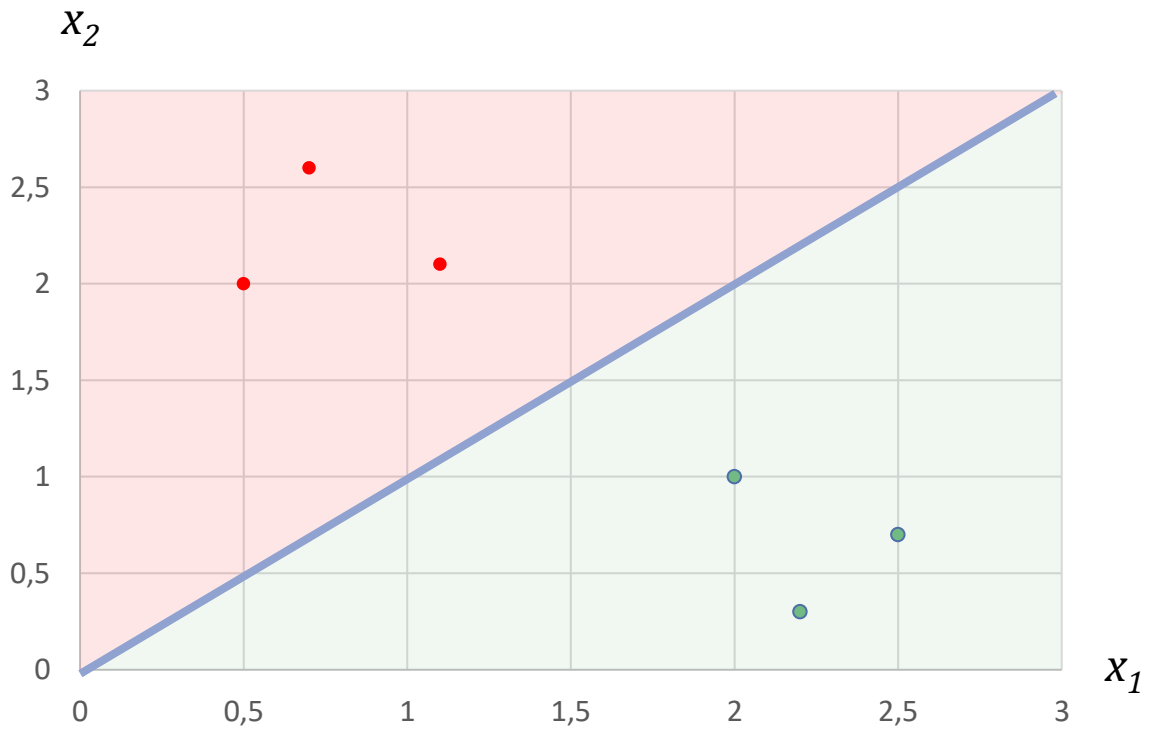
  - Demi-plan positif

$$\sum_{i=1}^{n} w_i x_i + b > 0$$

  - Demi-plan négatif

$$\sum_{i=1}^{n} w_i x_i + b < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

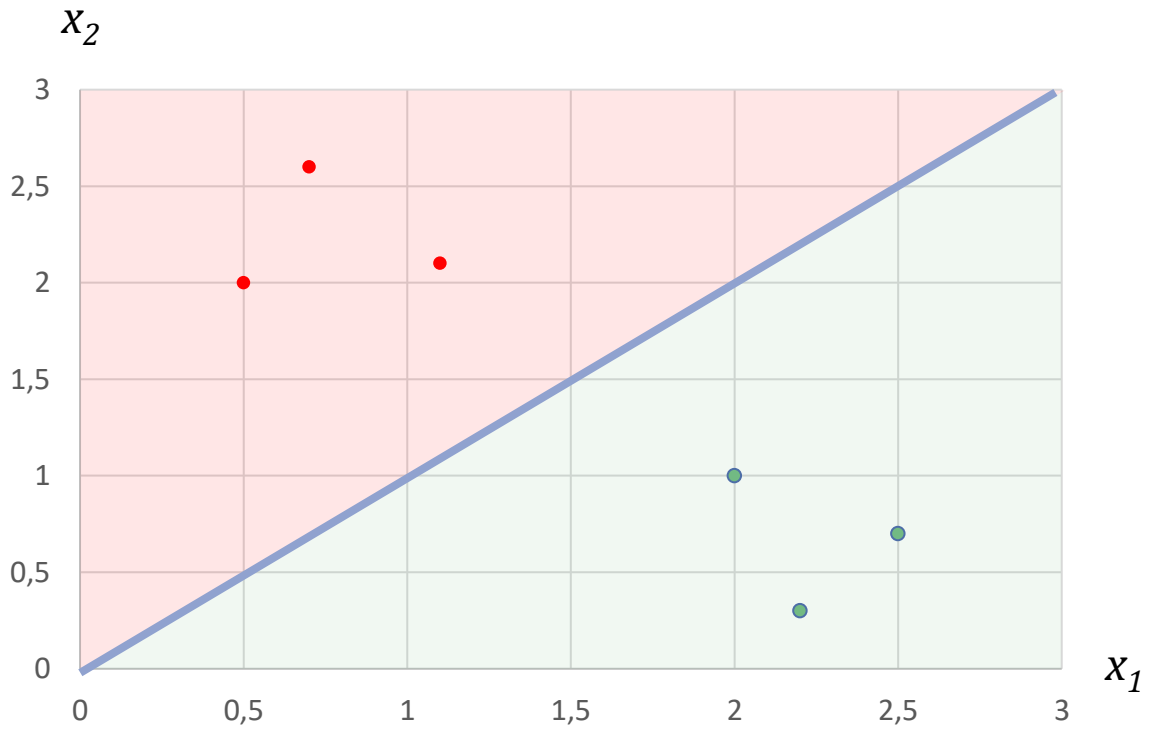
  - Demi-plan positif

$$y = 1 \; ssi \sum_{i=1}^{n} w_i x_i + b > 0$$

  - Demi-plan négatif

$$\sum_{i=1}^{n} w_i x_i + b < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

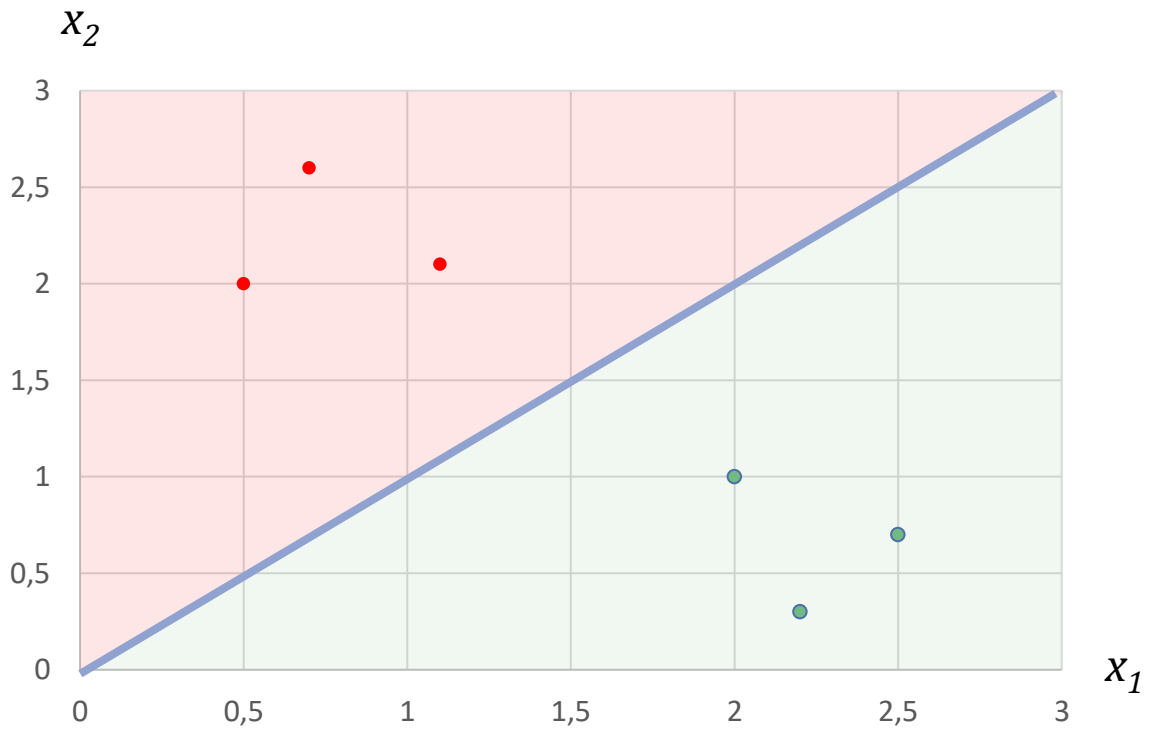
  - Demi-plan positif

$$y = 1 \; ssi \; z > 0$$

  - Demi-plan négatif

$$\sum_{i=1}^{n} w_i x_i + b < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

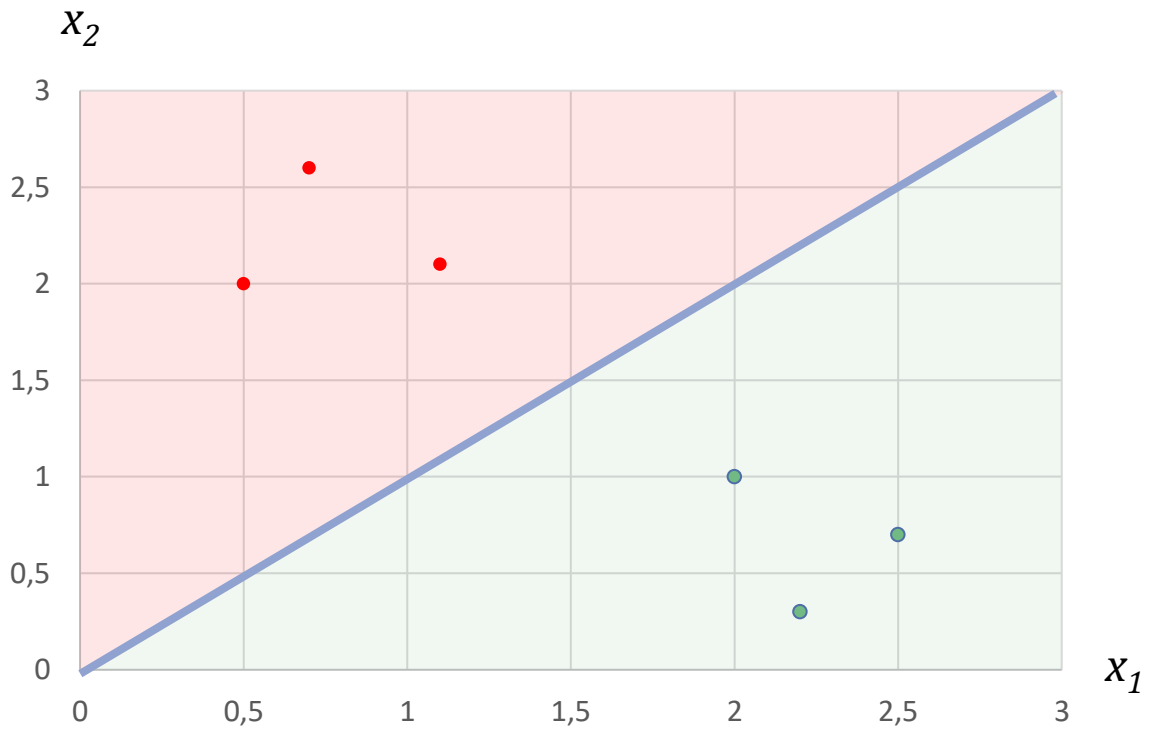
  - Demi-plan positif

$$y = 1 \; ssi \; z > 0$$

  - Demi-plan négatif

$$y = 0 \; ssi \; \sum_{i=1}^{n} w_i x_i + b < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Partition de l'espace

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

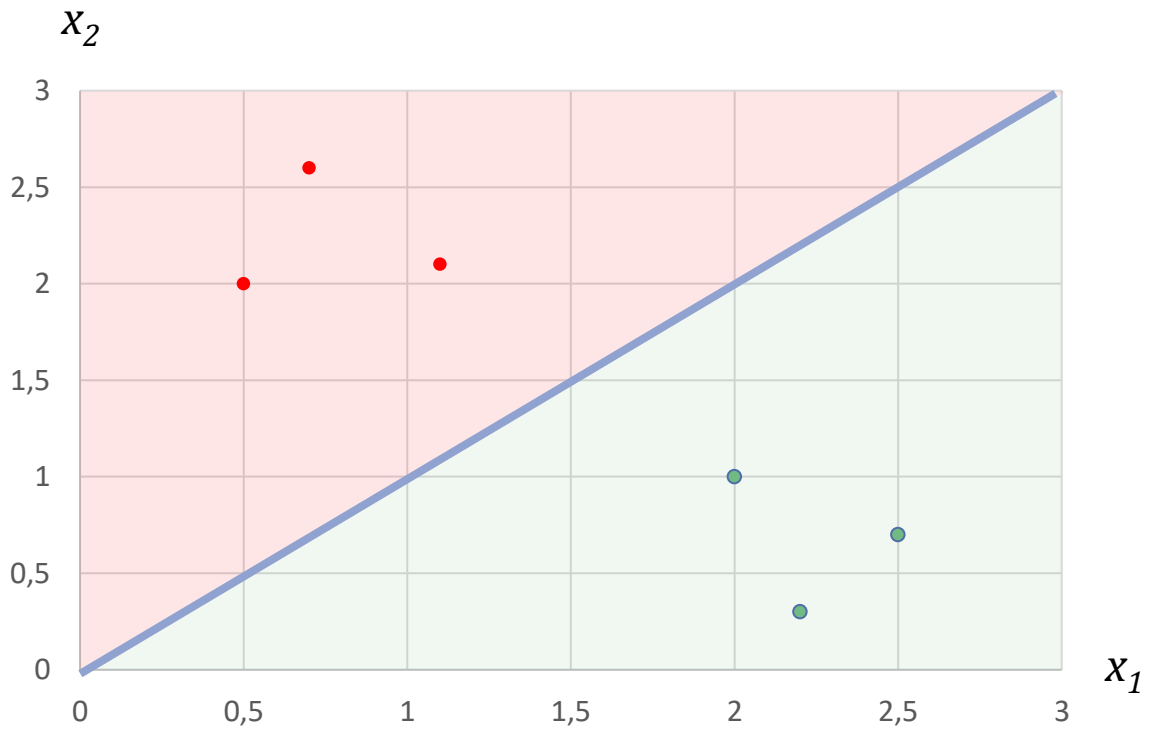
  - Demi-plan positif

$y = 1\ ssi\ z > 0$

  - Demi-plan négatif

$y = 0\ ssi\ z < 0$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Définition[Séparabilité linéaire]

Dans un espace à n dimension, deux ensembles de points A et B sont **linéairement séparables** si et seulement si il existe un hyperplan de dimension $n-1$ et d'équation H tel que:

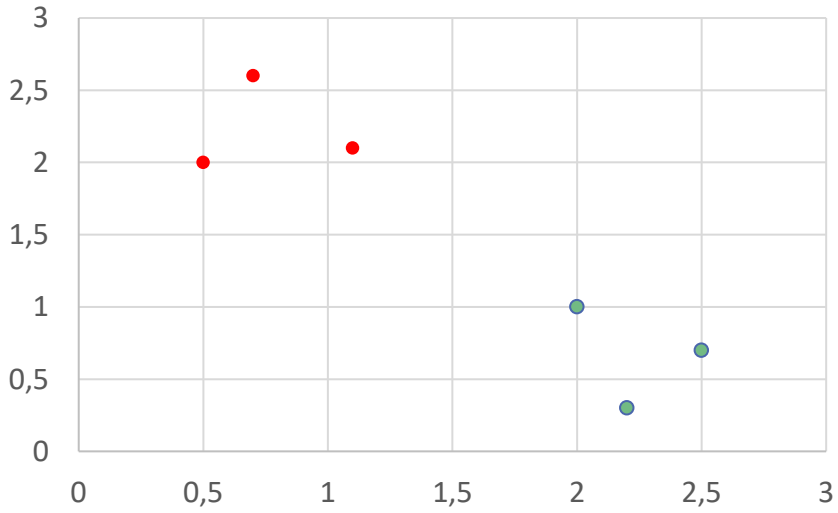
$$\forall a \in A, H(a) > 0 \text{ et } \forall b \in B, H(b) < 0$$

Définition[Séparabilité linéaire]

Dans un espace à n dimension, deux ensembles de points A et B sont **linéairement séparables** si et seulement si il existe un hyperplan de dimension $n-1$ et d'équation H tel que:

$$\forall a \in A, H(a) > 0 \text{ et } \forall b \in B, H(b) < 0$$

Exemple[Séparabilité linéaire]

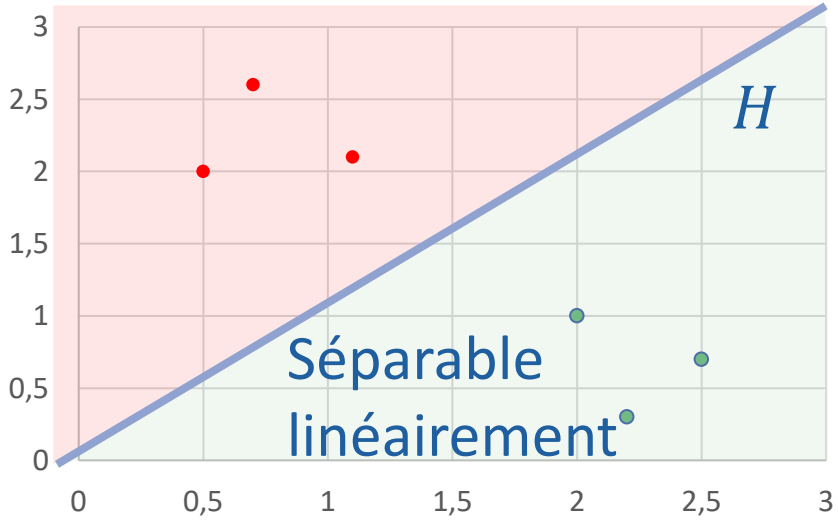


Définition[Séparabilité linéaire]

Dans un espace à n dimension, deux ensembles de points A et B sont **linéairement séparables** si et seulement si il existe un hyperplan de dimension $n-1$ et d'équation H tel que:

$$\forall a \in A, H(a) > 0 \text{ et } \forall b \in B, H(b) < 0$$

Exemple[Séparabilité linéaire]

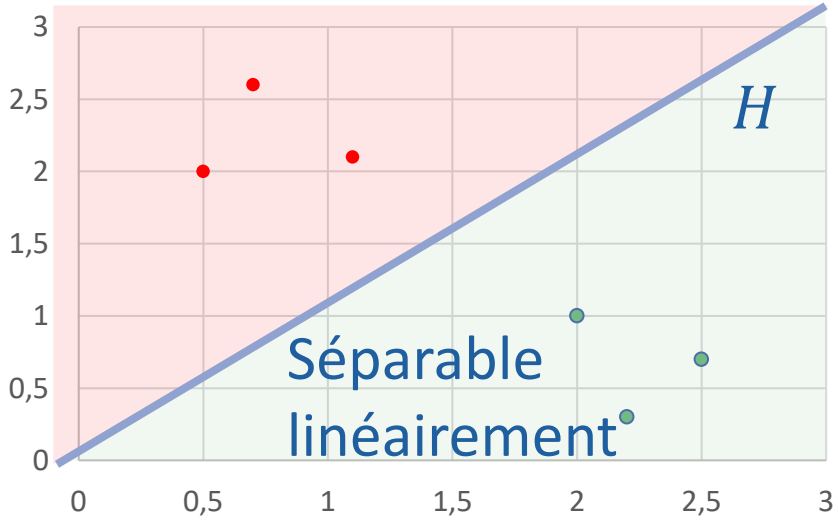


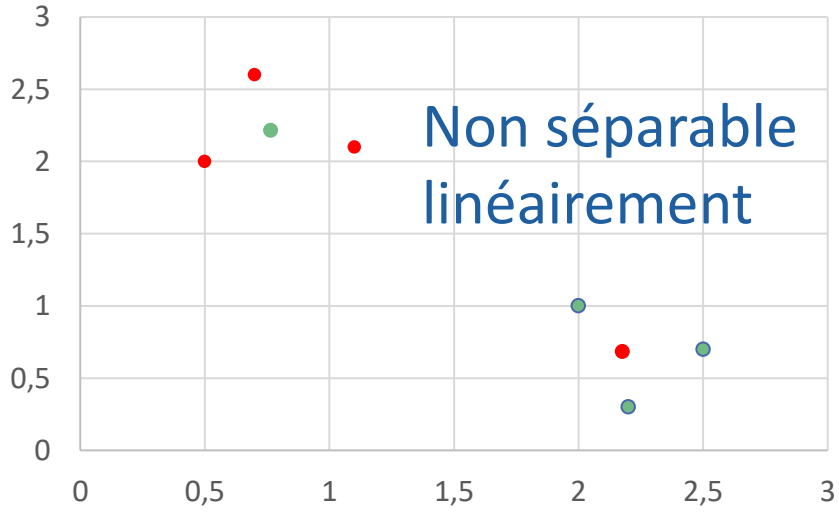
Définition[Séparabilité linéaire]

Dans un espace à n dimension, deux ensembles de points A et B sont **linéairement séparables** si et seulement si il existe un hyperplan de dimension $n-1$ et d'équation H tel que:

$$\forall a \in A, H(a) > 0 \text{ et } \forall b \in B, H(b) < 0$$

Exemple[Séparabilité linéaire]





Classification binaire linéaire

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

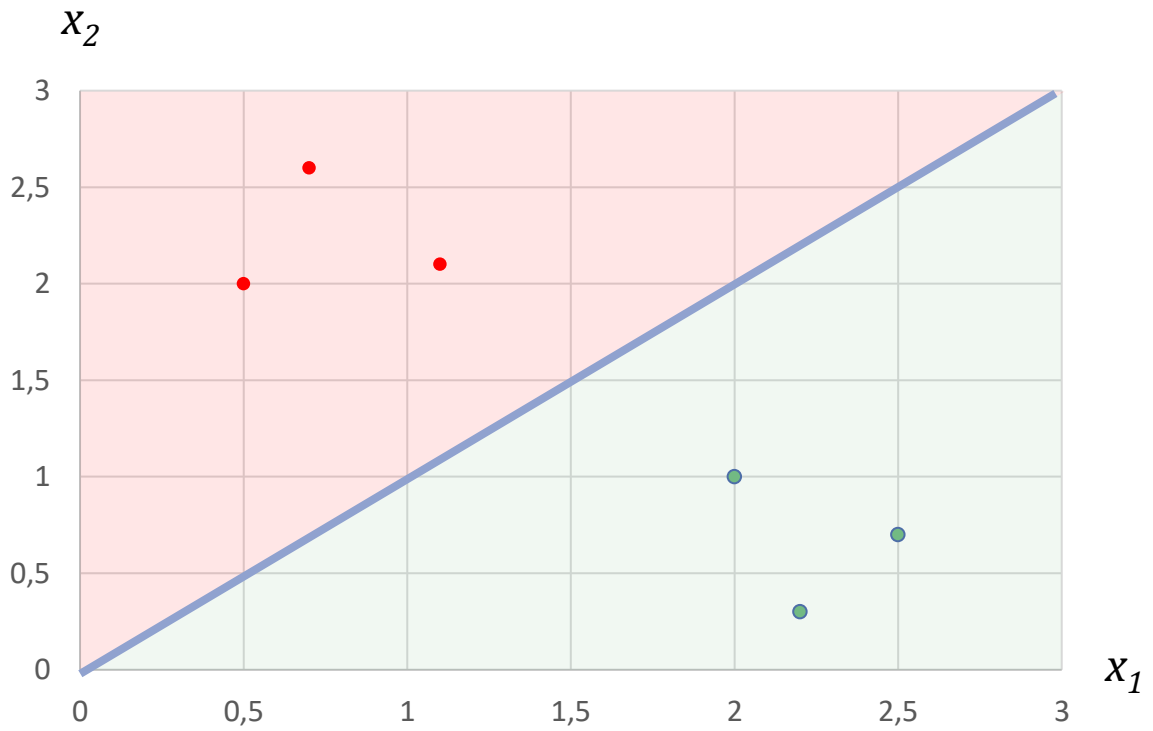
  - Demi-plan positif

$$y = 1 \; ssi \; z > 0$$

  - Demi-plan négatif

$$y = 0 \; ssi \; z < 0$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Classification binaire linéaire

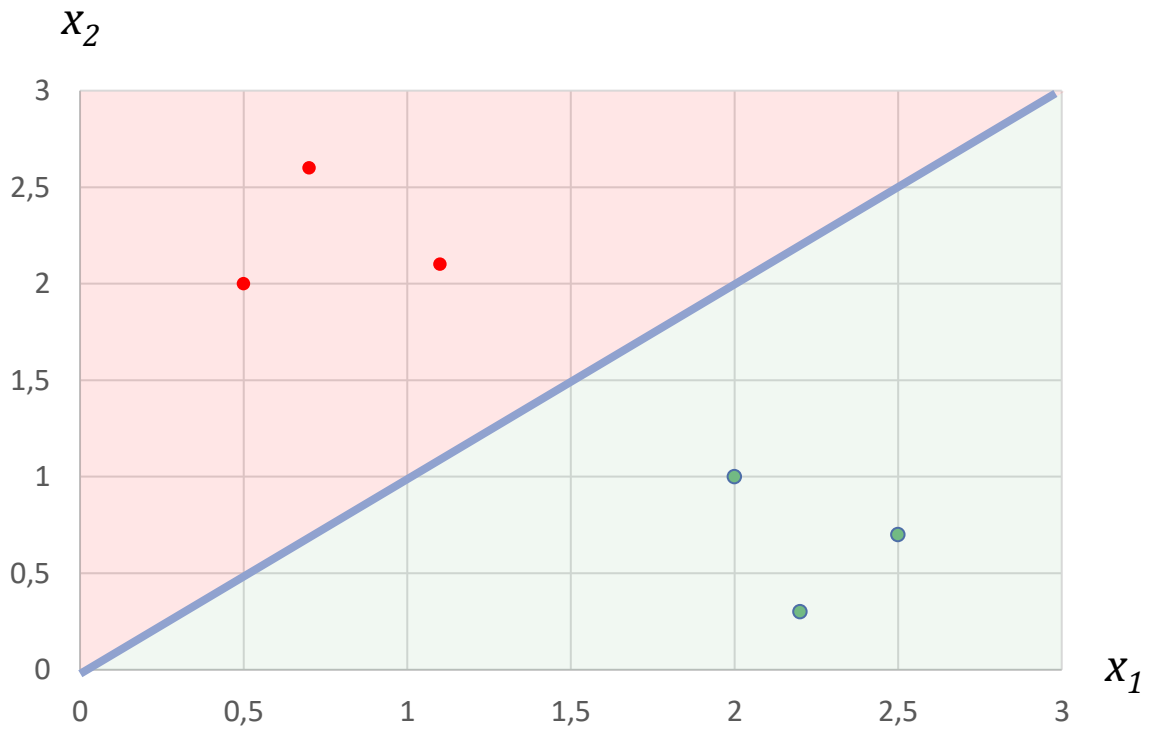
- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

  - Classe

$$y = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Classification binaire linéaire

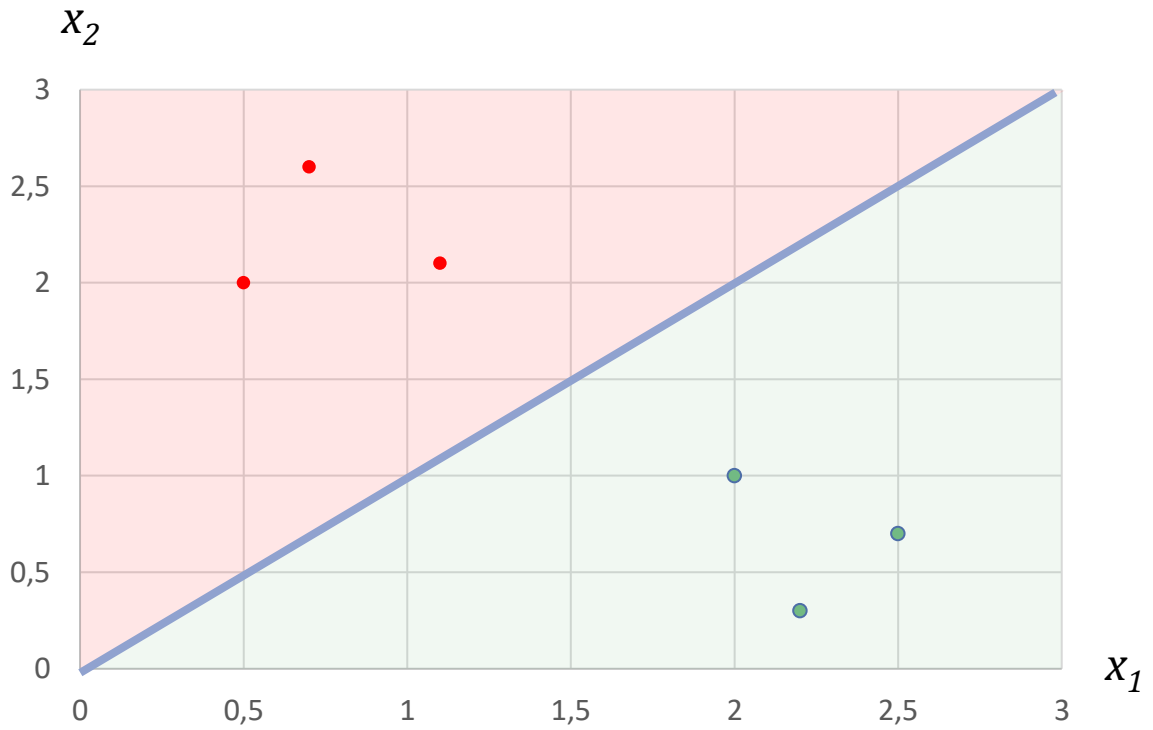
- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

  - Fonction de classification

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Classification binaire linéaire

- Partition de l'espace
  - Equation de la frontière de décision

$$z = \sum_{i=1}^{n} w_i x_i + b = 0$$

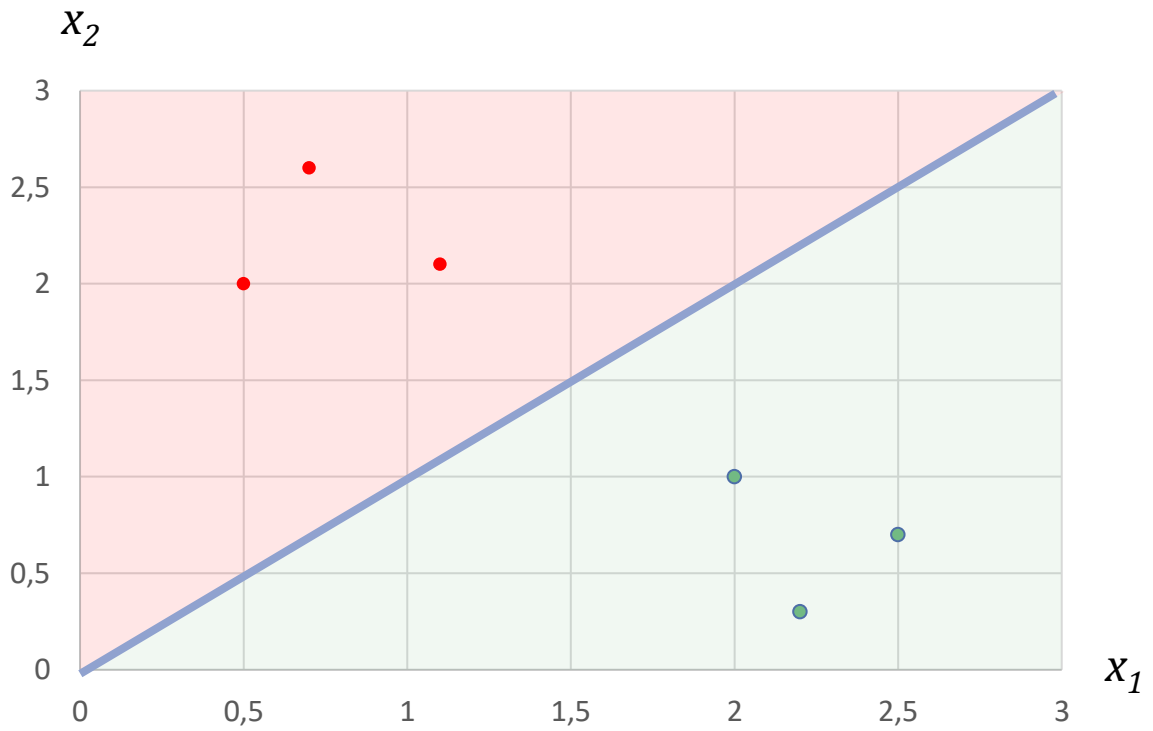
  - Fonction de classification

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

  - Classification

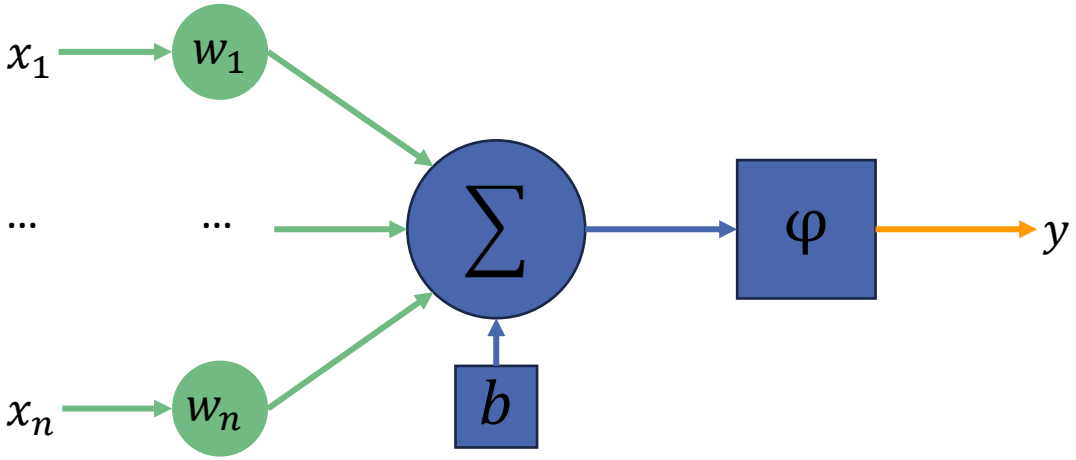
$$y = \varphi(z)$$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Classification binaire linéaire

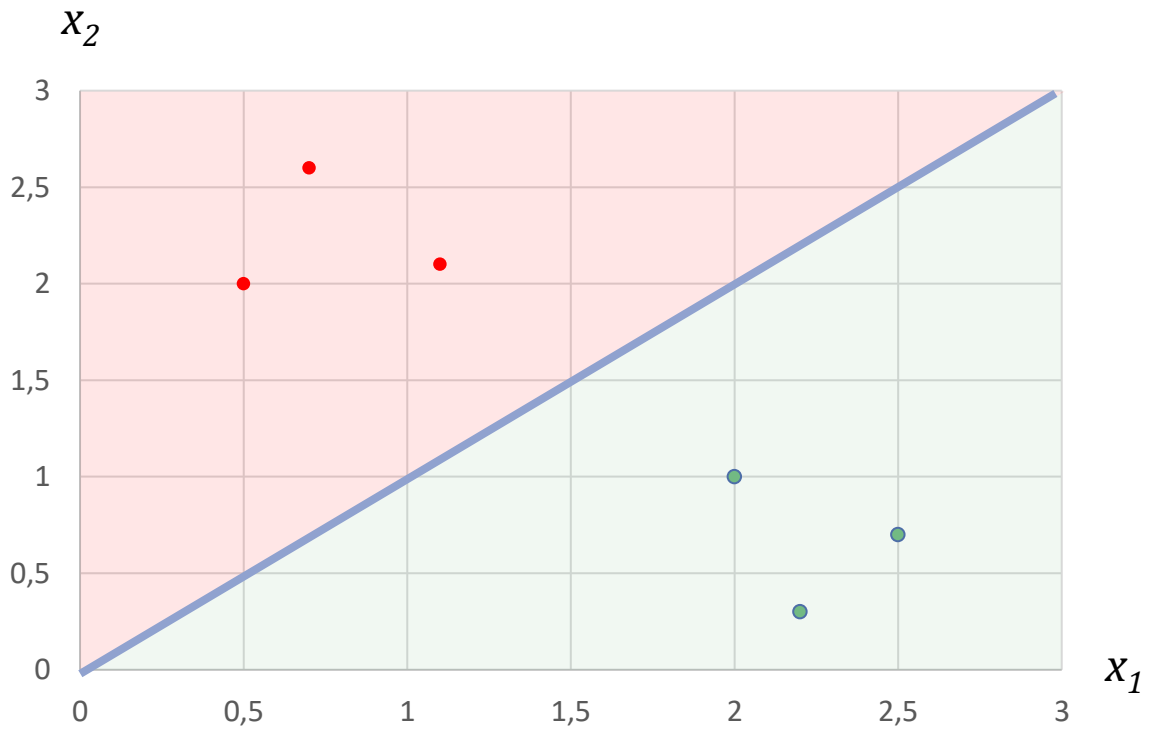
- Un neurone formel peut résoudre une classification binaire



$W = (w_1, \dots, w_i, \dots, w_n), n > 1$ Poids

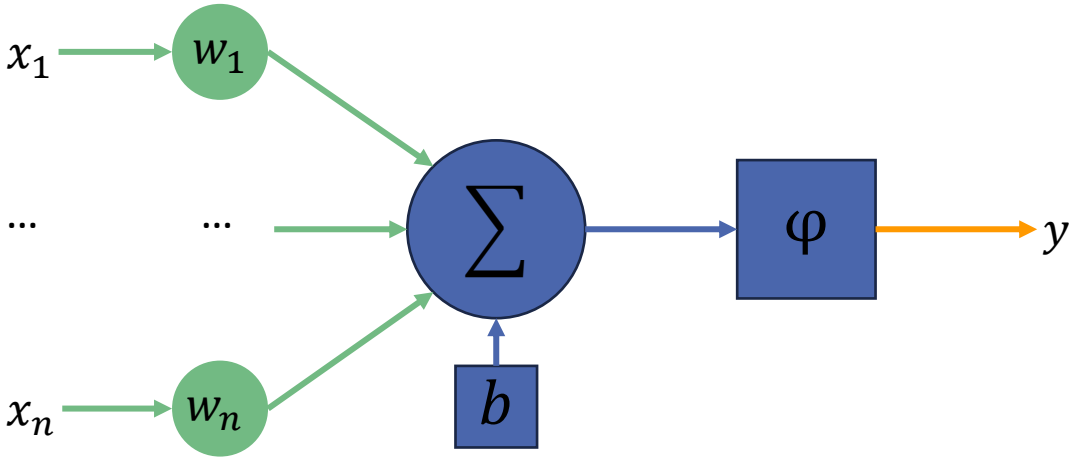
$$z = \sum_{i=1}^{n} x_i w_i + b$$ Agrégation

$$y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$ Activation



Classification binaire linéaire

- Un neurone formel peut résoudre une classification binaire linéaire

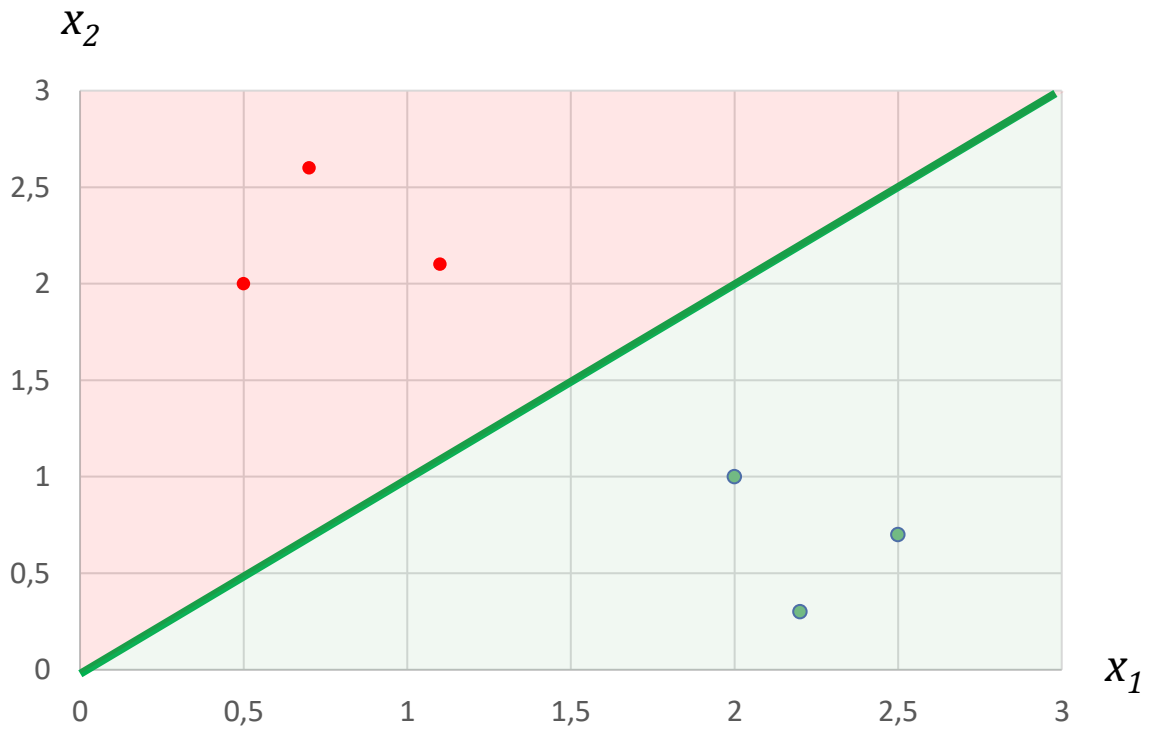


$\mathcal{W} = \{w_i\}, 1 \leq i \leq n$ Poids

$$z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

Agrégation Activation

Dépend uniquement des w_i

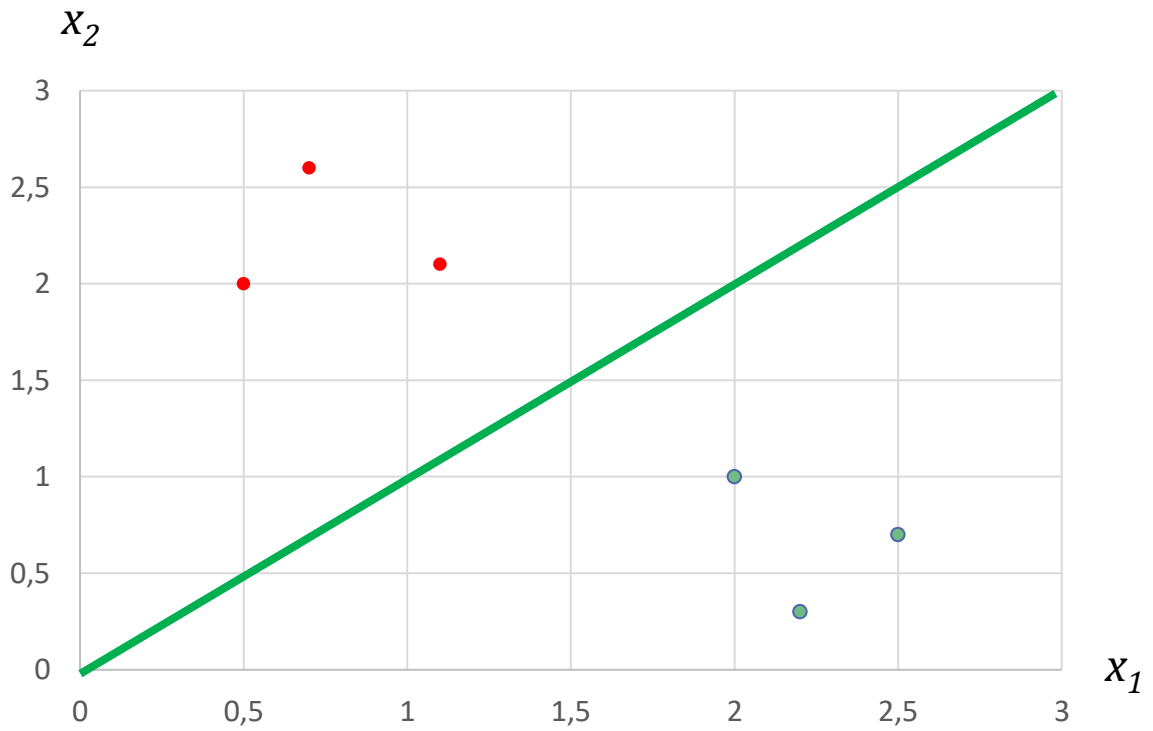


Classification binaire linéaire

- Un neurone formel peut résoudre une classification binaire

$$\mathcal{W} = \{w_i\}, 1 \leq i \leq n \qquad z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

Comment déterminer les w_i qui produisent la partition ?

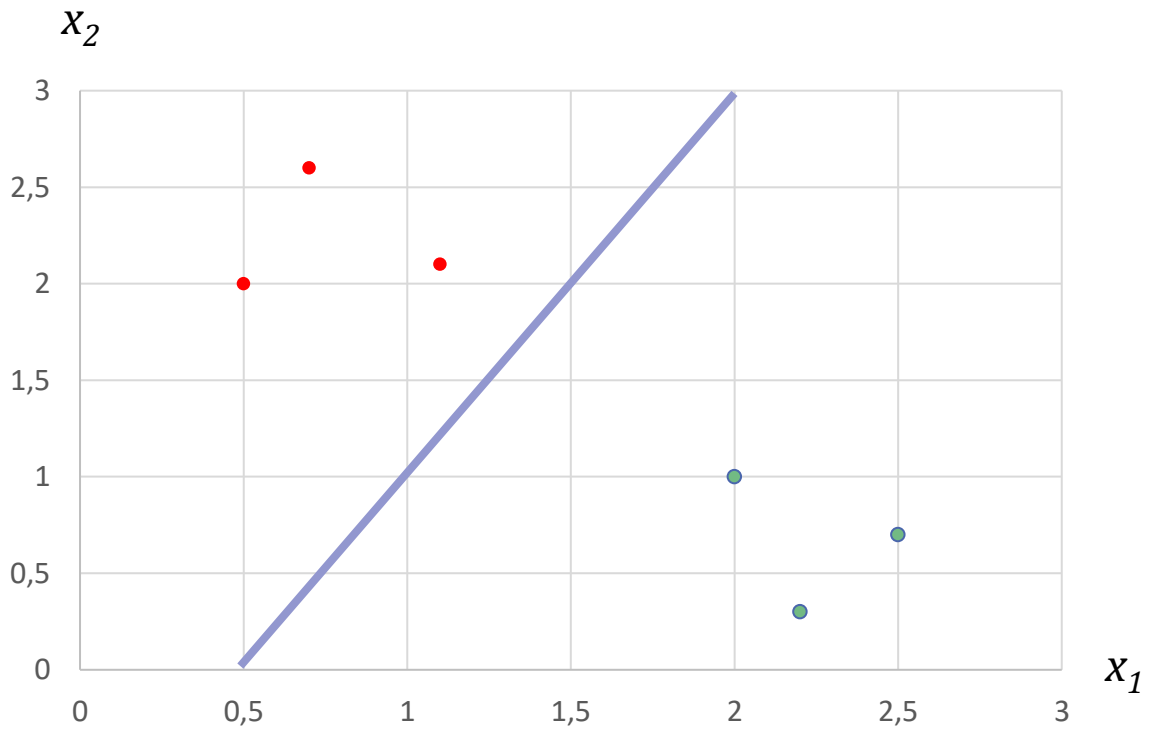


Classification binaire linéaire

- Un neurone formel peut résoudre une classification binaire

$$\mathcal{W} = \{w_i\}, 1 \leq i \leq n \qquad z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

Comment déterminer les w_i qui produisent la partition ?

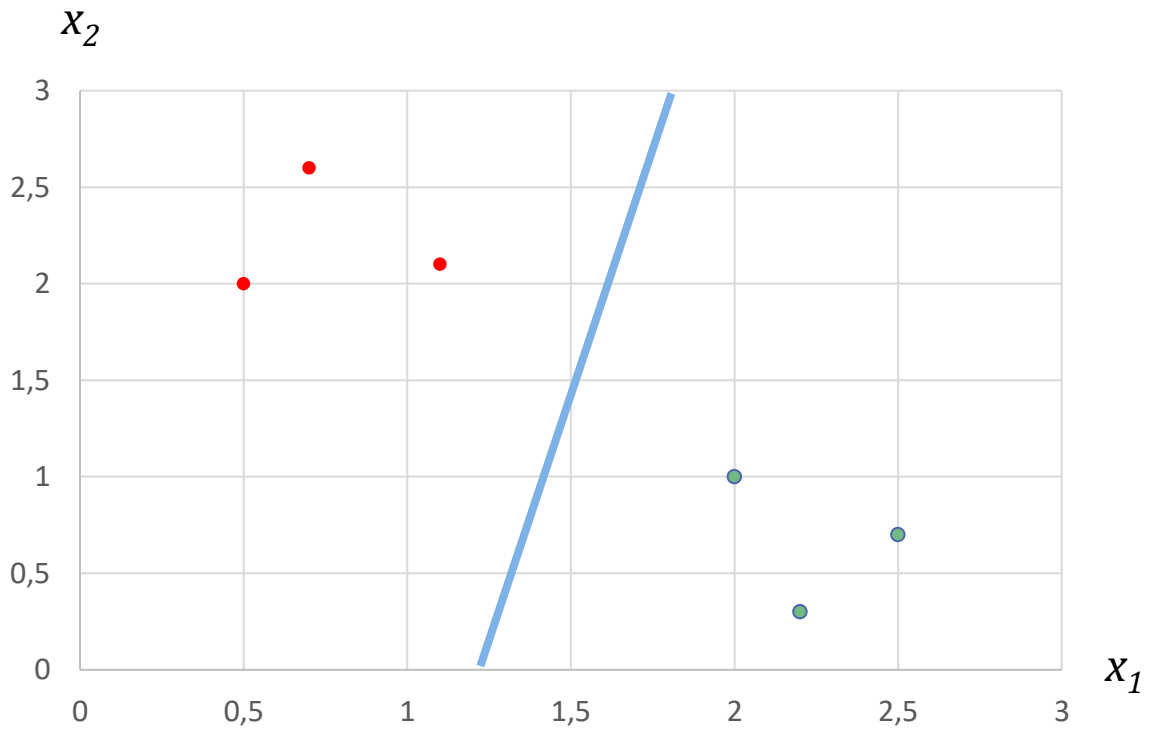


Classification binaire linéaire

- Un neurone formel peut résoudre une classification binaire

$$\mathcal{W} = \{w_i\}, 1 \leq i \leq n \qquad z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

Comment déterminer les w_i qui produisent la partition ?

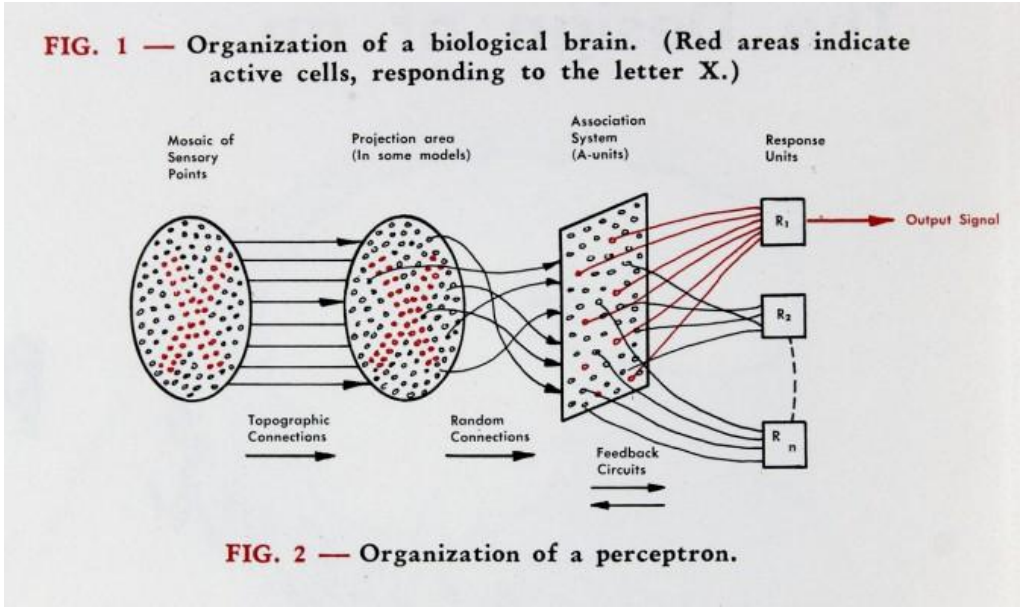


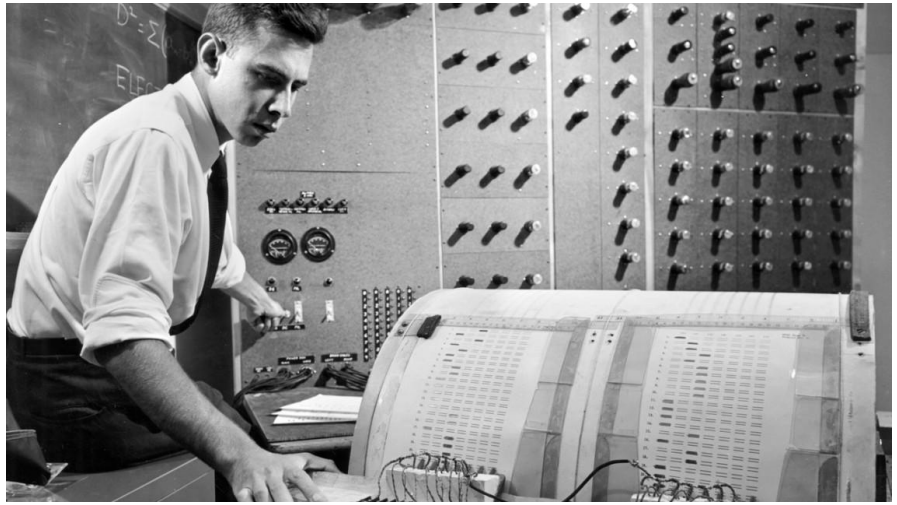
Perceptron

- Proposé par Frank Rosenblatt en 1957 (Cornell)

  The Design of an Intelligent Automaton in *Research Trends*, a Cornell Aeronautical Laboratory publication, 1958

- Première notion d'**apprentissage automatique**





https://news.cornell.edu/stories/2019/09/professors-perceptron-paved-way-ai-60-years-too-soon

Définition[Perceptron]

Un **perceptron** est un neurone formel à n entrées tel que:

- L'ensemble de ses poids est : $\mathcal{W} = \{w_i\}, 1 \leq i \leq n$
- Sa fonction d'agrégation est : $z = g(x_1, \dots, x_i, \dots, x_n) = \sum_{i=1}^{n} w_i x_i + b$
- Sa fonction d'activation est : $\varphi(z) = \begin{cases} 1 \; si \; z \geq 0 \\ 0 \; si \; z < 0 \end{cases}$

Définition[Perceptron]

Un **perceptron** est un neurone formel à n entrées tel que:

- L'ensemble de ses poids est : $\mathcal{W} = \{w_i\}, 1 \leq i \leq n$
- Sa fonction d'agrégation est : $z = g(x_1, \dots, x_i, \dots, x_n) = \sum_{i=1}^{n} w_i x_i + b$
- Sa fonction d'activation est : $\varphi(z) = \begin{cases} 1 \; si \; z \geq 0 \\ 0 \; si \; z < 0 \end{cases}$ fonction **Heaviside**

Le > devient un $\geq$ pour que $\varphi(z)$ soit définie en 0

Définition[Perceptron]

Un perceptron est un neurone formel à n entrées tel que:

- L'ensemble de ses poids est : $\mathcal{W} = \{w_i\}, 1 \leq i \leq n$
- Sa fonction d'agrégation est : $z = g(x_1, \dots, x_i, \dots, x_n) = \sum_{i=1}^{n} w_i x_i + b$
- Sa fonction d'activation est : $\varphi(z) = \begin{cases} 1 \; si \; z \geq 0 \\ 0 \; si \; z < 0 \end{cases}$
- Les poids $\mathcal{W}$ sont déterminés par un apprentissage à partir de données

Définition[Perceptron]

Un **perceptron** est un neurone formel à n entrées tel que:

- L'ensemble de ses poids est : $\mathcal{W} = \{w_i\}, 1 \leq i \leq n$
- Sa fonction d'agrégation est : $z = g(x_1, \dots, x_i, \dots, x_n) = \sum_{i=1}^{n} w_i x_i + b$
- Sa fonction d'activation est : $\varphi(z) = \begin{cases} 1 \; si \; z \geq 0 \\ 0 \; si \; z < 0 \end{cases}$
- Les poids $\mathcal{W}$ sont déterminés par un apprentissage à partir de données

Quelle est la forme de ces données ?

Notations[Perceptron]

Soit un perceptron appliqué à un jeux de données $\mathcal{D}$ tel que:

$$\mathcal{D} = \left\{S^{(k)}\right\}, 1 \leq k \leq m,\ S^{(k)} = t^{(k)}.X^{(k)} = \left(t^{(k)}, x_1^{(k)}, \ldots, x_i^{(k)}, \ldots, x_n^{(k)}\right)$$

Notations[Perceptron]

Soit un perceptron appliqué à un jeux de données $\mathcal{D}$ tel que:

$$\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m,\ S^{(k)} = t^{(k)}.X^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right)$$

- La valeur de la fonction d'agrégation pour l'exemple $S^{(k)}$ est notée:

$$z^{(k)} = z\left(X^{(k)}\right) = g\left(x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right) = \sum_{i=1}^{n} w_i x_i^{(k)} + b$$

Notations[Perceptron]

Soit un perceptron appliqué à un jeux de données $\mathcal{D}$ tel que:

$$\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m,\ S^{(k)} = t^{(k)}.X^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right)$$

- La valeur de la fonction d'agrégation pour l'exemple $S^{(k)}$ est notée:

$$z^{(k)} = z\left(X^{(k)}\right) = g\left(x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)}\right) = \sum_{i=1}^{n} w_i x_i^{(k)} + b$$

- La valeur de la fonction d'activation pour l'exemple $S^{(k)}$ est notée:

$$\varphi^{(k)} = \varphi\left(z^{(k)}\right) = \begin{cases} 1\ si\ z^{(k)} \geq 0 \\ 0\ si\ z^{(k)} < 0 \end{cases}$$

Définition[Prédiction]

Soit un perceptron à n entrées et de fonction d'activation φ, on appelle **prédiction**, notée y, sa valeur de sortie définie telle que:

$$y = \varphi(z), \text{ avec } z = \sum_{i=1}^{n} w_i x_i + b$$

Définition[Prédiction]

Soit un perceptron à n entrées et de fonction d'activation φ, on appelle **prédiction**, notée y, sa valeur de sortie définie telle que:

$$y = \varphi(z), \text{ avec } z = \sum_{i=1}^{n} w_i x_i + b$$

- La prédiction pour un vecteur de caractéristiques $X^{(k)}$ est notée:

$$y^{(k)} = \varphi^{(k)}$$

Définition[Prédiction]

Soit un perceptron à n entrées et de fonction d'activation φ, on appelle **prédiction**, notée y, sa valeur de sortie définie telle que:

$$y = \varphi(z), \text{ avec } z = \sum_{i=1}^{n} w_i x_i + b$$

- La prédiction pour un vecteur de caractéristiques $X^{(k)}$ est notée:

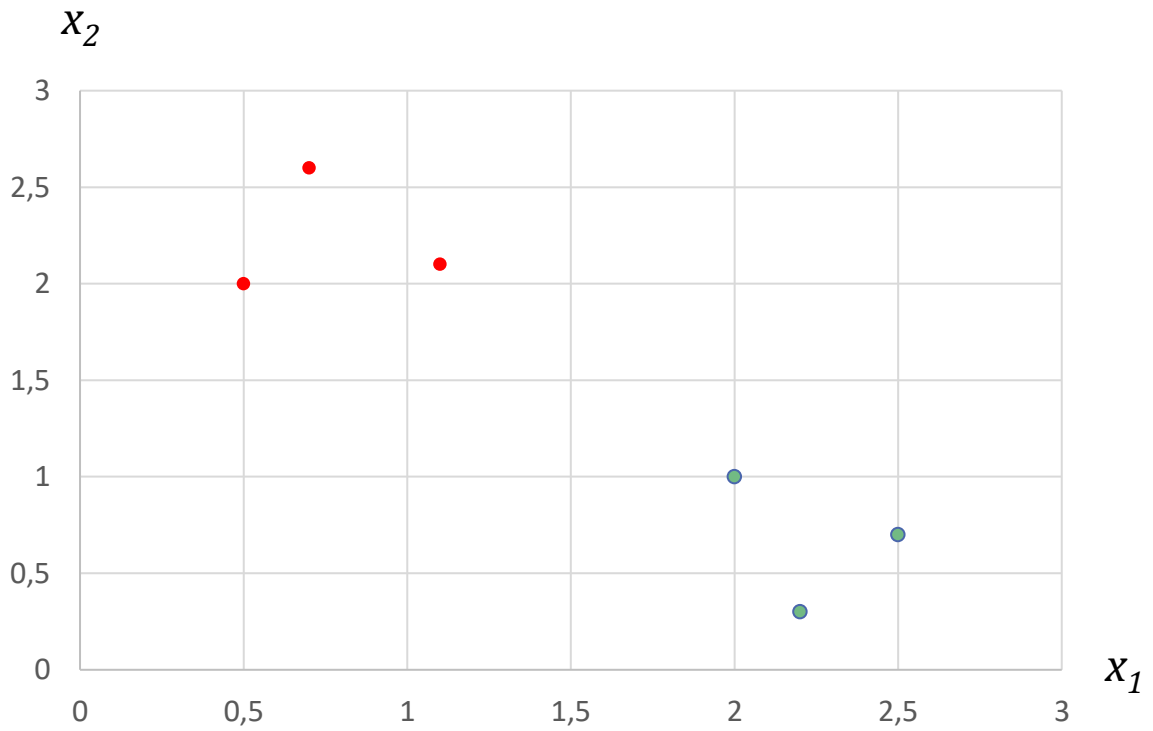
$$y^{(k)} = \varphi^{(k)}$$

- L'ensemble des prédictions pour un jeux de données $\mathcal{D}$, noté $\mathcal{Y}$, est l'ensemble des prédictions obtenues pour tous les vecteur de caractéristiques $X^{(k)}$.

Classification binaire

- Vecteur de caractéristiques ≡ coordonnées

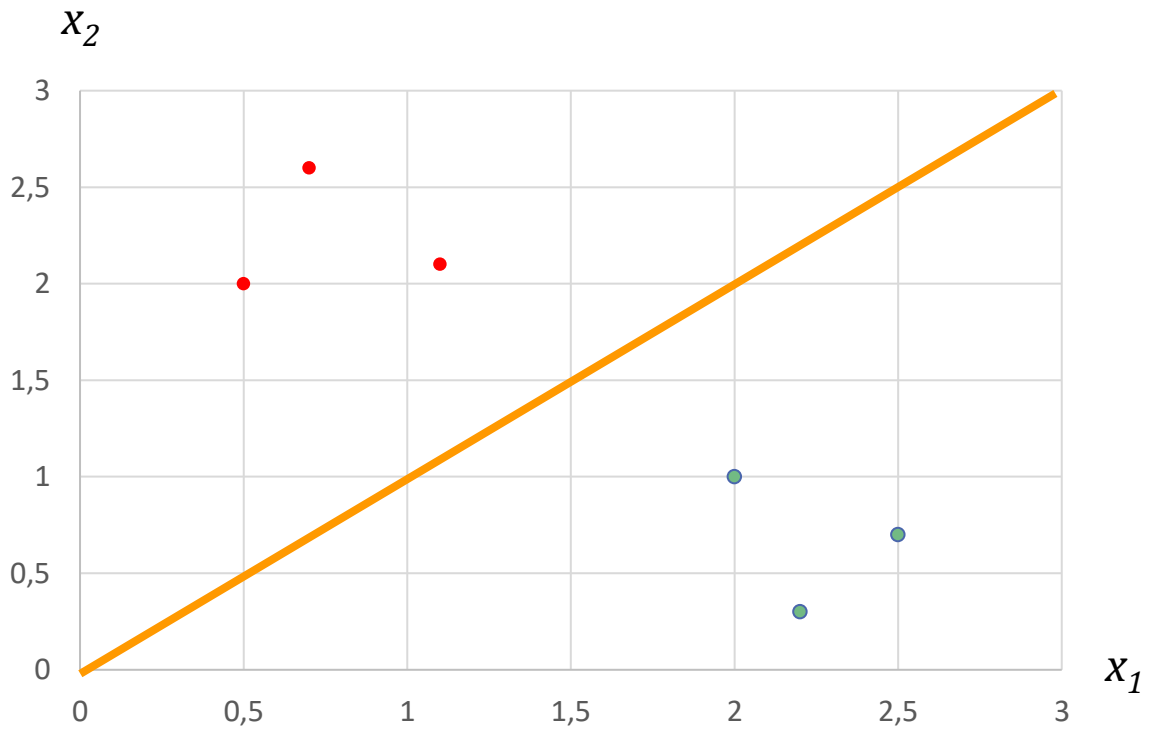
t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Classification binaire

- Vecteur de caractéristiques ≡ coordonnées
- Frontière de décision ≡ Droite

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3



Classification binaire

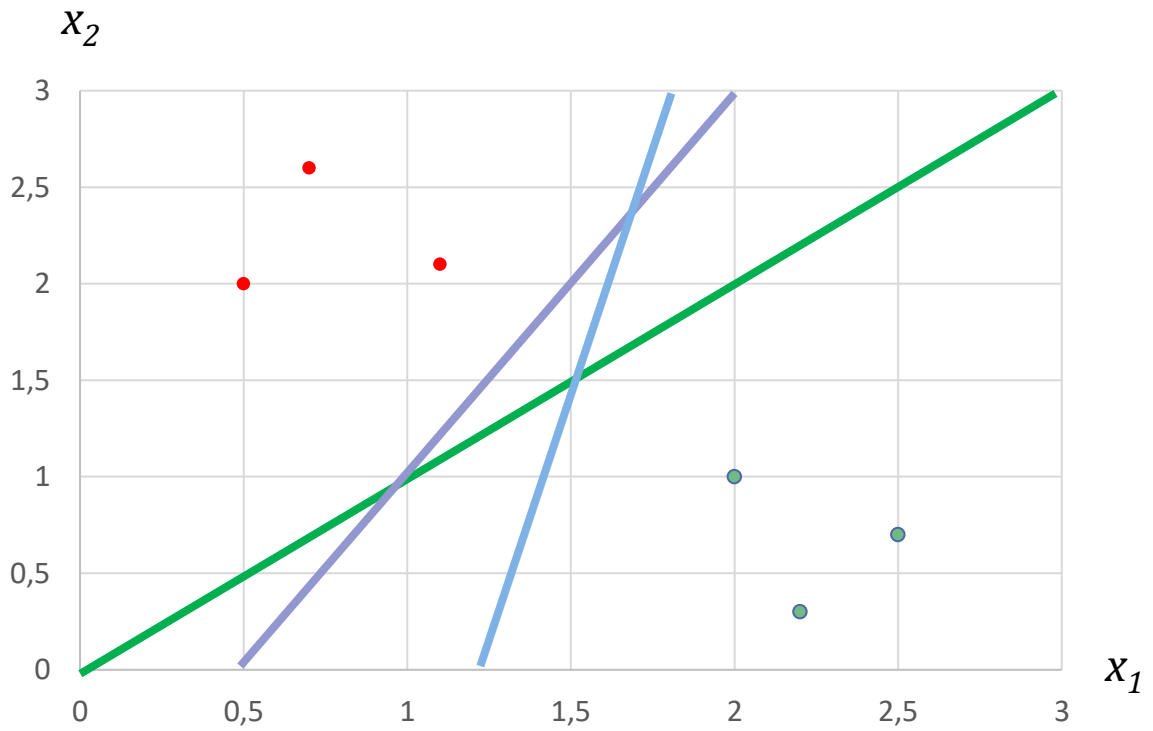
- Vecteur de caractéristiques ≡ coordonnées
- Frontière de décision ≡ Droite

y	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

Trouver une bonne frontière de décision

=

Trouver les w_i adéquats



Apprentissage

- Jeux de données $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m,$
  - $S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \ldots, x_i^{(k)}, \ldots, x_n^{(k)}\right)$
  - $X^{(k)} = \left(x_1^{(k)}, \ldots, x_i^{(k)}, \ldots, x_n^{(k)}\right)$
  - $\mathcal{X} = \{X^{(1)}, \ldots, X^{(m)}\}$

t	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

- Perceptron

$$z^{(k)} = \sum_{i=1}^{n} w_i x_i^{(k)} + b \qquad y^{(k)} = \varphi^{(k)} = \begin{cases} 1 \; si \; z^{(k)} \geq 0 \\ 0 \; si \; z^{(k)} < 0 \end{cases}$$

Apprentissage

- Algorithme

Initialisation des poids et de l'erreur

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

Apprentissage

- Algorithme

Tant qu'il y a une erreur

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$

fintq

Apprentissage

- Algorithme

Calcul de la prédiction

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
  finpour
fintq

Apprentissage

- Algorithme

Si la prédiction et la target value sont différentes

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
    finsi
  finpour
fintq

Apprentissage

- Algorithme

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
    finsi
  finpour
fintq

Les poids synaptiques impliqués sont modifiés

Apprentissage

- Algorithme

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
fintq

Calcul de la nouvelle prédiction

Apprentissage

- Algorithme

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Calcul de la nouvelle erreur

Apprentissage

- Algorithme
  - α : Taux d'apprentissage

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Apprentissage

- Algorithme de Rosenblatt
  - α : Taux d'apprentissage
  - $t^{(k)} - y^{(k)}$: Terme d'erreur

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(\boldsymbol{t^{(k)} - y^{(k)}}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Apprentissage

- Algorithme de Rosenblatt
  - α : Taux d'apprentissage
  - $t^{(k)} - y^{(k)}$: Terme d'erreur
  - Traitement de tous les éléments

Passage sur un jeu d'entrainement complet

$\forall w_i \in \mathcal{W},\ w_i \leftarrow 0$
$e \leftarrow 1$

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Théorème[Convergence de Novikoff]

Soit un perceptron dont $W = (w_1, \dots, w_n)$ est le vecteur de poids et soit $\mathcal{D}$ un jeu de données. L'algorithme de Rosenblatt converge sur $\mathcal{D}$ si et seulement si $\mathcal{D}$ est linéairement séparable.

Théorème[Convergence de Novikoff]

Soit un perceptron dont $W = (w_1, \dots, w_n)$ est le vecteur de poids et soit $\mathcal{D}$ un jeu de données. L'algorithme de Rosenblatt converge sur $\mathcal{D}$ si et seulement si $\mathcal{D}$ est linéairement séparable. Dans ce cas, le nombre maximal d'itérations pour atteindre la convergence est de:

$$\left(\frac{R}{\gamma}\right)^2$$

Avec:

- $R = max_{1 \leq k \leq m}\left(\left\|X^{(k)}\right\|\right)$
- $\gamma = min_{1 \leq k \leq m}\left(y'^{(k)} \sum_{i=1}^{n} \frac{w_i^*}{\|W^*\|} x_i^{(k)}\right)$ avec $y'^{(k)} = \begin{cases} 1 \; si \; y^{(k)} = 1 \\ -1 \; si \; y^{(k)} = 0 \end{cases}$

Définition[Paramètre]

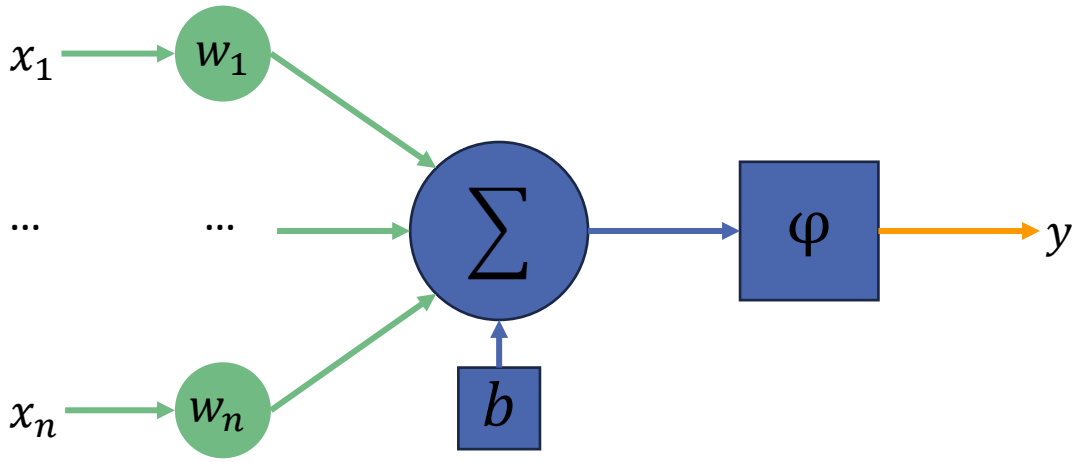
Pour un réseau de neurones, les **paramètres** sont l'ensemble des valeurs permettant de calculer une prédiction à partir d'une entrée donnée.

Définition[Paramètre]

Pour un réseau de neurones, les **paramètres** sont l'ensemble des valeurs permettant de calculer une prédiction à partir d'une entrée donnée.

Exemple

- Perceptron à n entrée

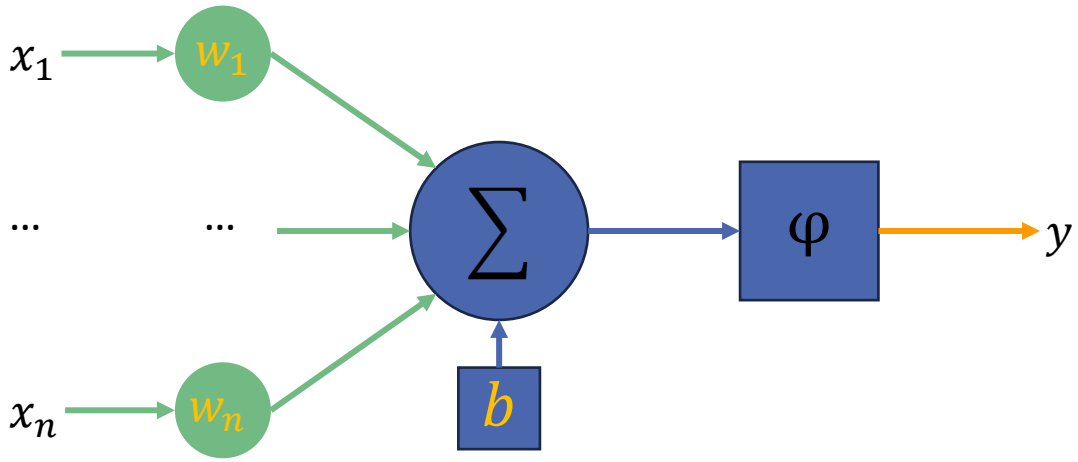


Définition[Paramètre]

Pour un réseau de neurones, les **paramètres** sont l'ensemble des valeurs permettant de calculer une prédiction à partir d'une entrée donnée.

Exemple

- Perceptron à n entrée
- Paramètres: $\{w_i \mid 1 \leq i \leq n\} \cup \{b\}$



Définition[Apprentissage]

Pour un réseau de neurones, l'**apprentissage** (ou **entrainement**) est la détermination de ses paramètres à partir d'un jeu de données.

Définition[Apprentissage]

Pour un réseau de neurones, l'**apprentissage** (ou **entrainement**) est la détermination de ses paramètres à partir d'un jeu de données.

Exemple

- Perceptron à n entrée

Définition[Apprentissage]

Pour un réseau de neurones, l'**apprentissage** (ou **entrainement**) est la détermination de ses paramètres à partir d'un jeu de données.

Exemple

- Perceptron à n entrée
- Apprentissage = algorithme de Rosenblatt

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Définition[Apprentissage]

Pour un réseau de neurones, l'**apprentissage** (ou **entrainement**) est la détermination de ses paramètres à partir d'un jeu de données.

Exemple

- Perceptron à n entrée
- Apprentissage = algorithme de Rosenblatt
  - Détermination des paramètres

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Définition[Apprentissage]

Pour un réseau de neurones, l'**apprentissage** (ou **entrainement**) est la détermination de ses paramètres à partir d'un jeu de données.

Exemple

- Perceptron à n entrée
- Apprentissage = algorithme de Rosenblatt
  - Détermination des paramètres
  - Utilisation du jeu de données

tantque $e > 0$
  pour chaque $X^{(k)}$ **faire**
    $y^{(k)} \leftarrow \varphi^{(k)}$
    si $t^{(k)} \neq y^{(k)}$ **alors**
      pour chaque w_i **faire**
        $w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
      finpour
      $y^{(k)} \leftarrow \varphi^{(k)}$
    finsi
  finpour
  $e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$
fintq

Définition[Epoque/Epoch]

Soit $\mathcal{D}$ un jeu de données dont $\mathcal{X} = \{X^{(1)}, \dots, X^{(k)}, \dots, X^{(m)}\}$ est l'ensemble des vecteurs de caractéristiques. Pour un algorithme d'apprentissage, une époque (epoch) est la phase traitement de l'ensemble des éléments de $\mathcal{X}$.

Définition[Epoque/Epoch]

Soit $\mathcal{D}$ un jeu de données dont $\mathcal{X} = \{X^{(1)}, \ldots, X^{(k)}, \ldots, X^{(m)}\}$ est l'ensemble des vecteurs de caractéristiques. Pour un algorithme d'apprentissage, une époque (epoch) est la phase traitement de l'ensemble des éléments de $\mathcal{X}$.

Exemple[Epoque/Epoch]

- Dans l'algorithme de Rosenblatt

pour chaque $X^{(k)}$ **faire**
  $y^{(k)} \leftarrow \varphi(z^{(k)})$
  si $t^{(k)} \neq y^{(k)}$ **alors**
    pour chaque w_i **faire**
      $w_i \leftarrow w_i + \alpha(t^{(k)} - y^{(k)})x_i$
    finpour
    $y^{(k)} \leftarrow \varphi(z^{(k)})$
  finsi
finpour

Définition[Hyperparamètre]

Un **hyperparamètre** est une valeur qui est utilisé pour configurer un réseau de neurones. Contrairement aux paramètres, qui résultent de l'apprentissage, les **hyperparamètres** contrôlent celui-ci et doivent être définis en amont.

Définition[Hyperparamètre]

Un **hyperparamètre** est une valeur qui est utilisé pour configurer un réseau de neurones. Contrairement aux paramètres, qui résultent de l'apprentissage, les **hyperparamètres** contrôlent celui-ci et doivent être définis en amont.

Exemple

- Taux d'apprentissage

pour chaque $X^{(k)}$ **faire**
$y^{(k)} \leftarrow \varphi\left(z^{(k)}\right)$
si $t^{(k)} \neq y^{(k)}$ **alors**
pour chaque w_i **faire**
$w_i \leftarrow w_i + \alpha\left(t^{(k)} - y^{(k)}\right)x_i$
finpour
$y^{(k)} \leftarrow \varphi\left(z^{(k)}\right)$
finsi
finpour
$e \leftarrow \sum\left|t^{(k)} - y^{(k)}\right|$

Définition[Hyperparamètre]

Un **hyperparamètre** est une valeur qui est utilisé pour configurer un réseau de neurones. Contrairement aux paramètres, qui résultent de l'apprentissage, les **hyperparamètres** contrôlent celui-ci et doivent être définis en amont.

Exemple

- Taux d'apprentissage
- Les valeurs définissant la structure du réseau de neurone (nombre de neurones, nombre de couches, …) sont aussi des hyperparamètres

Définition[Modèle]

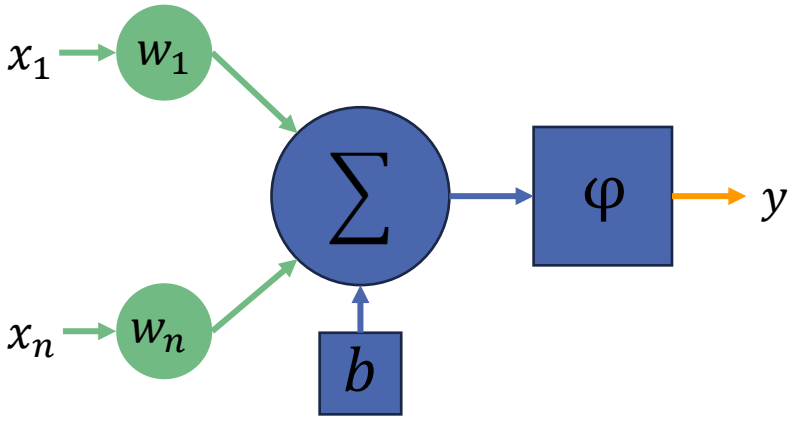
En intelligence artificielle connexionniste, on appelle **modèle** un réseau de neurone dont les paramètres sont complètement déterminés (via un apprentissage).

Définition[Modèle]

En intelligence artificielle connexionniste, on appelle **modèle** un réseau de neurone dont les paramètres sont complètement déterminés (via un apprentissage).

Exemple

Modèle = Structure

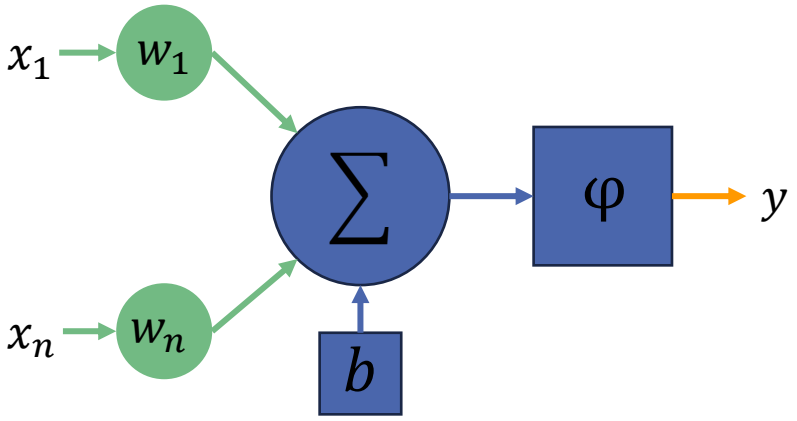


Définition[Modèle]

En intelligence artificielle connexionniste, on appelle **modèle** un réseau de neurone dont les paramètres sont complètement déterminés (via un apprentissage).

Exemple

Modèle = Structure + Fonctions



$$z = \sum_{i=1}^{n} x_i w_i + b$$

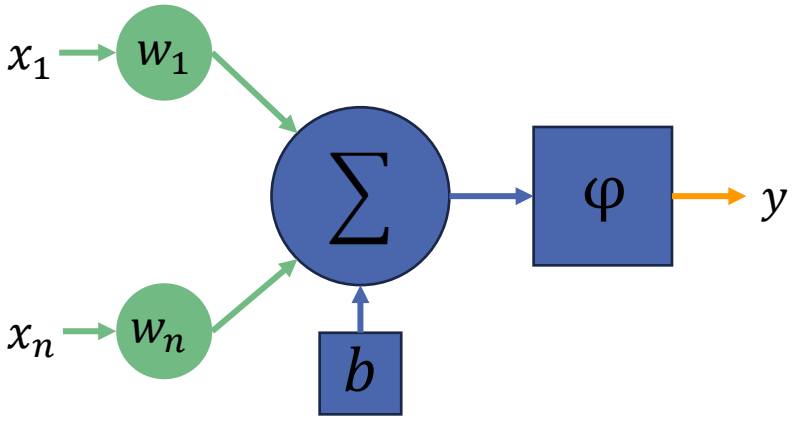
$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

Définition[Modèle]

En intelligence artificielle connexionniste, on appelle **modèle** un réseau de neurone dont les paramètres sont complètement déterminés (via un apprentissage).

Exemple

Modèle = Structure + Fonctions + paramètres



$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

w_1	w_2	b
-0,5	1,5	-1,5

Perceptron

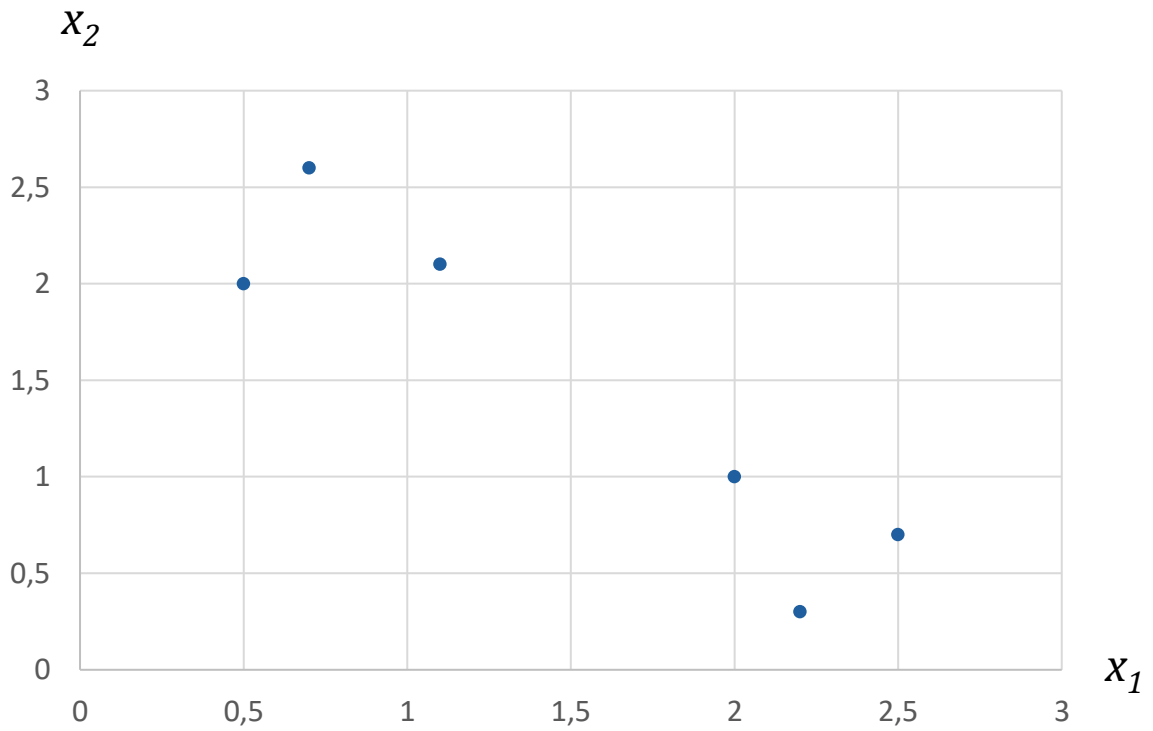
- Permet de résoudre des problèmes de classification binaire linéaire
- Possède un algorithme d'apprentissage

Comment l'améliorer ?

Classification binaire

- Utilisation d'un perceptron pour séparer des classes

$$z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

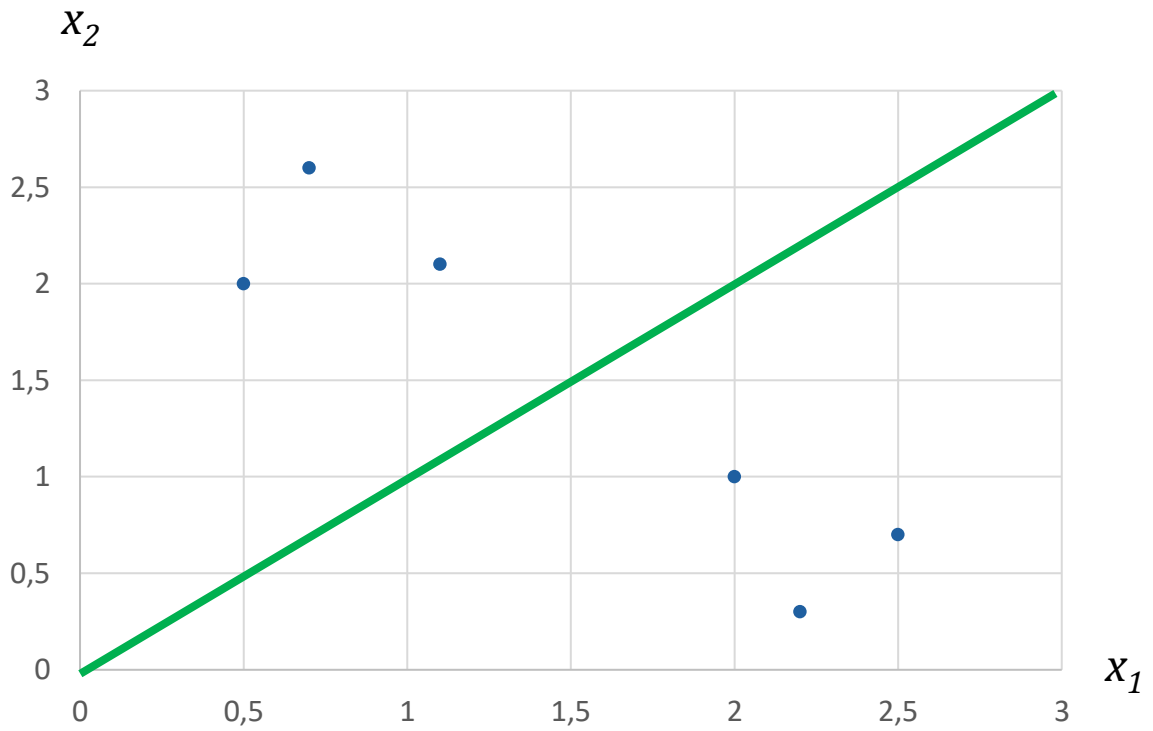


Classification binaire

- Utilisation d'un perceptron pour séparer des classes

$$z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

- Calcul de la frontière de décision par apprentissage



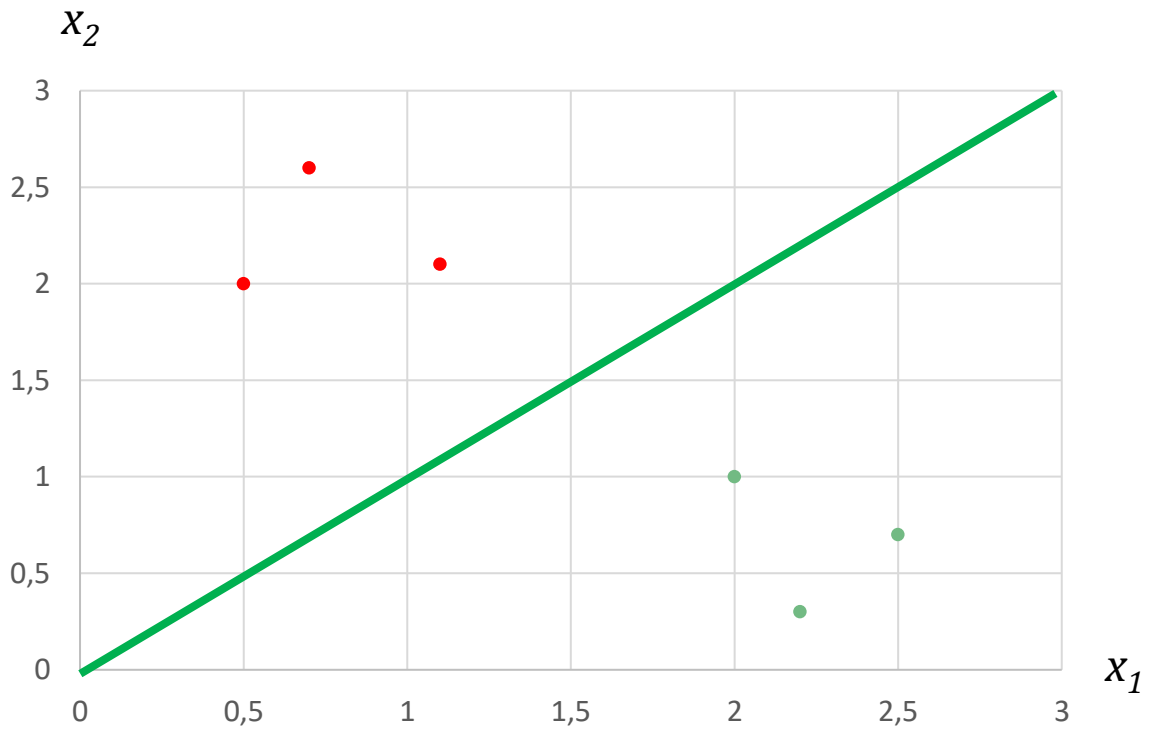
Classification binaire

- Utilisation d'un perceptron pour séparer des classes

$$z = \sum_{i=1}^{n} x_i w_i + b \qquad y = \varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

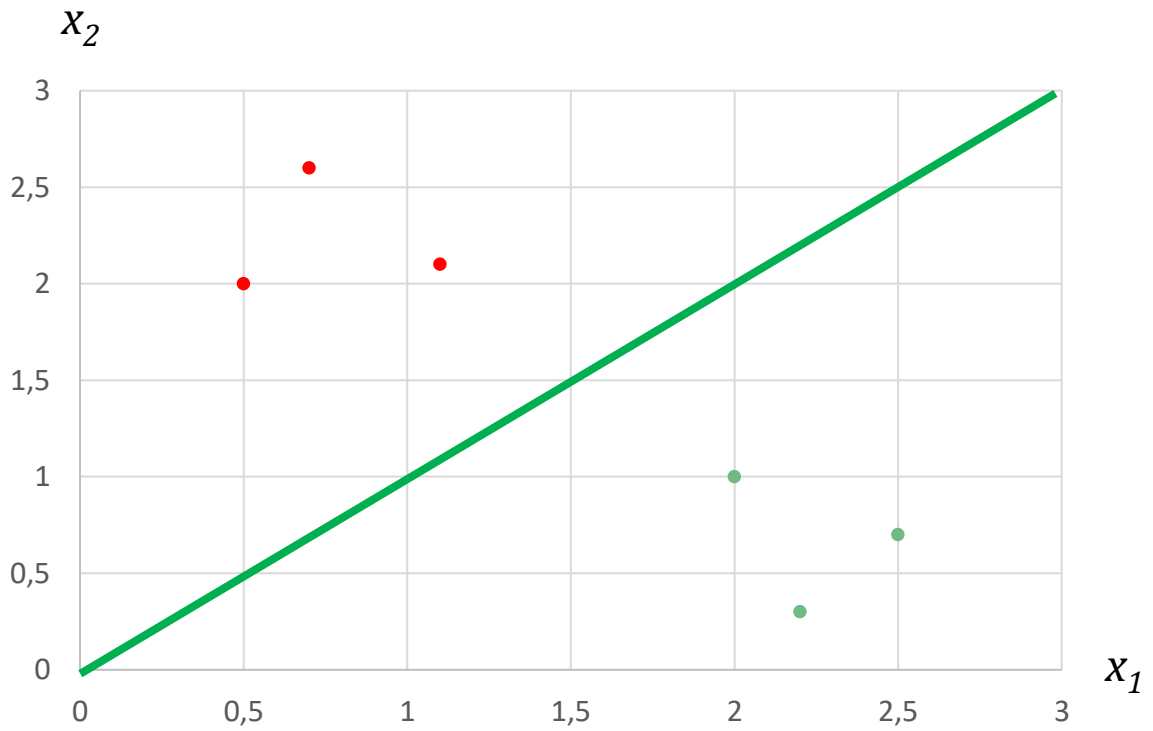
- Calcul de la frontière de décision par apprentissage

- Détermination de la classe par la position par rapport à la frontière de décision



Classification binaire

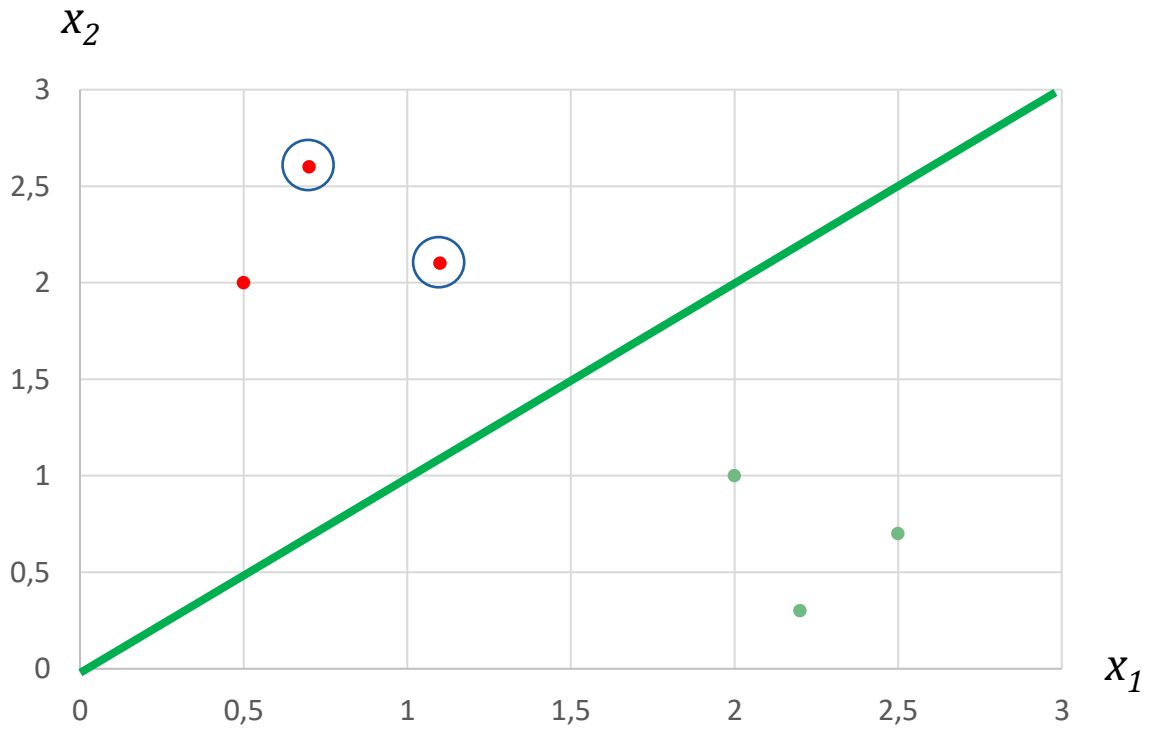
- Pas d'indication ou de quantification de confiance



Classification binaire

- Pas d'indication ou de quantification de confiance

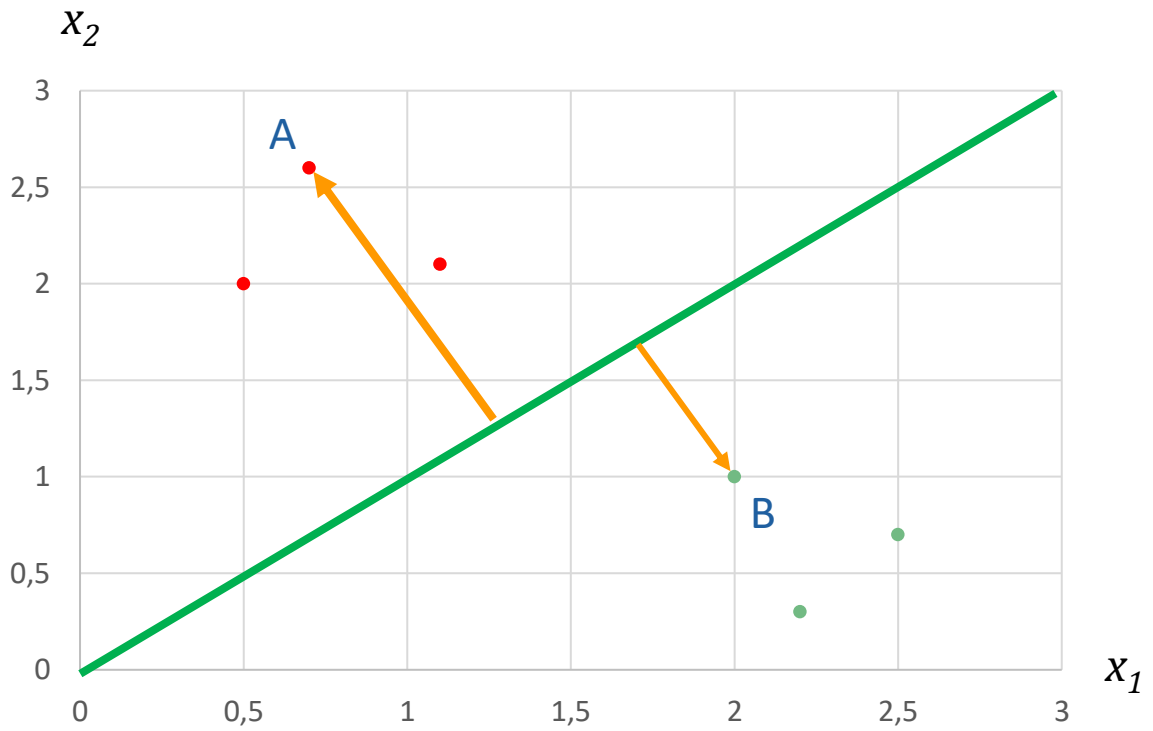
Le classement de ces 2 points a-t-il un même niveau de confiance ?



Classification binaire

- Pas d'indication ou de quantification de confiance
- **Intuition:** Plus un point est proche de la frontière de décision moins le classement est sûr

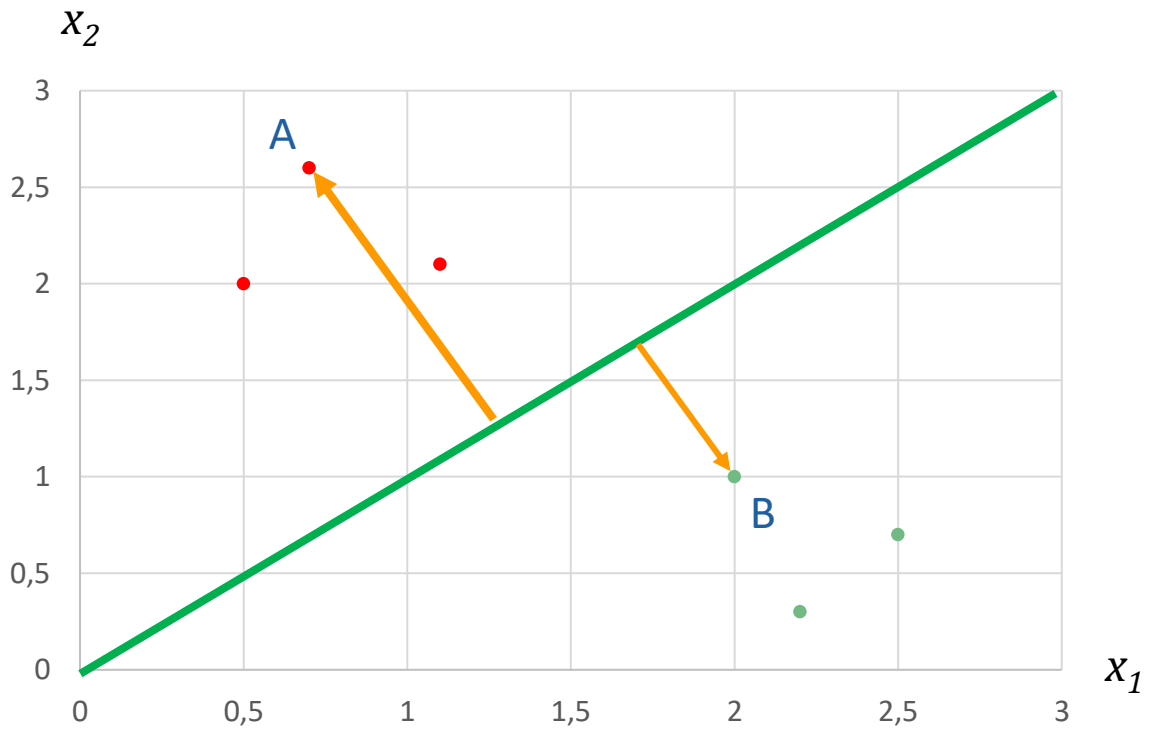
Il est plus vraisemblable que A soit de la classe voulue par rapport à B



Classification binaire

- Pas d'indication ou de quantification de confiance
- **Intuition:** Plus un point est loin de la frontière de décision plus le classement est sûr

Il est plus vraisemblable que A soit de la classe voulue par rapport à B

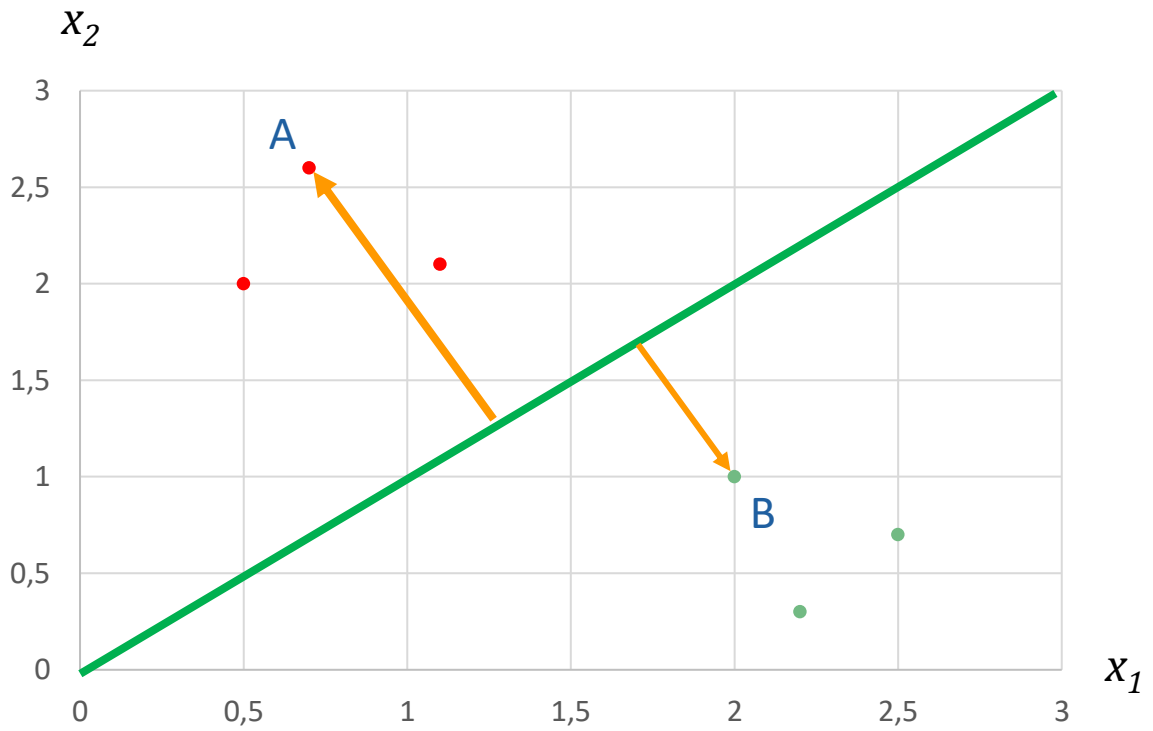


Classification binaire

- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



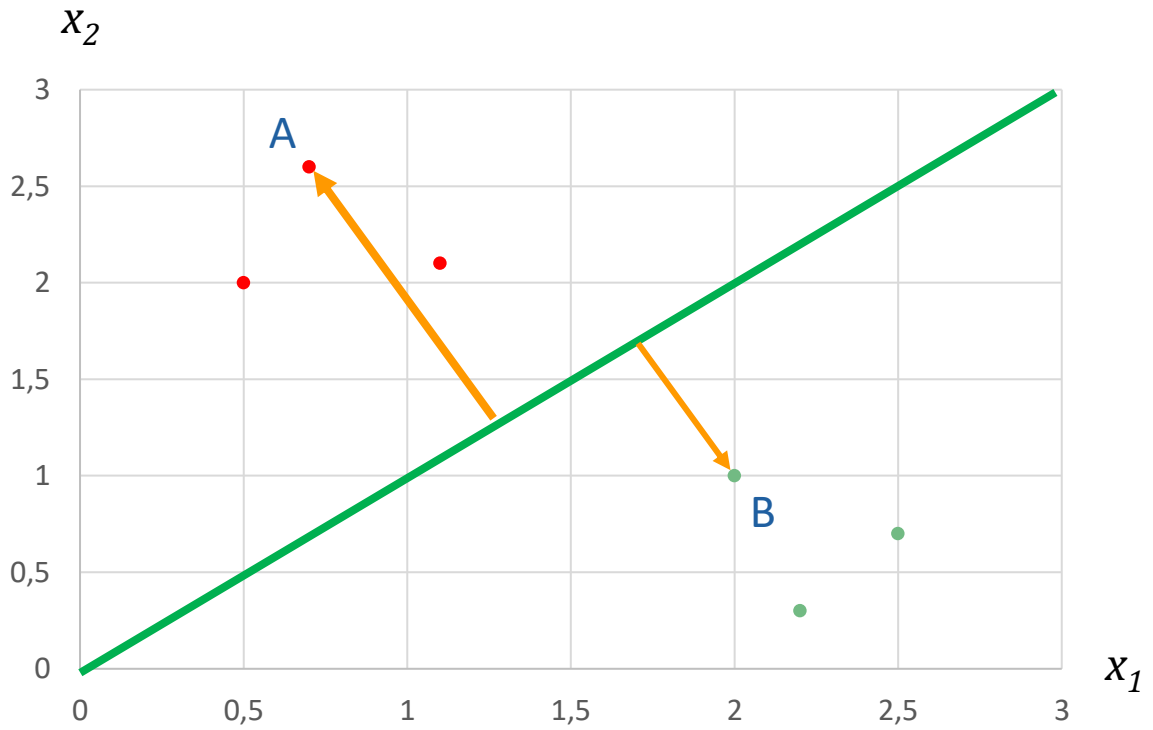
Classification binaire

- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite:

$$\frac{\sum_{i=1}^{n} x_i w_i + b}{\sqrt{\sum_{1}^{n} w_i}}$$

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



Classification binaire

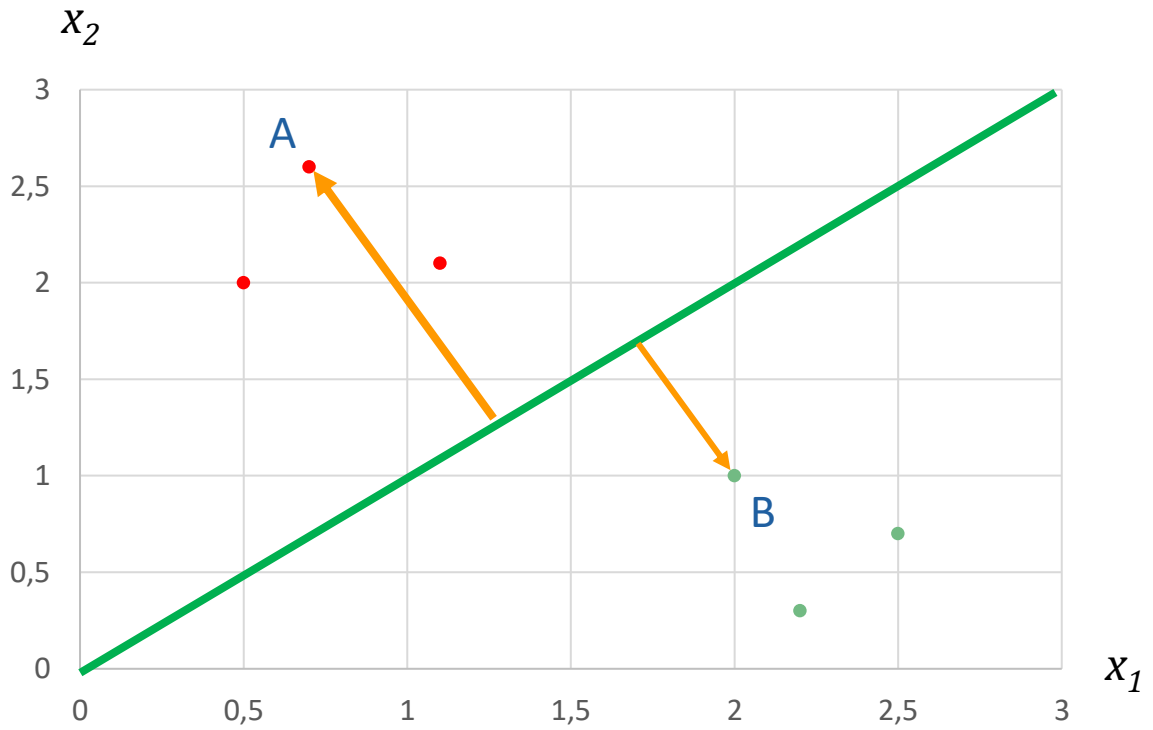
- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite:

$$\frac{\sum_{i=1}^{n} x_i w_i + b}{\sqrt{\sum_{1}^{n} w_i}} = \frac{z}{\sqrt{\sum_{1}^{n} w_i}}$$

Définition de z

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



Classification binaire

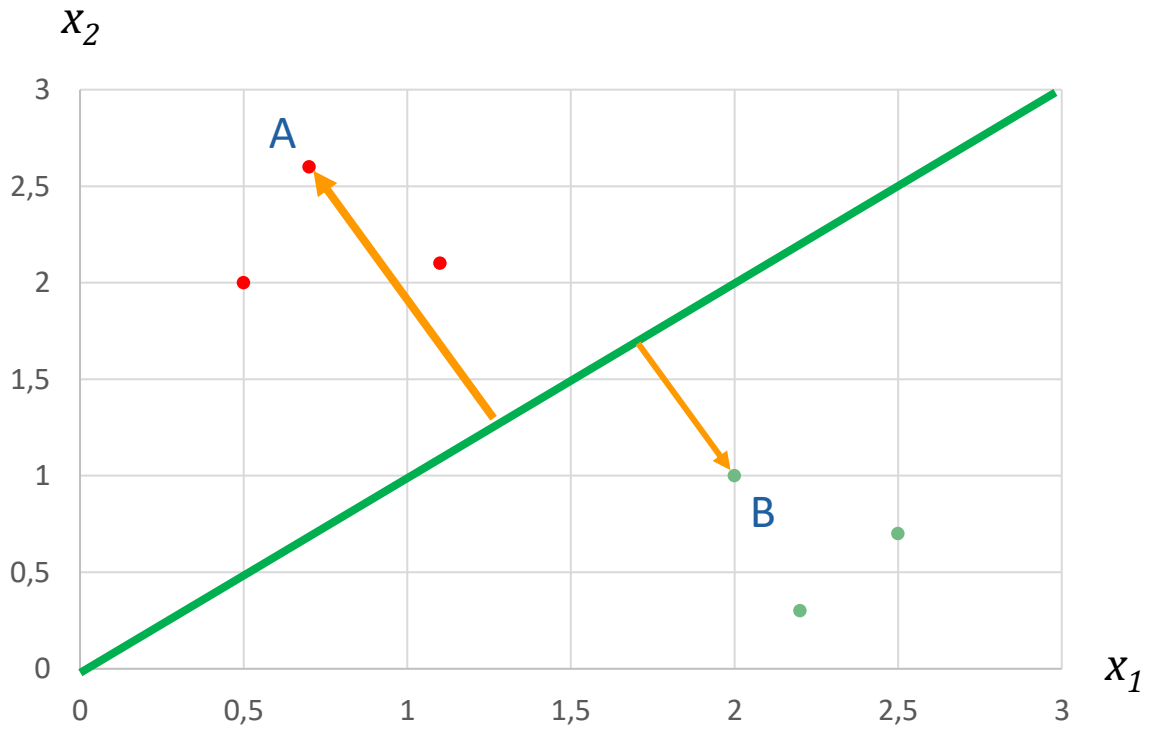
- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite:

$$\frac{\sum_{i=1}^{n} x_i w_i + b}{\sqrt{\sum_1^n w_i}} = \frac{z}{\sqrt{\sum_1^n w_i}} = \lambda z$$

$$\lambda = \frac{1}{\sqrt{\sum_1^n w_i}}$$

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



Classification binaire

- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

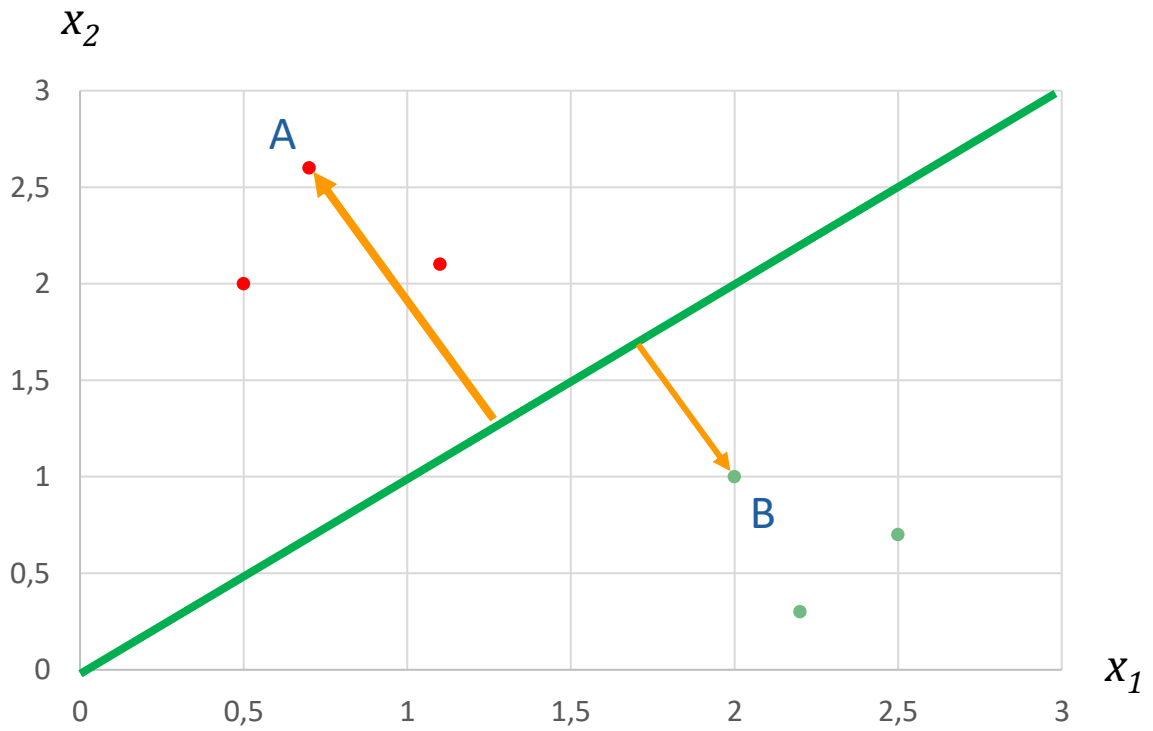
- Ecart d'un point à la droite:

$$\frac{\sum_{i=1}^{n} x_i w_i + b}{\sqrt{\sum_1^n w_i}} = \frac{z}{\sqrt{\sum_1^n w_i}} = \lambda z \equiv z$$

$$\lambda = \frac{1}{\sqrt{\sum_1^n w_i}}$$

Constant et strictement positif

$$\lambda z^{(i)} < \lambda z^{(k)} \leftrightarrow z^{(i)} < z^{(k)}$$

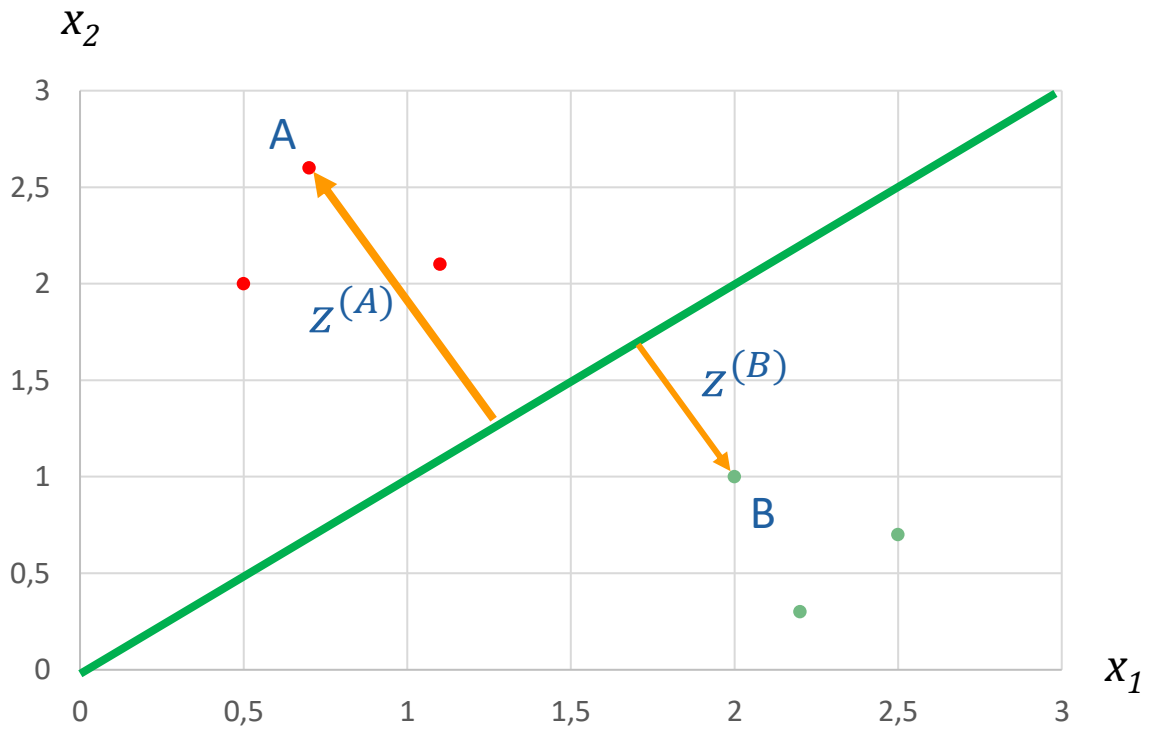


Classification binaire

- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite: z

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

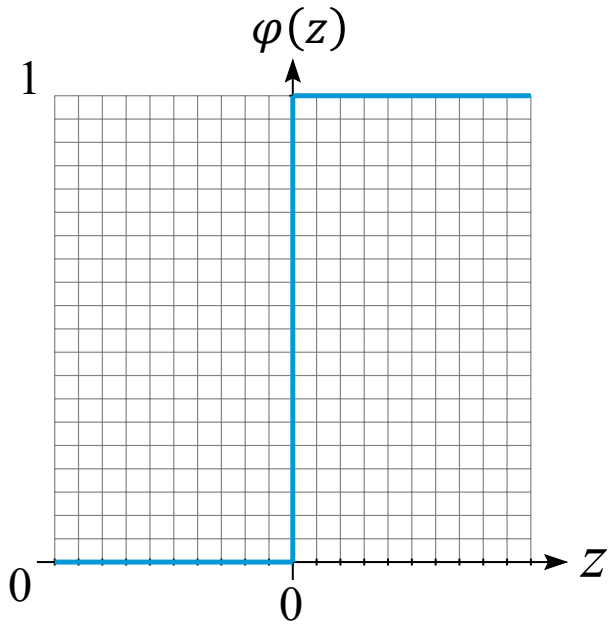


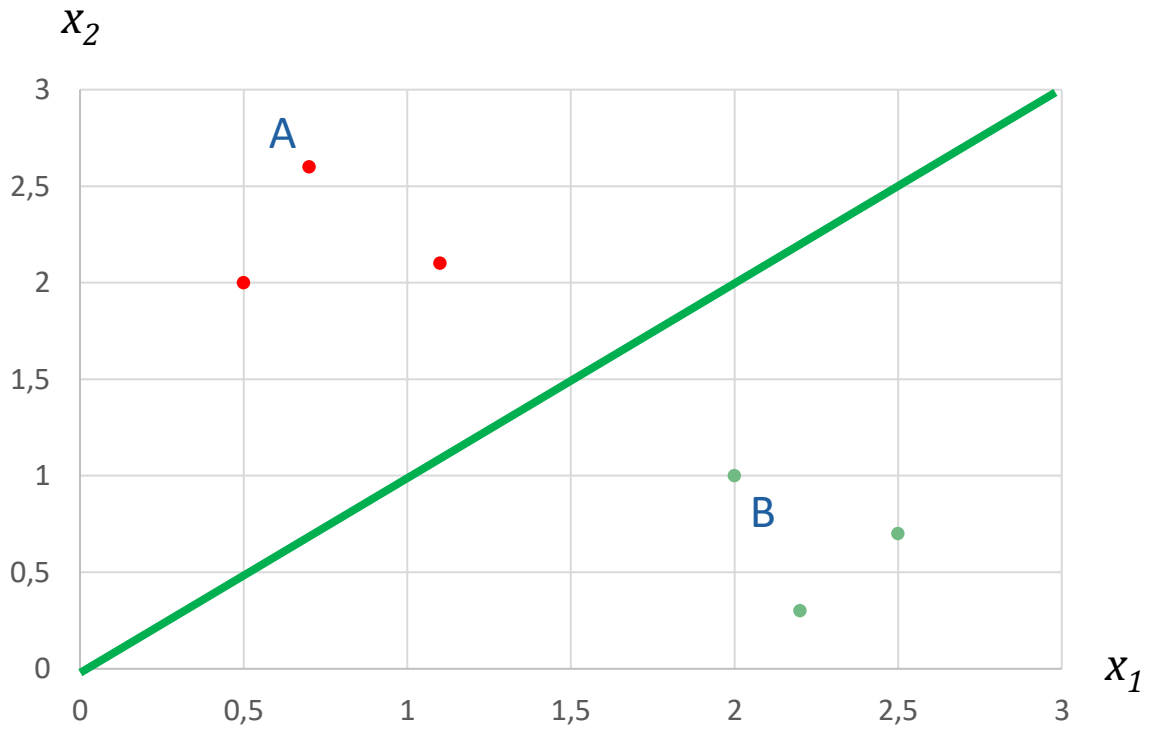
Classification binaire

- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite: z
- Fonction d'activation

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



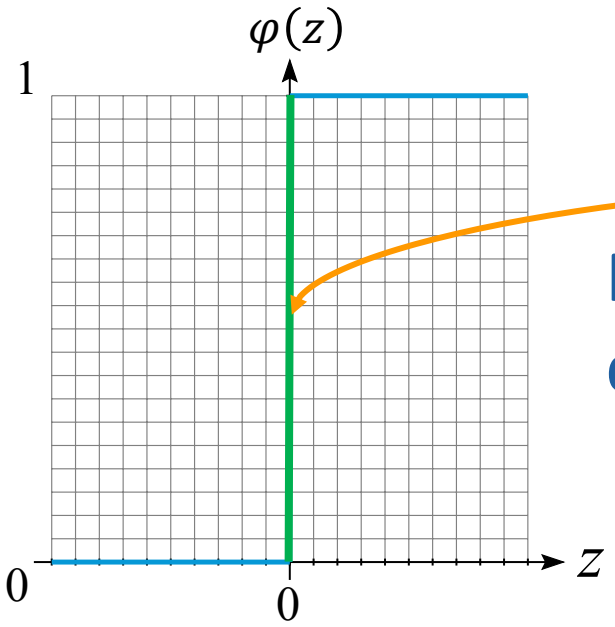


Classification binaire

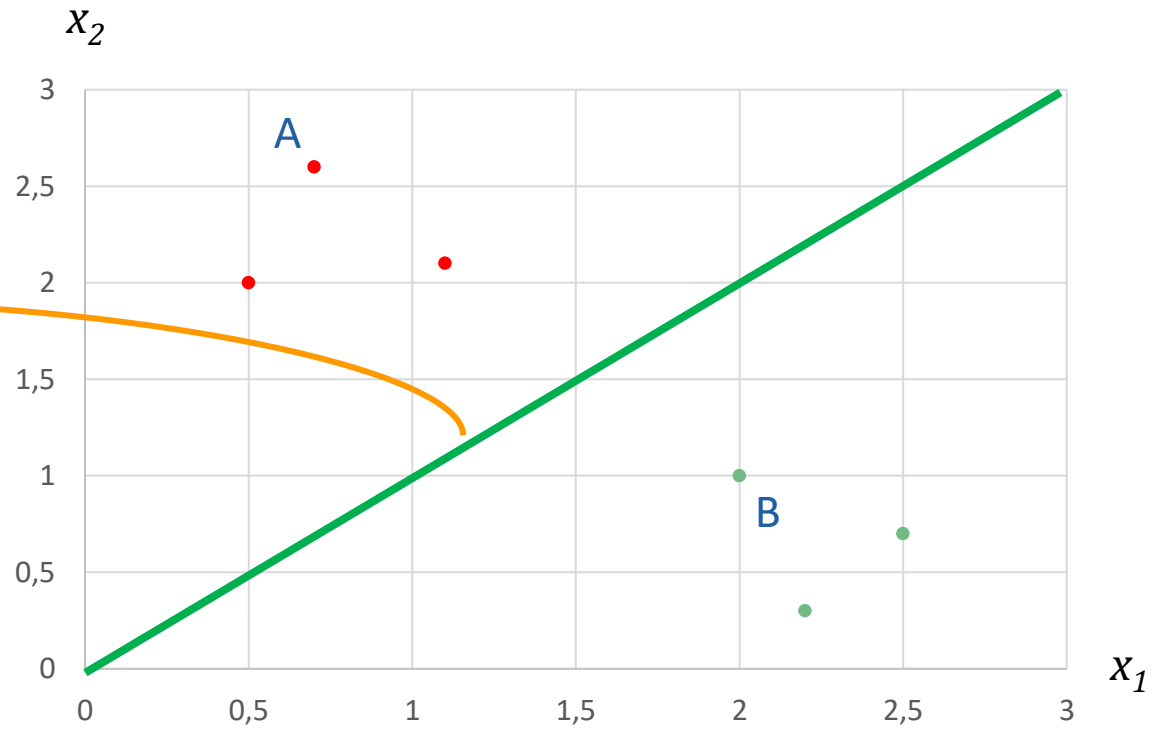
- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite: z
- Fonction d'activation

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



Frontière de décision $\varphi(z) = 0$

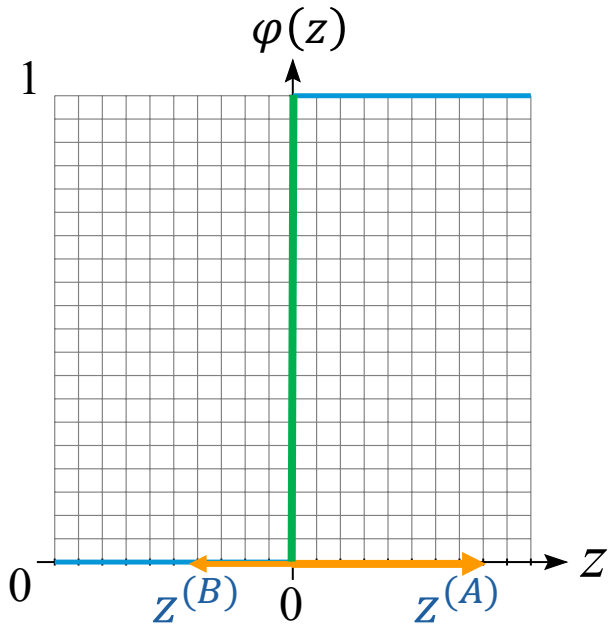


Classification binaire

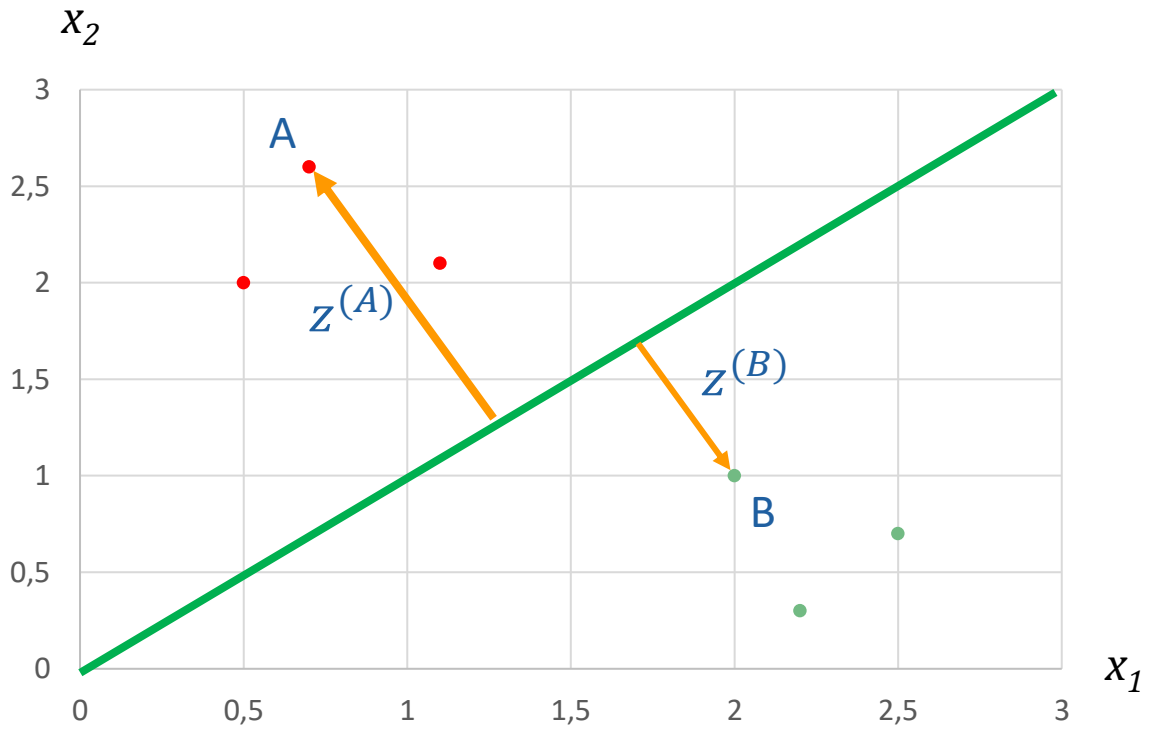
- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite: z
- Fonction d'activation

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



Les z sont conservés

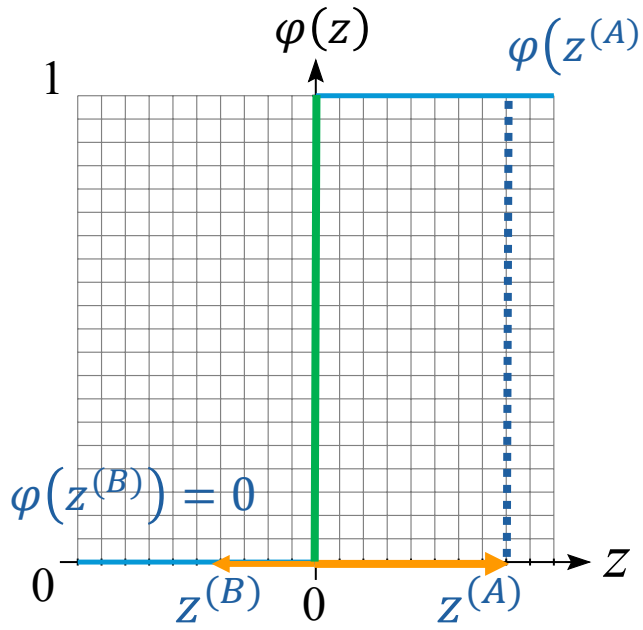


Classification binaire

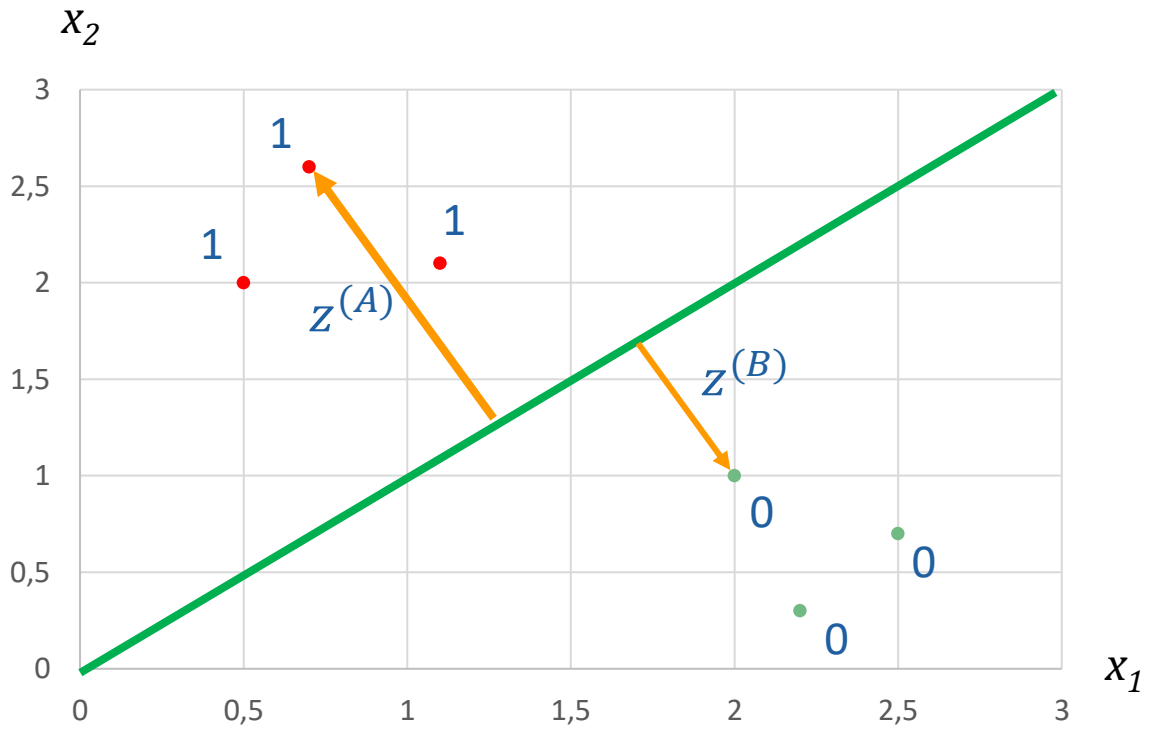
- Frontière de décision: $\sum_{i=1}^{n} x_i w_i + b = 0$
- Ecart d'un point à la droite: z
- Fonction d'activation

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$

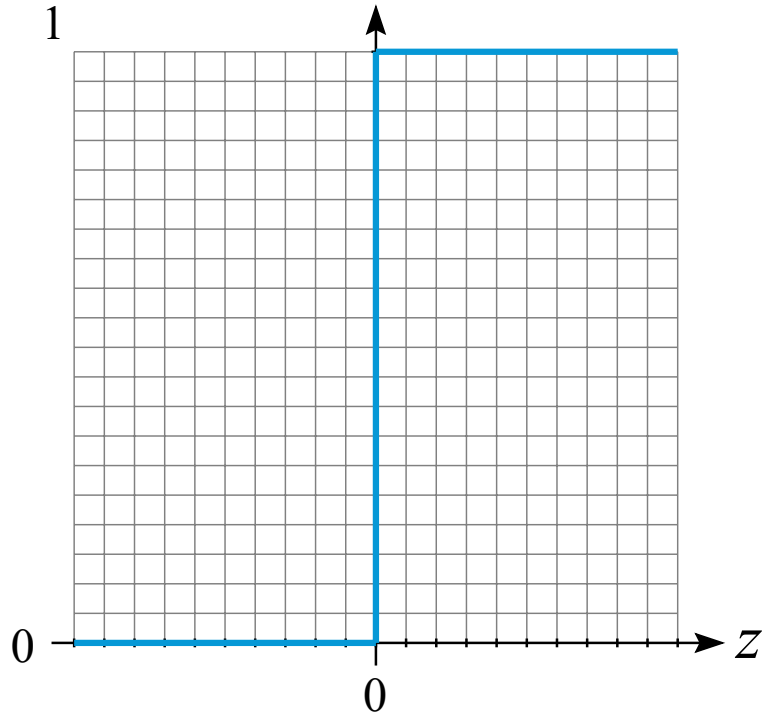


La fonction φ écrase les écarts en 0 ou 1



Classification binaire

- **Idée:** Changement de la définition de φ en conservant des propriétés
  - Continuité sur $\mathbb{R}$
  - Strictement Croissante sur $\mathbb{R}$
  - Ensemble image est $[0; 1]$



Définition[Fonctions logistiques]

Les **fonctions logistiques** sont les fonctions de la forme:

$$f(x) = \frac{K}{1 + \alpha e^{-rx}}$$

avec $\alpha \in \mathbb{R}$ et $K, r \in \mathbb{R}^+$

Définition[Fonctions logistiques]

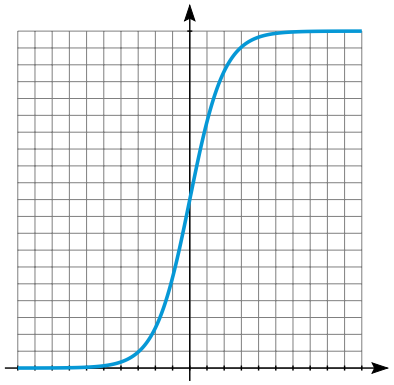
Les **fonctions logistiques** sont les fonctions de la forme:

$$f(x) = \frac{K}{1 + \alpha e^{-rx}}$$

avec $\alpha \in \mathbb{R}$ et $K, r \in \mathbb{R}^+$

Définition[Fonctions sigmoïdes]

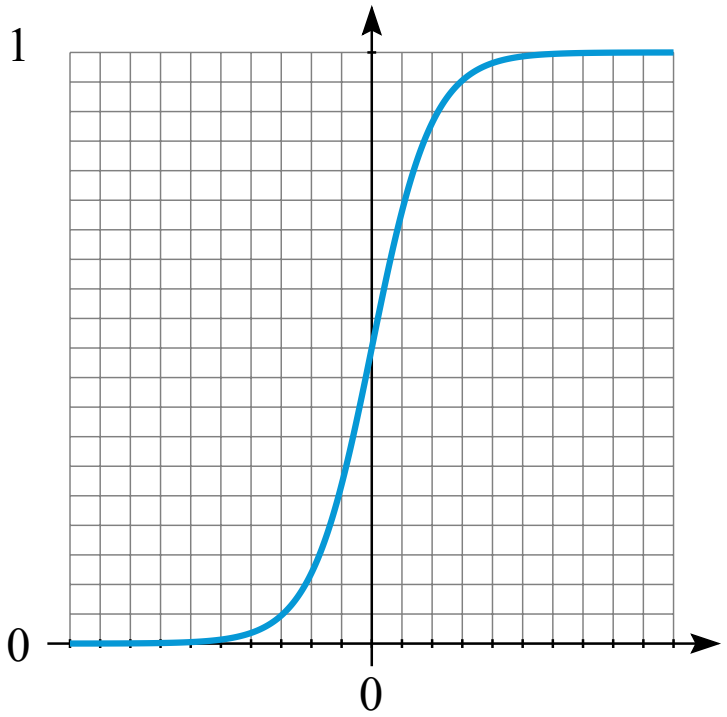
Les **fonctions sigmoïdes** sont des fonctions logistiques avec $\alpha > 0$.



Forme de S

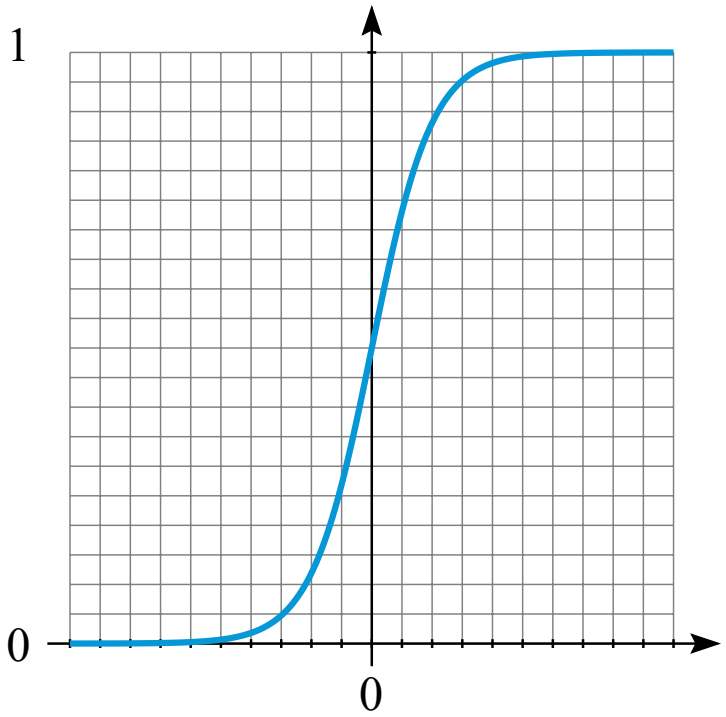
Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1+e^{-x}}$ $(\alpha = K = r = 1)$



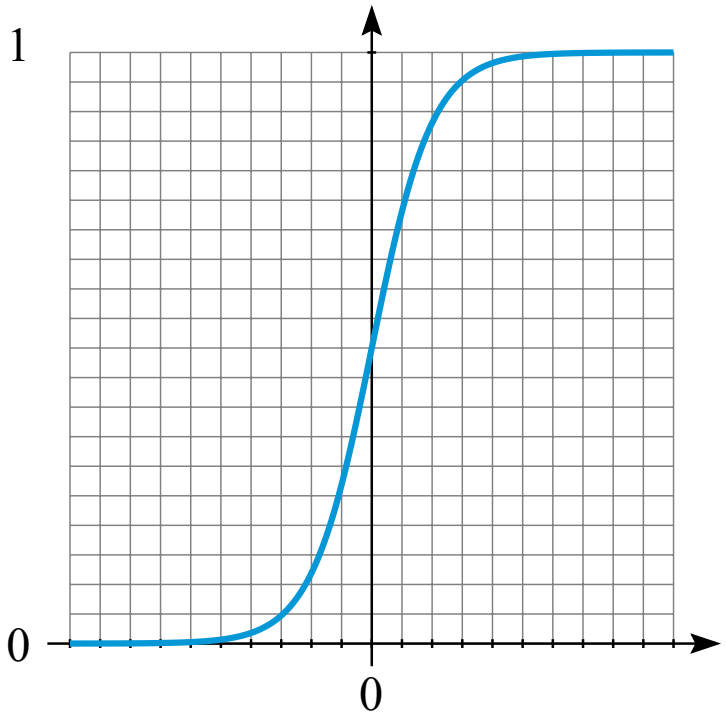
Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$



Fonction logistique (Sigmoïde)

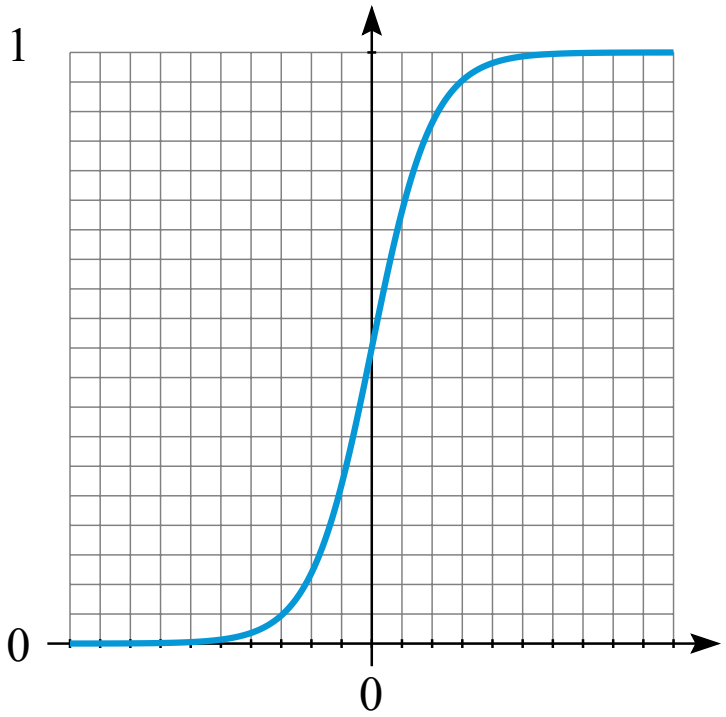
- Définition: $f(x) = \dfrac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissance



Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissance

  $\forall x, y \in \mathbb{R}, x < y \rightarrow -x > -y$



Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissance

$\forall x, y \in \mathbb{R}, x < y \rightarrow -x > -y \rightarrow e^{-x} > e^{-y}$

e est strictement croissante sur $\mathbb{R}$

Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissance

$$\forall x, y \in \mathbb{R}, x < y \rightarrow -x > -y \rightarrow e^{-x} > e^{-y} \rightarrow 1 + e^{-x} > 1 + e^{-y}$$

Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissance

$$\forall x, y \in \mathbb{R}, x < y \rightarrow -x > -y \rightarrow e^{-x} > e^{-y} \rightarrow 1 + e^{-x} > 1 + e^{-y}$$

$$\rightarrow \frac{1}{1 + e^{-x}} < \frac{1}{1 + e^{-y}}$$

$\frac{1}{x}$ est strictement décroissante sur $\mathbb{R}^*$

Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissance

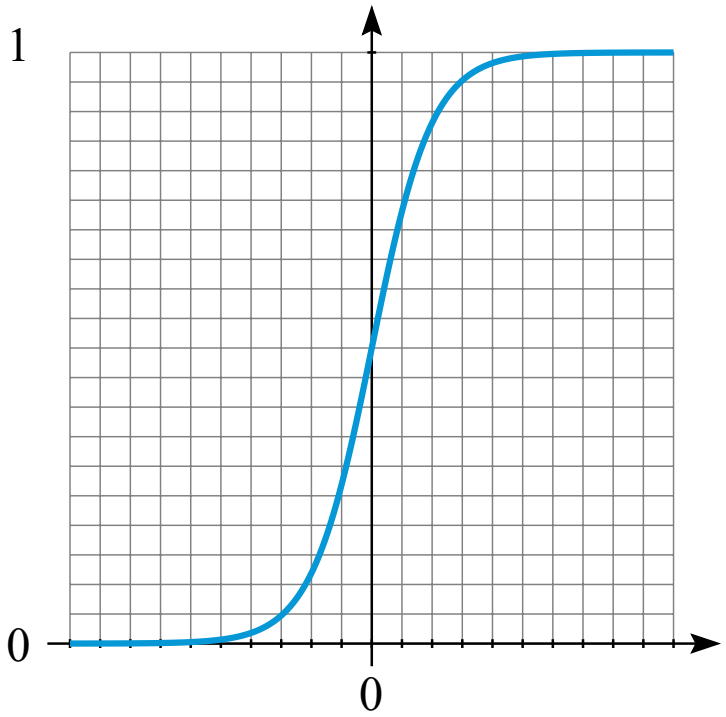
$$\forall x, y \in \mathbb{R}, x < y \rightarrow -x > -y \rightarrow e^{-x} > e^{-y} \rightarrow 1 + e^{-x} > 1 + e^{-y}$$

$$\rightarrow \frac{1}{1 + e^{-x}} < \frac{1}{1 + e^{-y}} \equiv f(x) < f(y)$$

Fonction logistique (Sigmoïde)

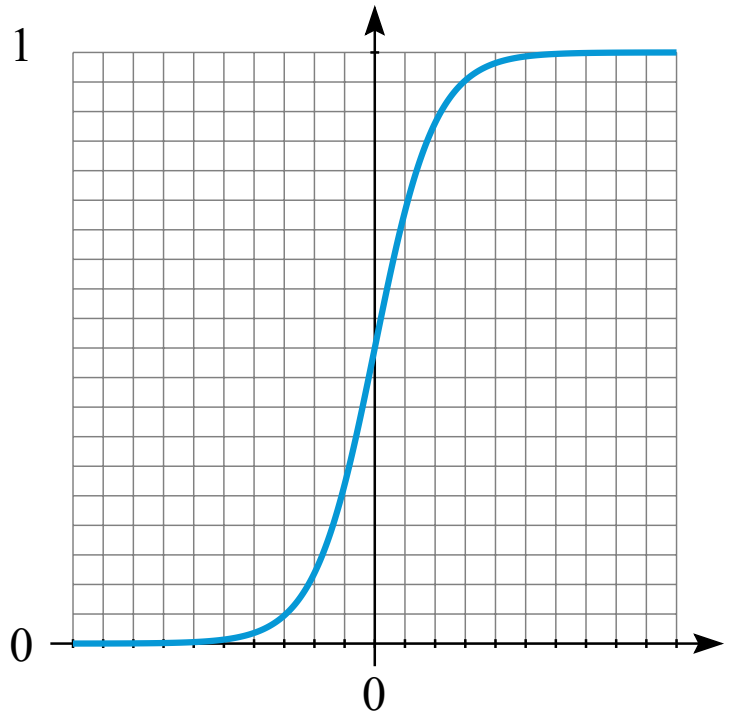
- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement

$\forall x, y \in \mathbb{R}, x < y \rightarrow f(x) < f(y)$



Fonction logistique (Sigmoïde)

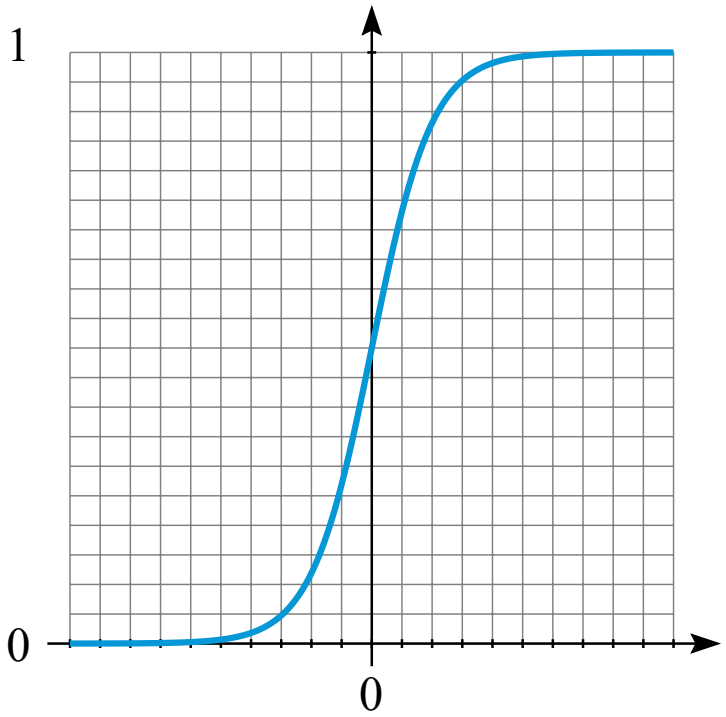
- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement
- Ensemble image



Fonction logistique (Sigmoïde)

- Définition: $f(x) = \dfrac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement
- Ensemble image

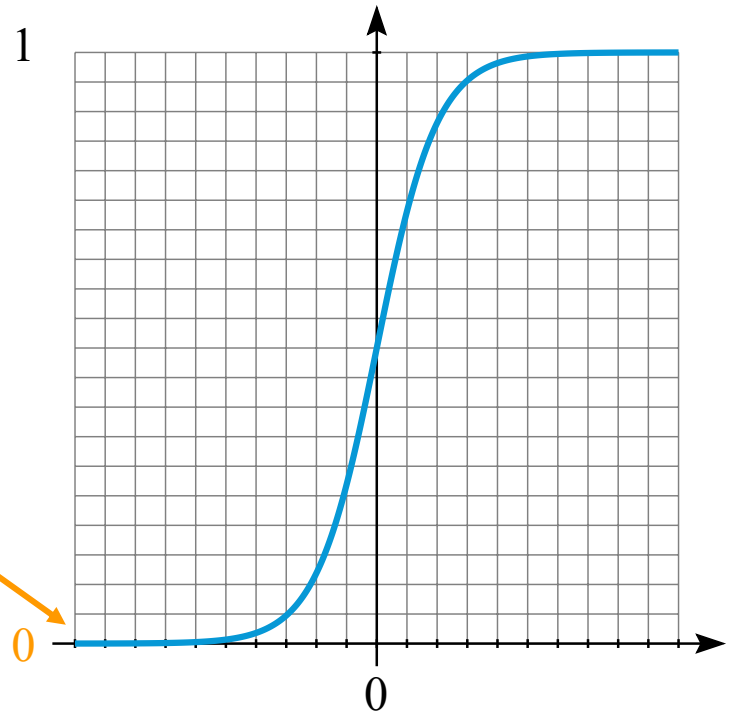
$$\lim_{x \to -\infty} e^{-x} = +\infty$$



Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement
- Ensemble image

$$\lim_{x \to -\infty} e^{-x} = +\infty \rightarrow \lim_{x \to -\infty} \frac{1}{1 + e^{-x}} = 0$$

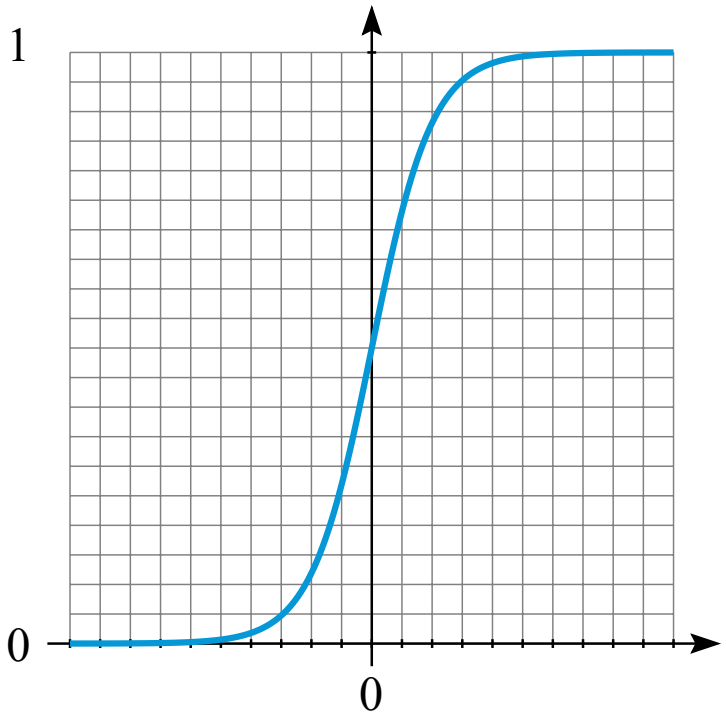


Fonction logistique (Sigmoïde)

- Définition: $f(x) = \dfrac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement
- Ensemble image

$$\lim_{x \to -\infty} e^{-x} = +\infty \rightarrow \lim_{x \to -\infty} \frac{1}{1 + e^{-x}} = 0$$

$$\lim_{x \to +\infty} e^{-x} = 0$$

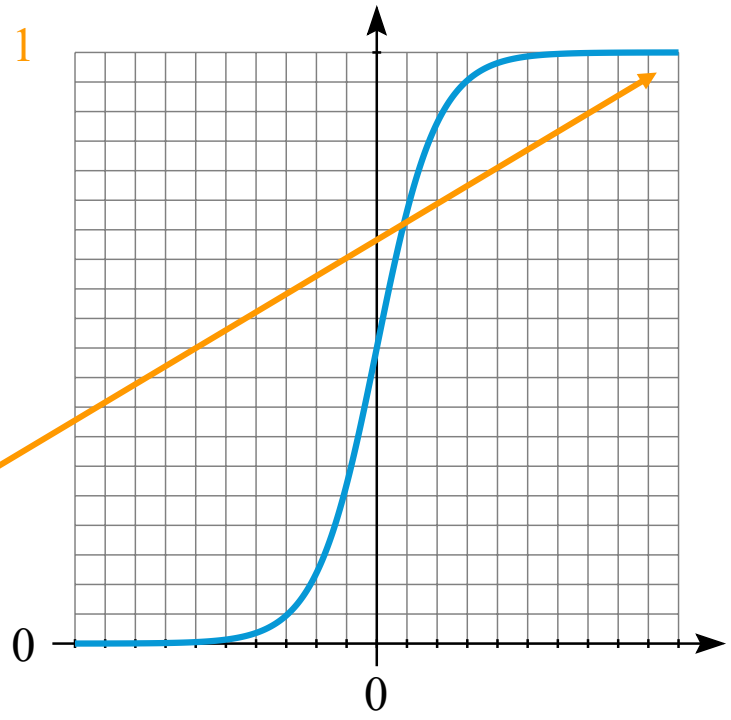


Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement
- Ensemble image

$$\lim_{x \to -\infty} e^{-x} = +\infty \rightarrow \lim_{x \to -\infty} \frac{1}{1 + e^{-x}} = 0$$

$$\lim_{x \to +\infty} e^{-x} = 0 \rightarrow \lim_{x \to +\infty} \frac{1}{1 + e^{-x}} = 1$$

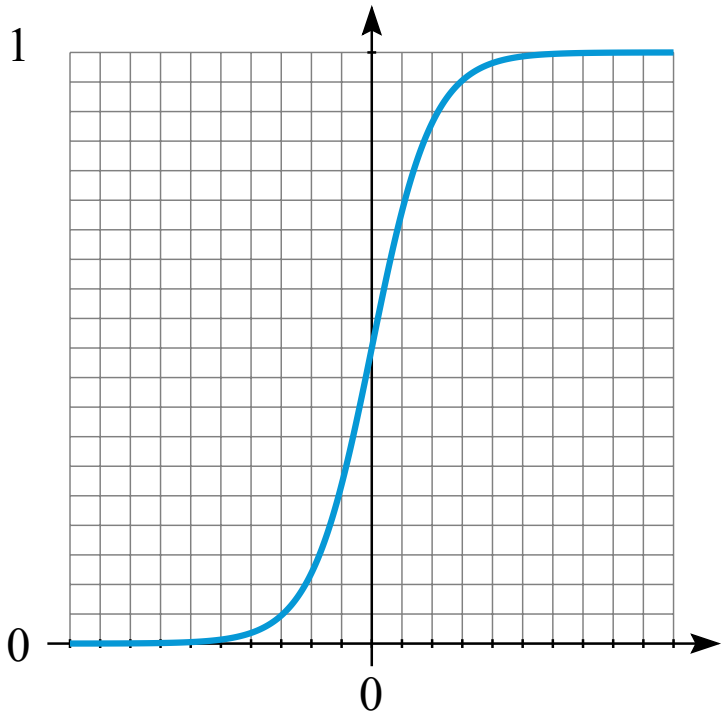


Fonction logistique (Sigmoïde)

- Définition: $f(x) = \dfrac{1}{1 + e^{-x}}$
- Continue car $\forall x \in \mathbb{R}, 1 + e^{-x} \neq 0$
- Croissante strictement
- Ensemble image $]0; 1[$

$$\lim_{x \to -\infty} e^{-x} = +\infty \rightarrow \lim_{x \to -\infty} \frac{1}{1 + e^{-x}} = 0$$

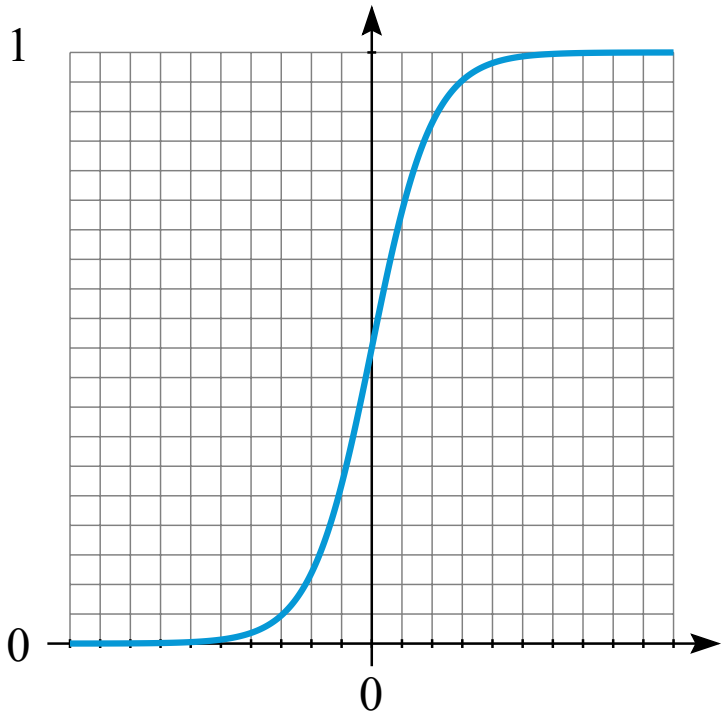
$$\lim_{x \to +\infty} e^{-x} = 0 \rightarrow \lim_{x \to +\infty} \frac{1}{1 + e^{-x}} = 1$$



Fonction logistique (Sigmoïde)

- Définition: $f(x) = \frac{1}{1 + e^{-x}}$
- Continue
- Croissante strictement
- Ensemble image $]0; 1[$

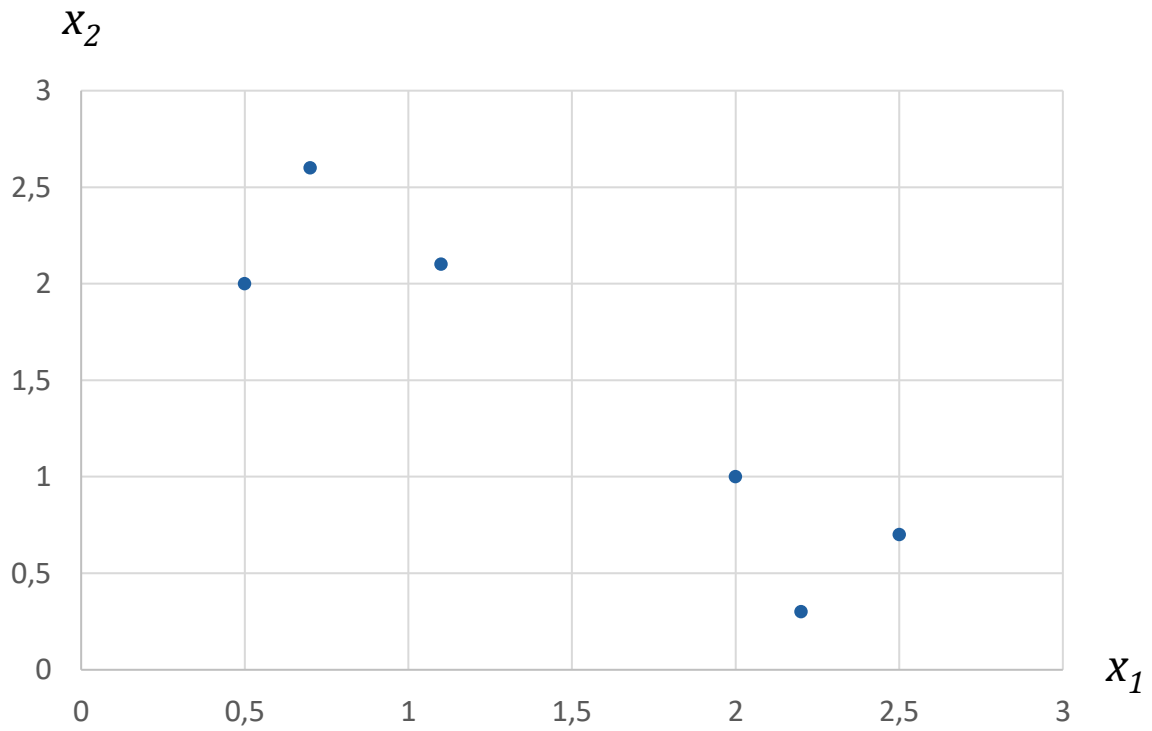
Tous les critères sont (*presque*) validés



Exemple

y	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3

Dataset



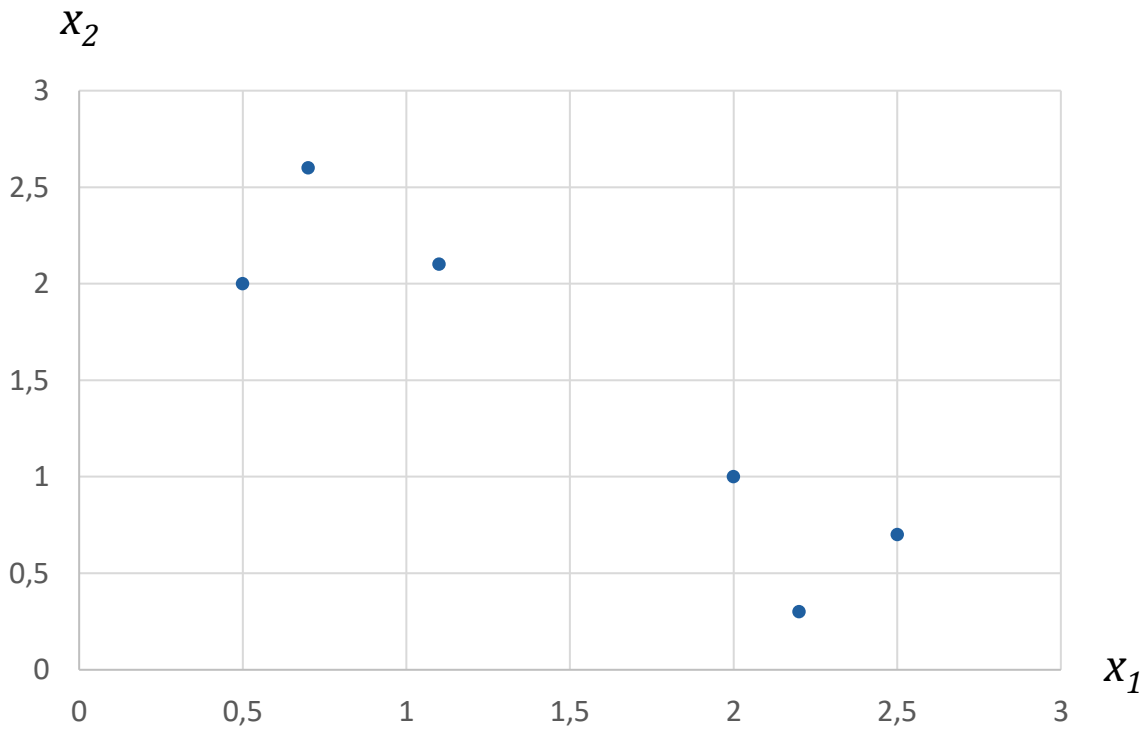
Exemple

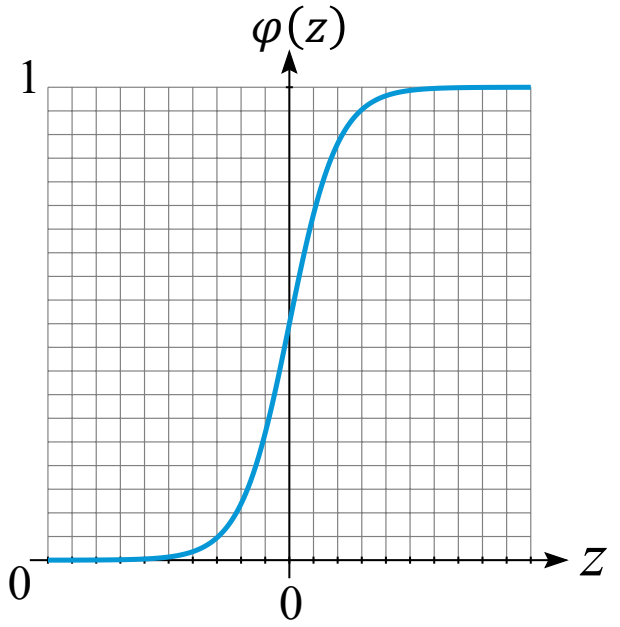
Perceptron

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

y	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3





Exemple

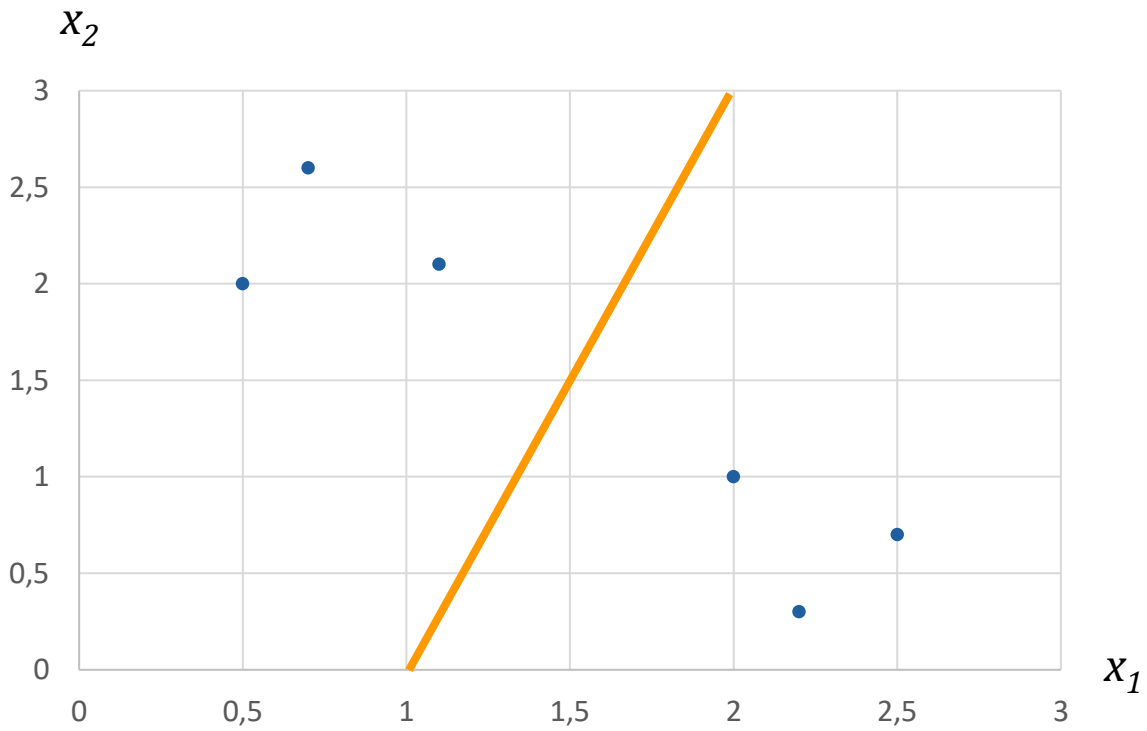
Apprentissage

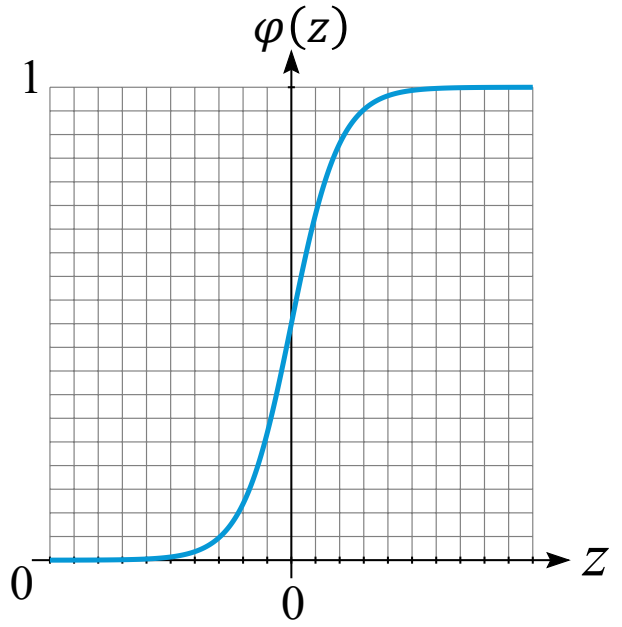
w_1	w_2	b
-0,5	1,5	-1,5

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

y	x_1	x_2
1	0.5	2.0
1	1.1	2.1
1	0.7	2.6
0	2.0	1.0
0	2.5	0.7
0	2.2	0.3





Exemple

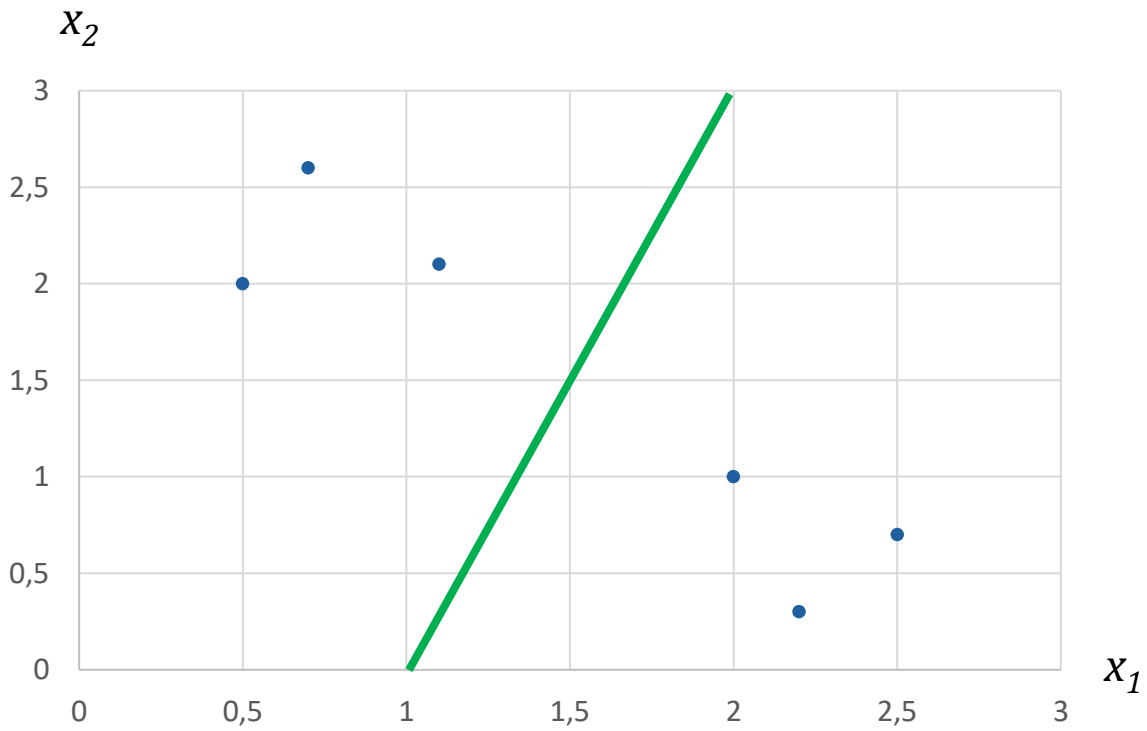
w_1	w_2	b
-0,5	1,5	-1,5

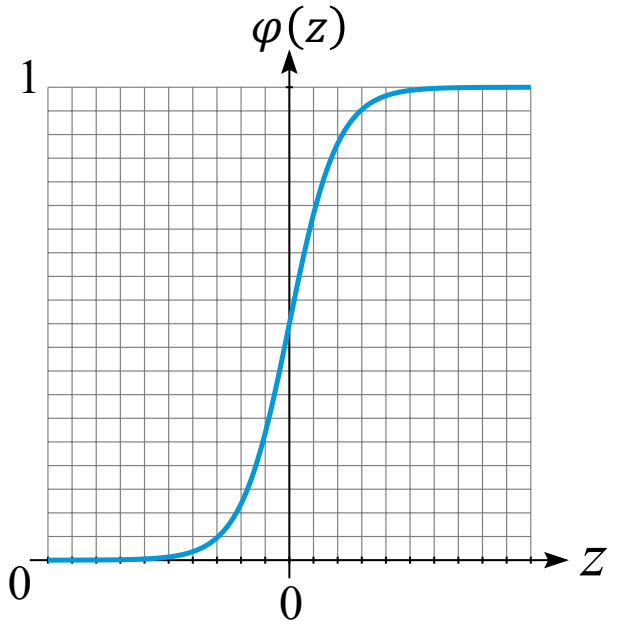
$$z = \sum_{i=1}^{n} x_i w_i + b$$

Calcul des z

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

y	x_1	x_2	z
1	0.5	2.0	1,25
1	1.1	2.1	1,10
1	0.7	2.6	2,05
0	2.0	1.0	-1,00
0	2.5	0.7	-1,70
0	2.2	0.3	-2,15





Exemple

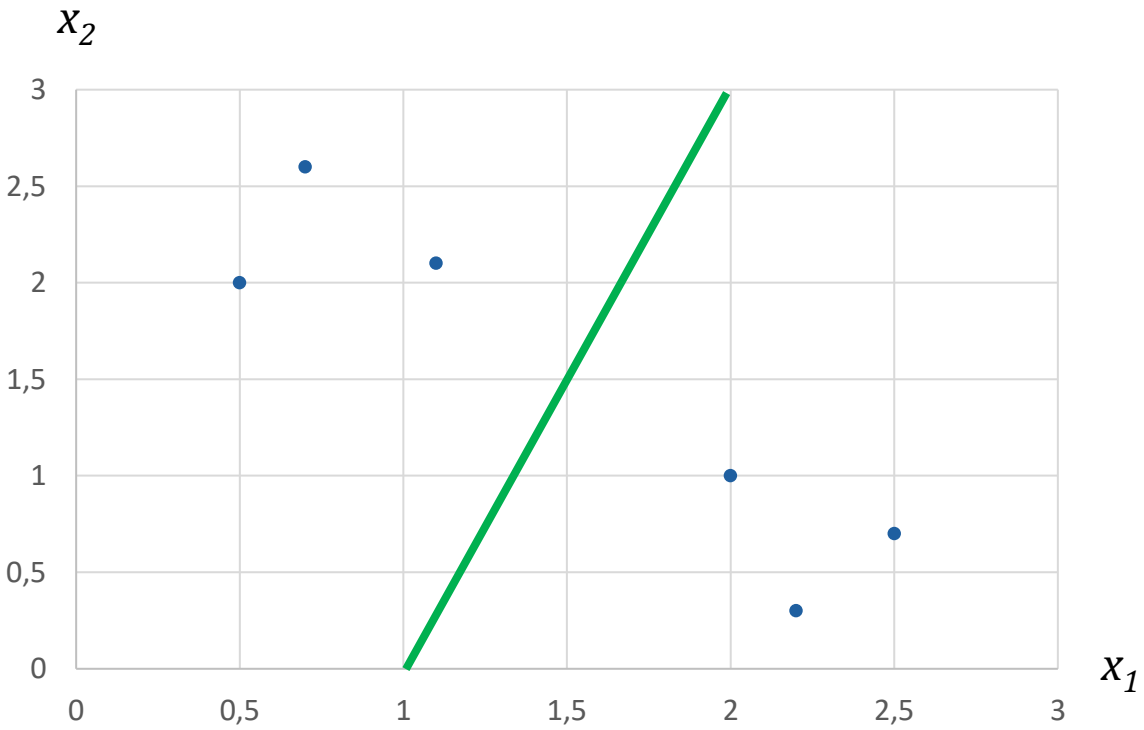
w_1	w_2	b
-0,5	1,5	-1,5

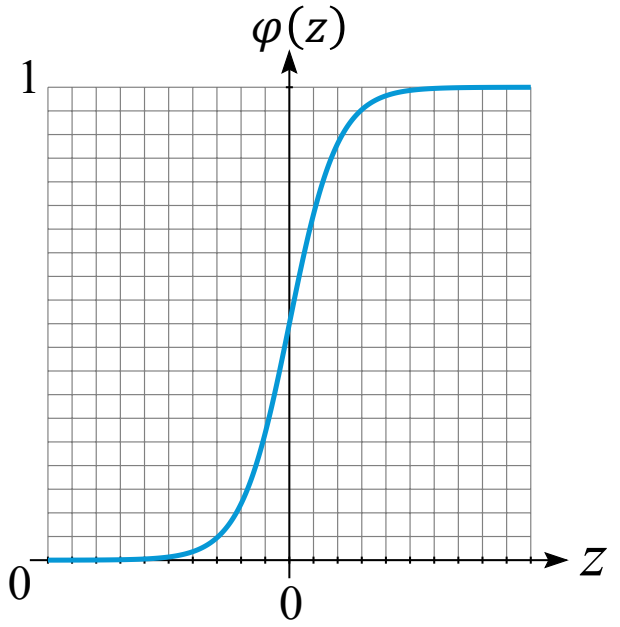
$$z = \sum_{i=1}^{n} x_i w_i + b$$

Calcul de $\varphi(z)$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104





Exemple

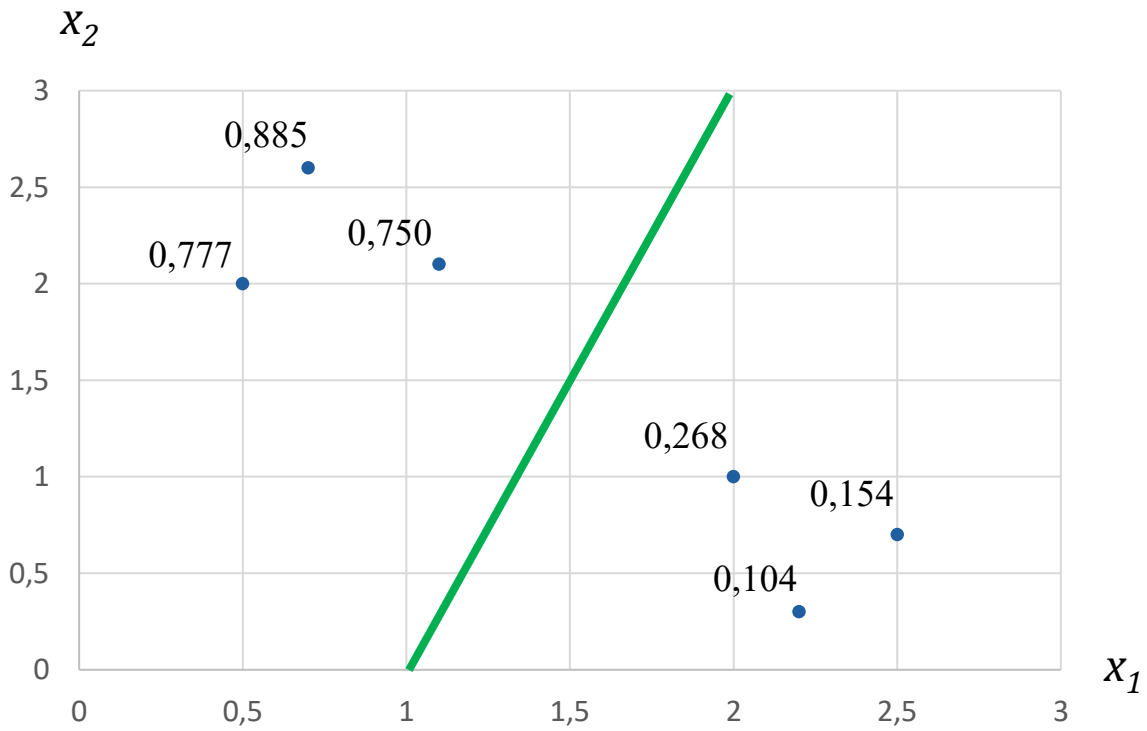
w_1	w_2	b
-0,5	1,5	-1,5

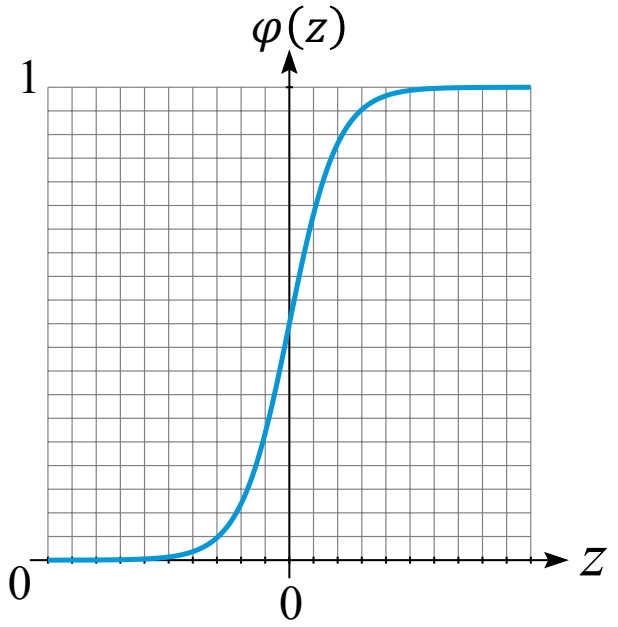
$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

Report sur le graphique

y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104





Exemple

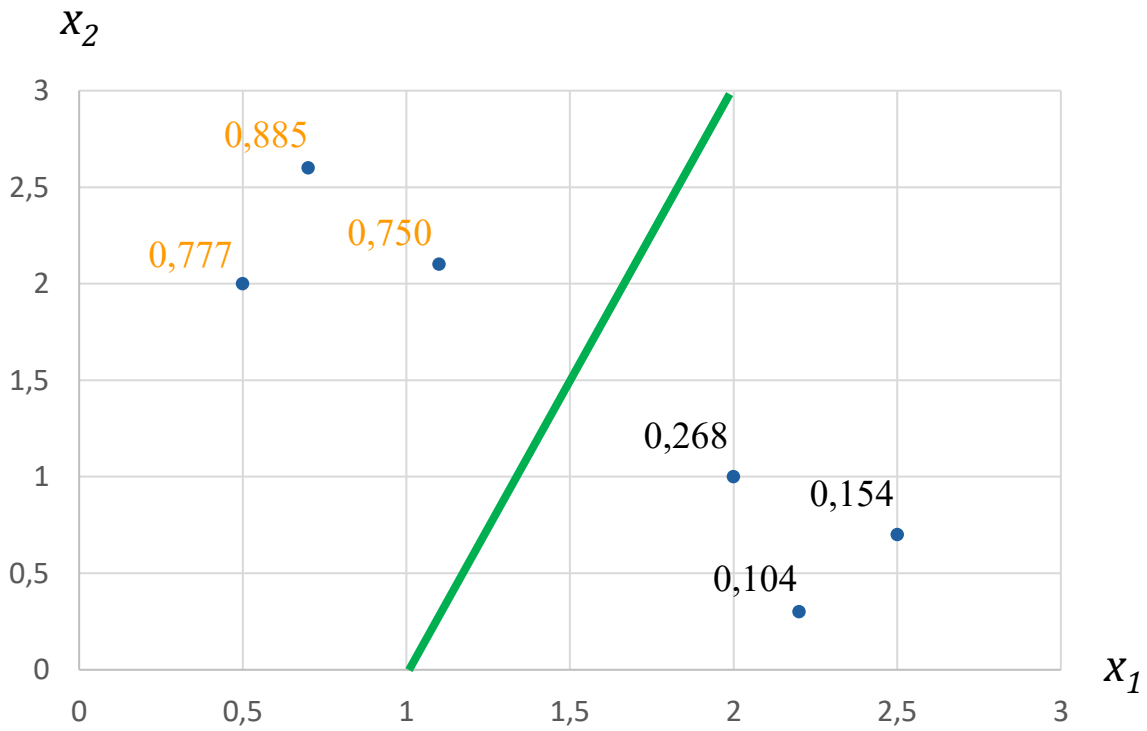
Pour la classe 1 la valeur $\varphi(z)$ semble être une indication d'appartenance

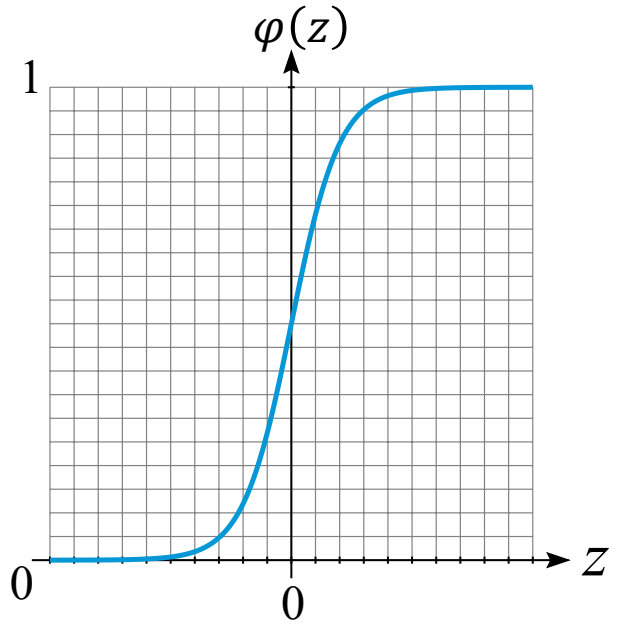
w_1	w_2	b
-0,5	1,5	-1,5

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104





Exemple

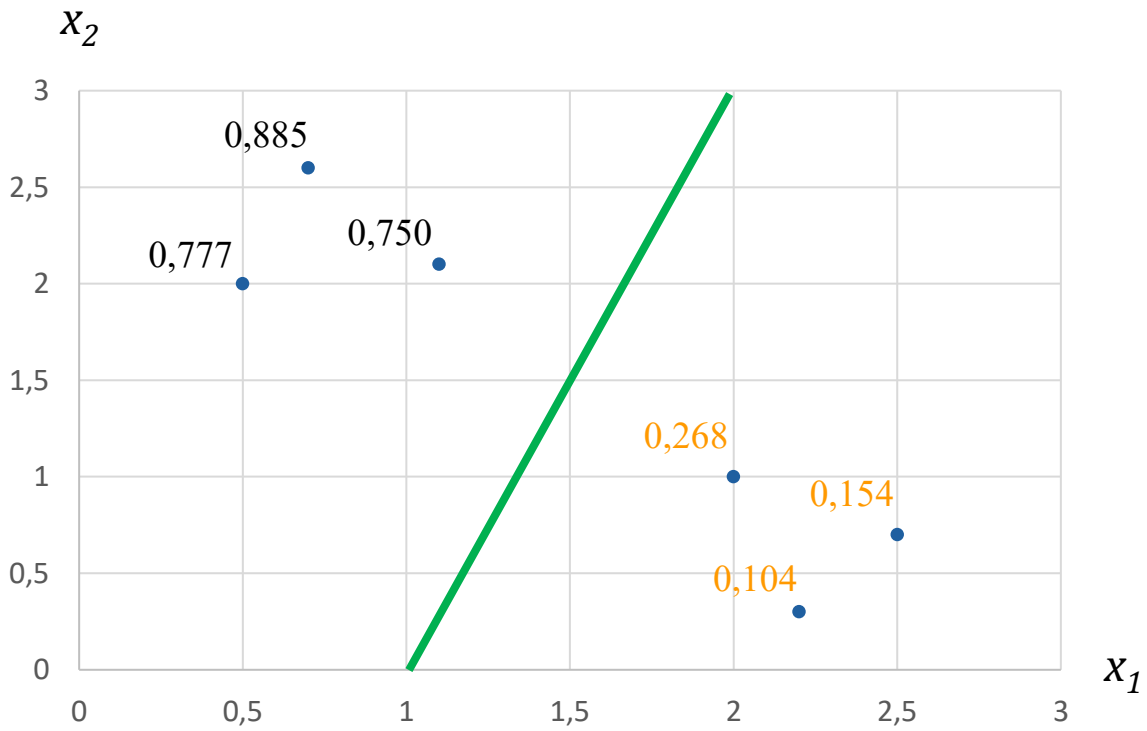
Pour la classe 0 la valeur $\varphi(z)$ semble être une contre-indication d'appartenance

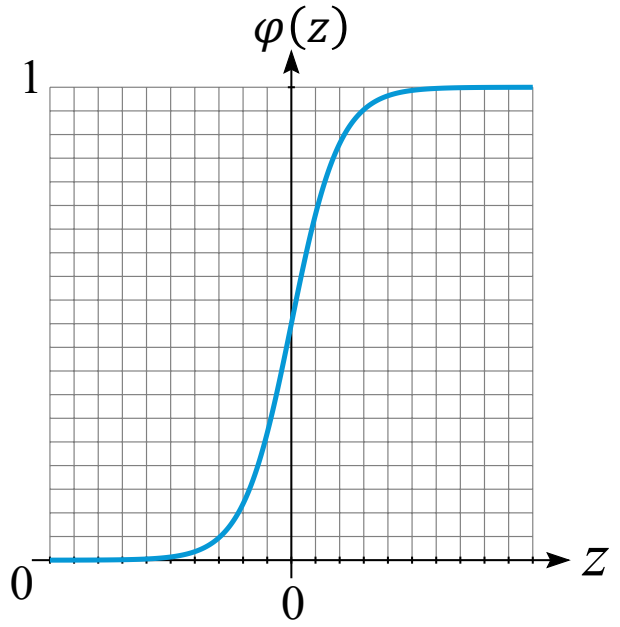
w_1	w_2	b
-0,5	1,5	-1,5

$$z = \sum_{i=1}^{n} x_i w_i + b$$

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

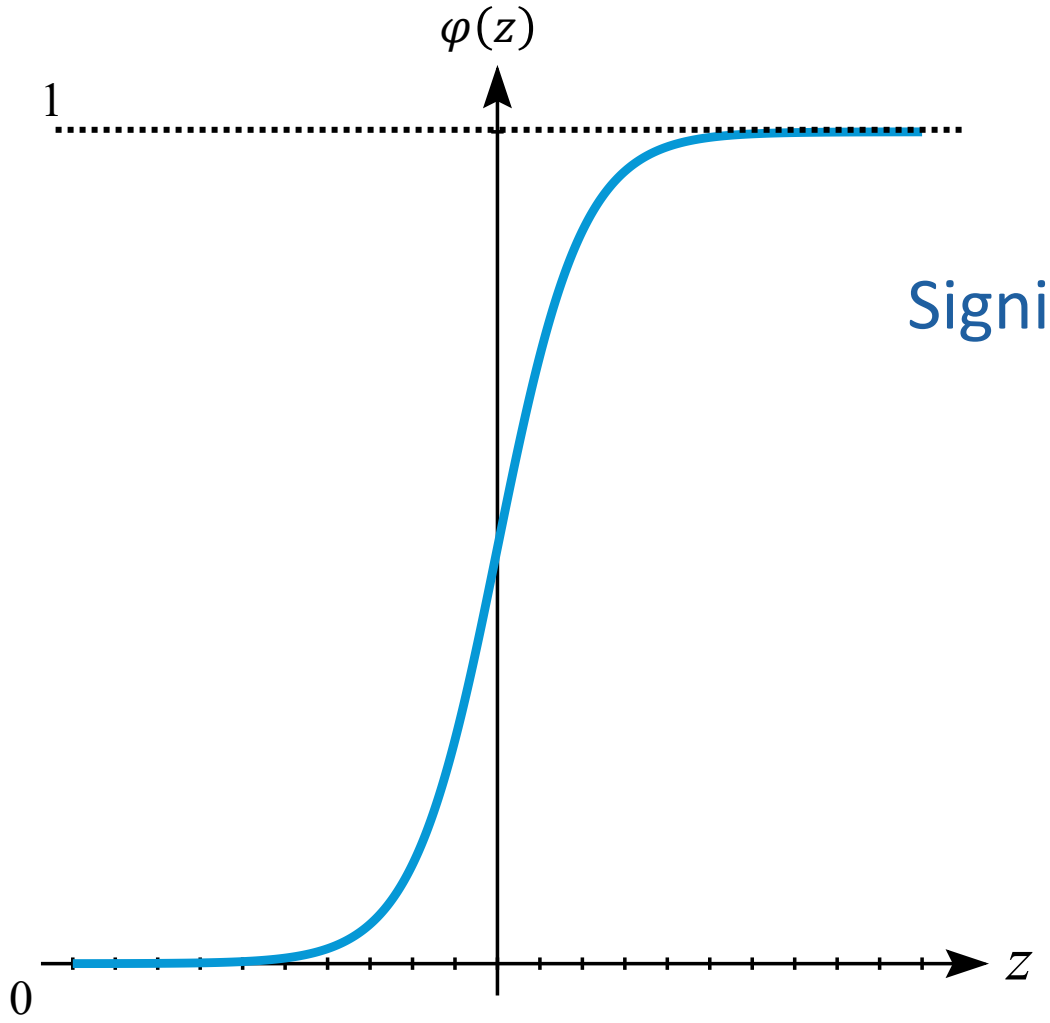
y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104





Exemple

y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104

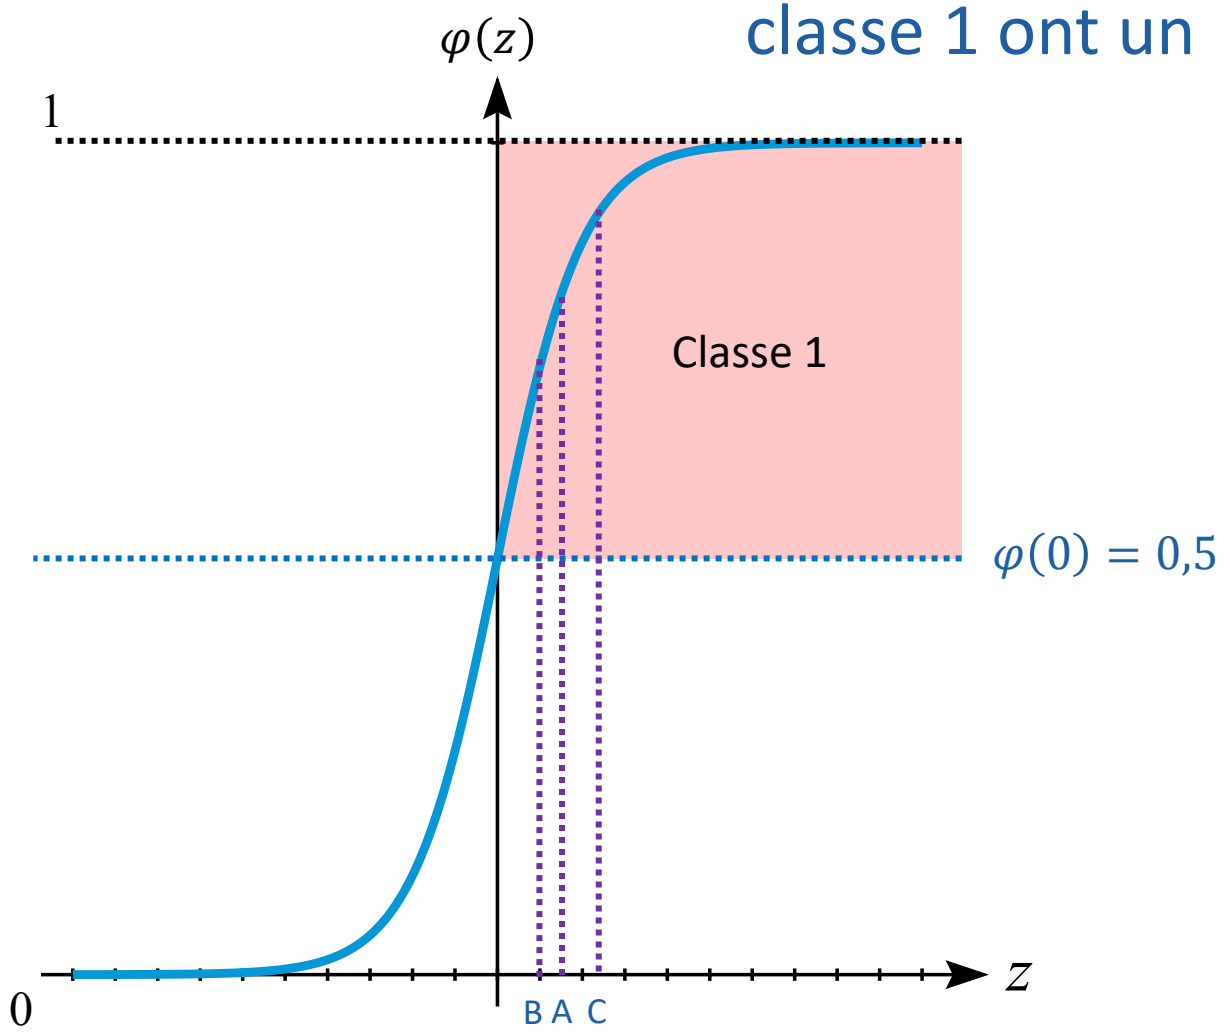


Signification de $\varphi(z)$?

Exemple

y	x_1	x_2	z	$\varphi(z)$	
1	0.5	2.0	**1,25**	**0,777**	A
1	1.1	2.1	**1,10**	**0,750**	B
1	0.7	2.6	**2,05**	**0,885**	C
0	2.0	1.0	-1,00	0,268	
0	2.5	0.7	-1,70	0,154	
0	2.2	0.3	-2,15	0,104	

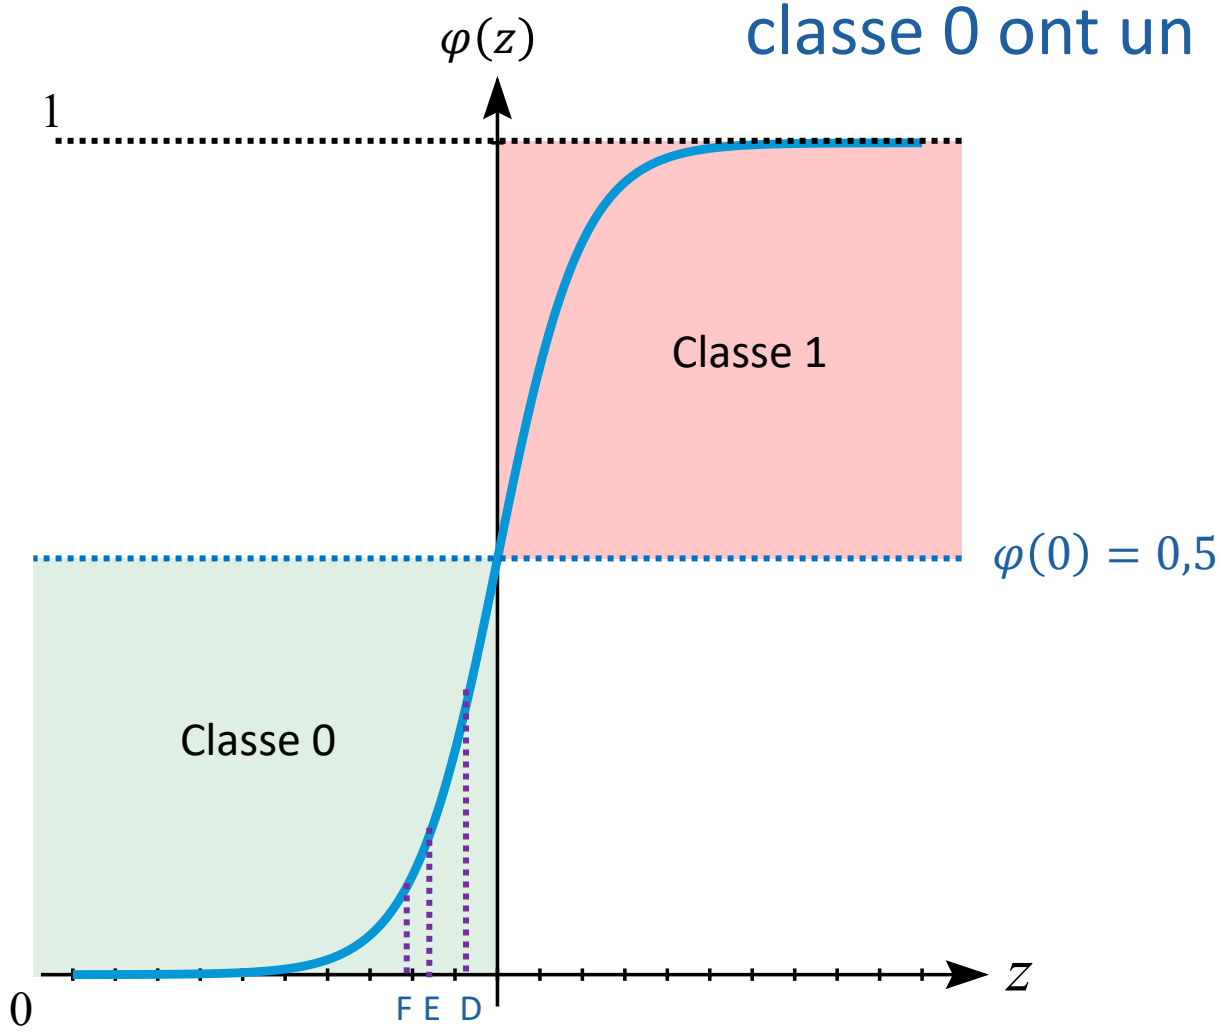
Toutes les instances de la classe 1 ont un $\varphi(z) > 0{,}5$



Exemple

y	x_1	x_2	z	$\varphi(z)$	
1	0.5	2.0	1,25	0,777	
1	1.1	2.1	1,10	0,750	
1	0.7	2.6	2,05	0,885	
0	2.0	1.0	**-1,00**	**0,268**	D
0	2.5	0.7	**-1,70**	**0,154**	E
0	2.2	0.3	**-2,15**	**0,104**	F

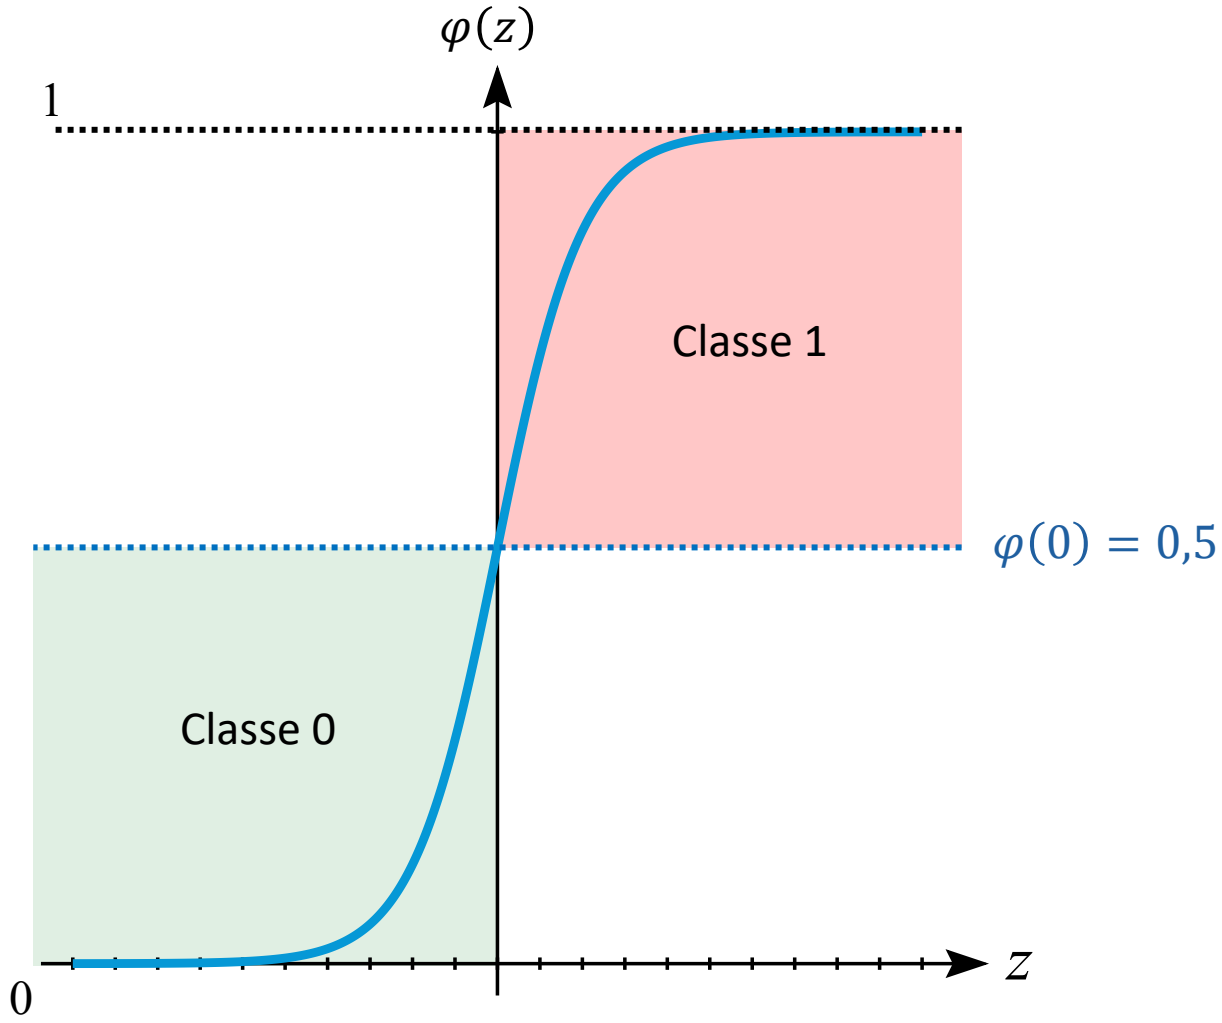
Toutes les instances de la classe 0 ont un $\varphi(z) < 0{,}5$



Exemple

La valeur $\varphi(z)$ est un taux d'appartenance à la classe 1

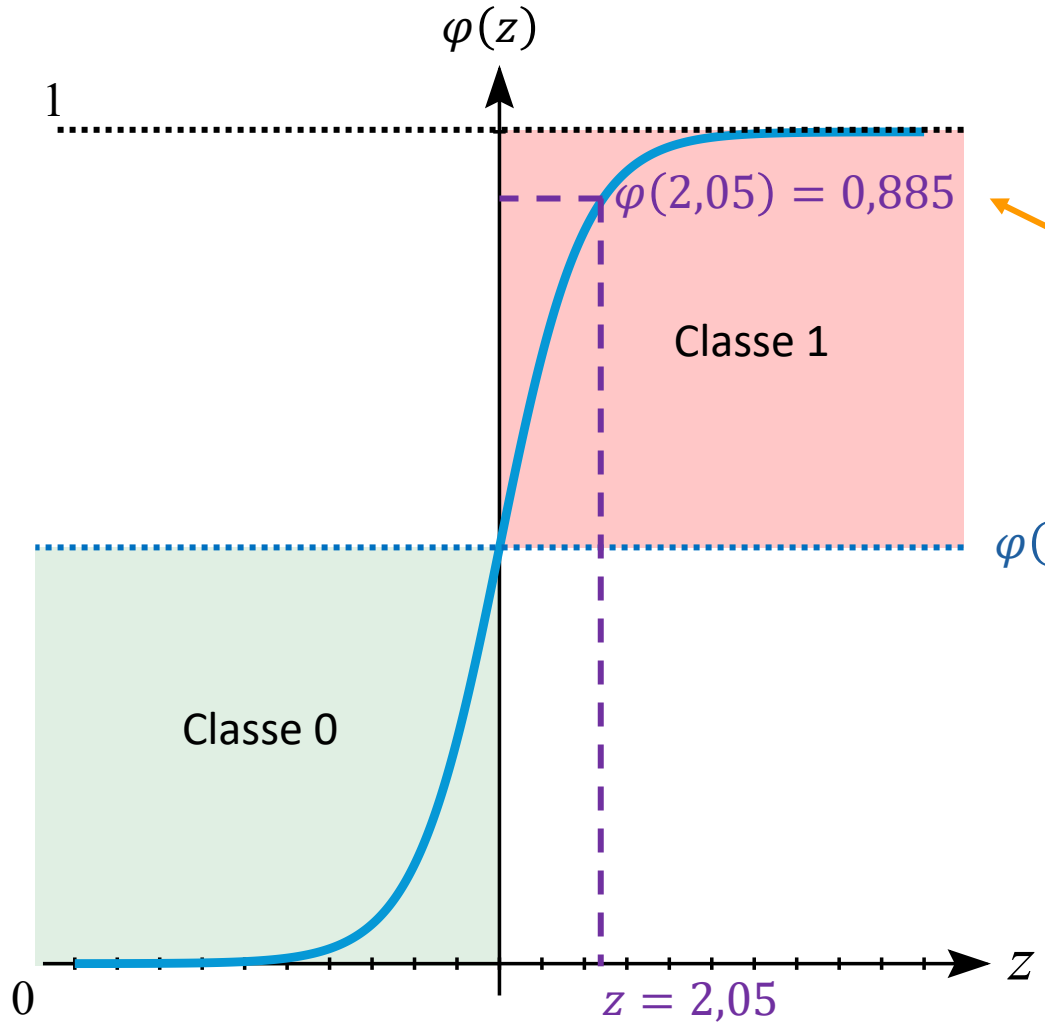
y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104



Exemple

La valeur $\varphi(z)$ est un taux d'appartenance à la classe 1

y	x_1	x_2	z	$\varphi(z)$	
1	0.5	2.0	1,25	0,777	
1	1.1	2.1	1,10	0,750	
1	0.7	2.6	**2,05**	**0,885**	C
0	2.0	1.0	-1,00	0,268	
0	2.5	0.7	-1,70	0,154	
0	2.2	0.3	-2,15	0,104	

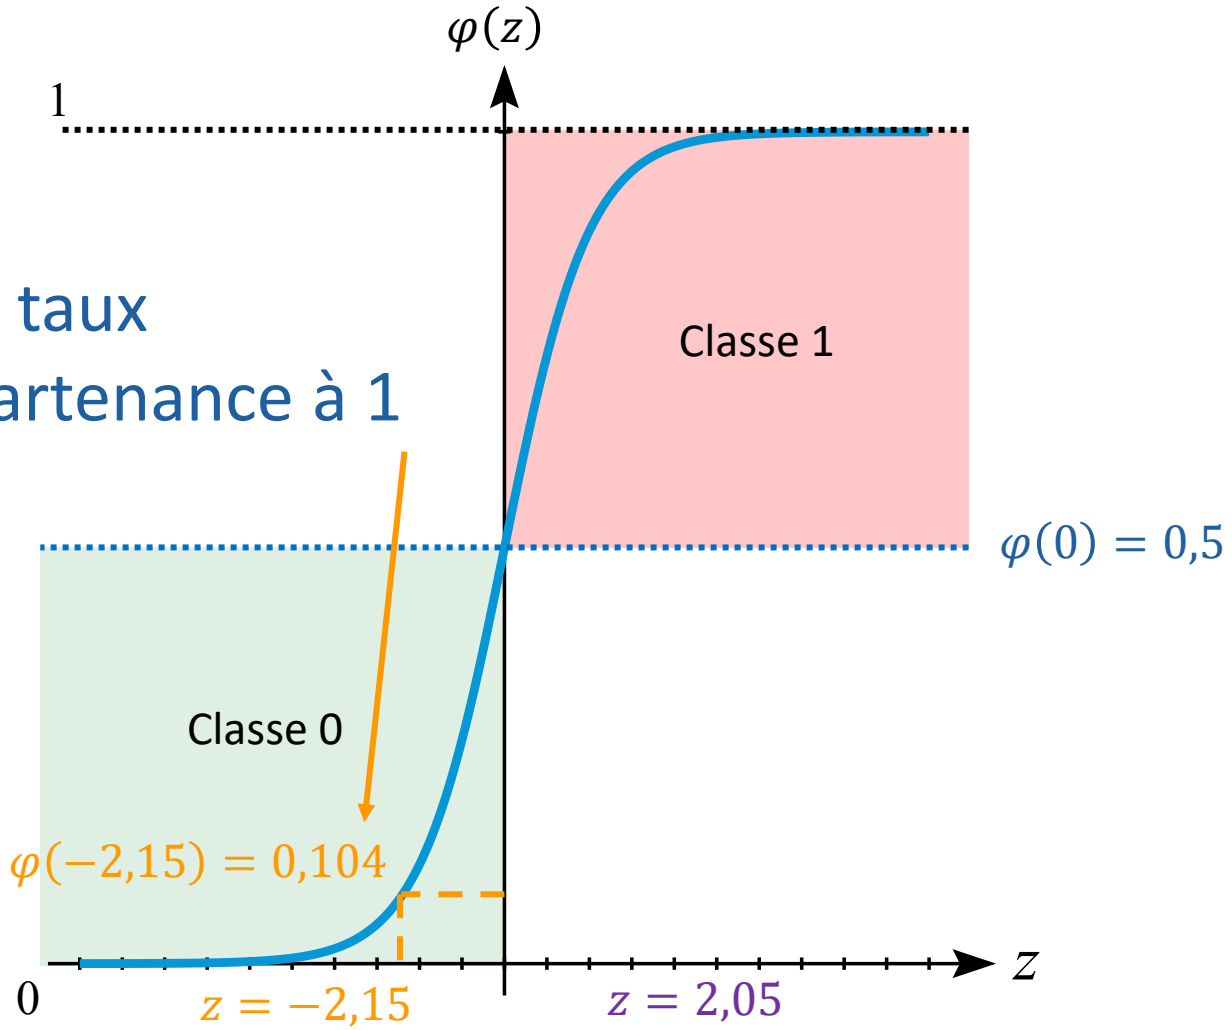


Fort taux d'appartenance à 1

Exemple

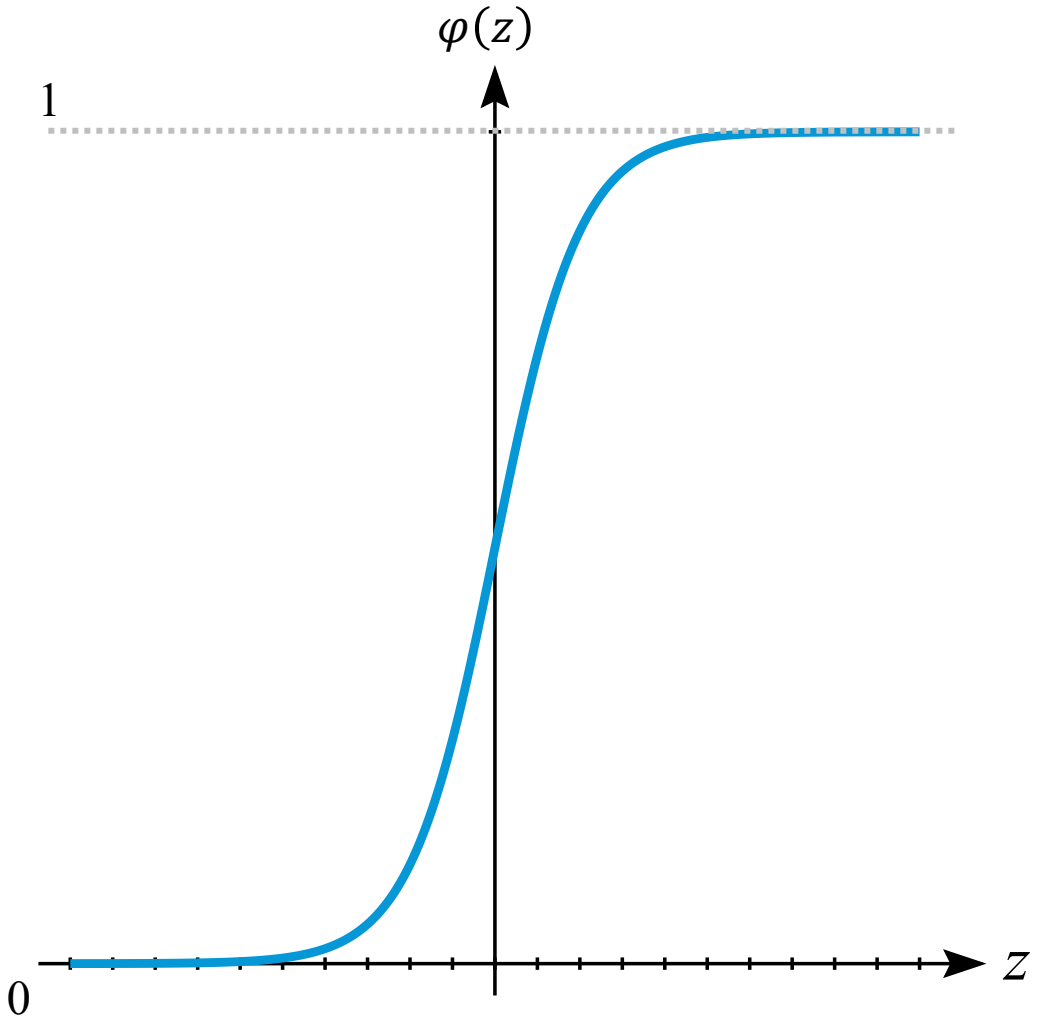
La valeur $\varphi(z)$ est un taux d'appartenance à la classe 1

y	x_1	x_2	z	$\varphi(z)$
1	0.5	2.0	1,25	0,777
1	1.1	2.1	1,10	0,750
1	0.7	2.6	2,05	0,885
0	2.0	1.0	-1,00	0,268
0	2.5	0.7	-1,70	0,154
0	2.2	0.3	-2,15	0,104



Interprétation

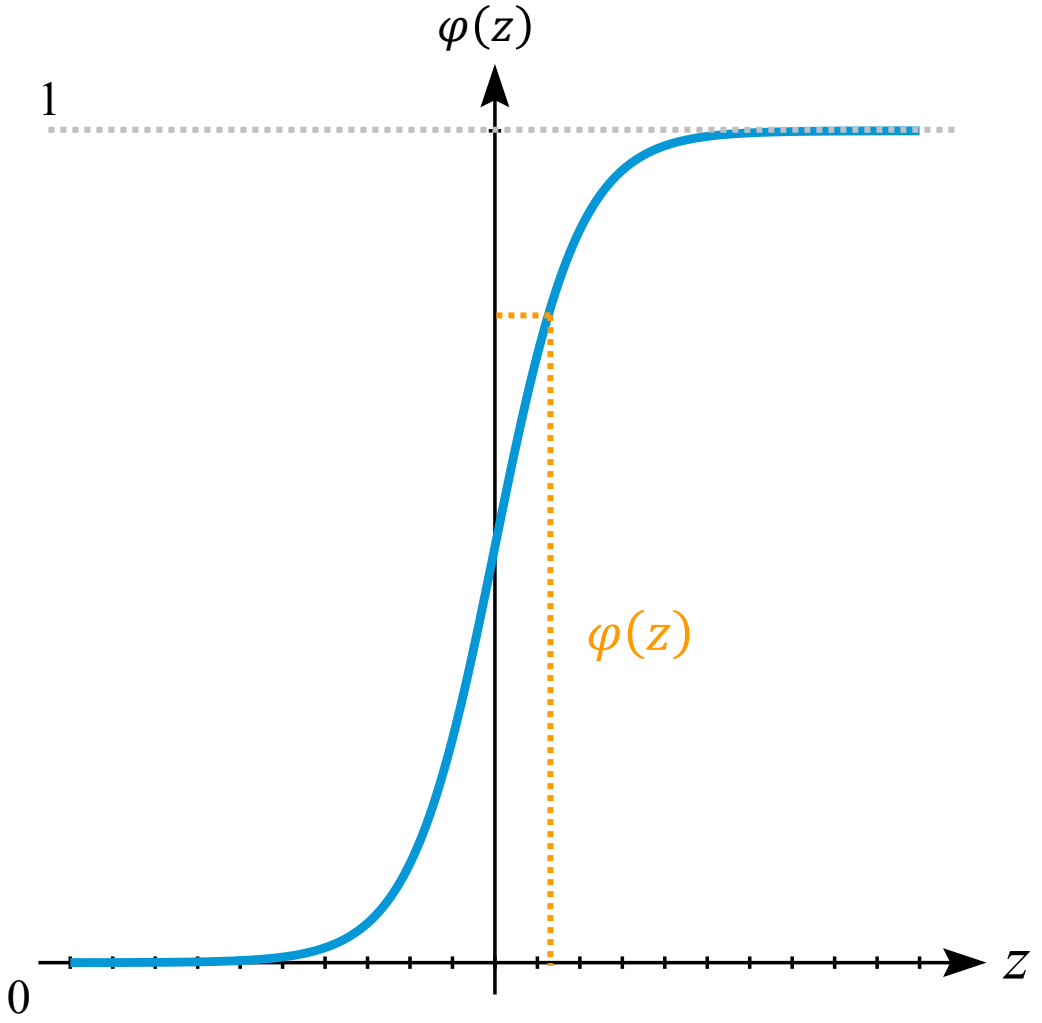
- $\varphi(z)$ est un taux d'appartenance à la classe 1
- $\varphi(z) \in]0;1[$
- φ est continue sur $\mathbb{R}$



Interprétation

- $\varphi(z)$ est un taux d'appartenance à la classe 1
- $\varphi(z) \in]0;1[$
- φ est continue sur $\mathbb{R}$

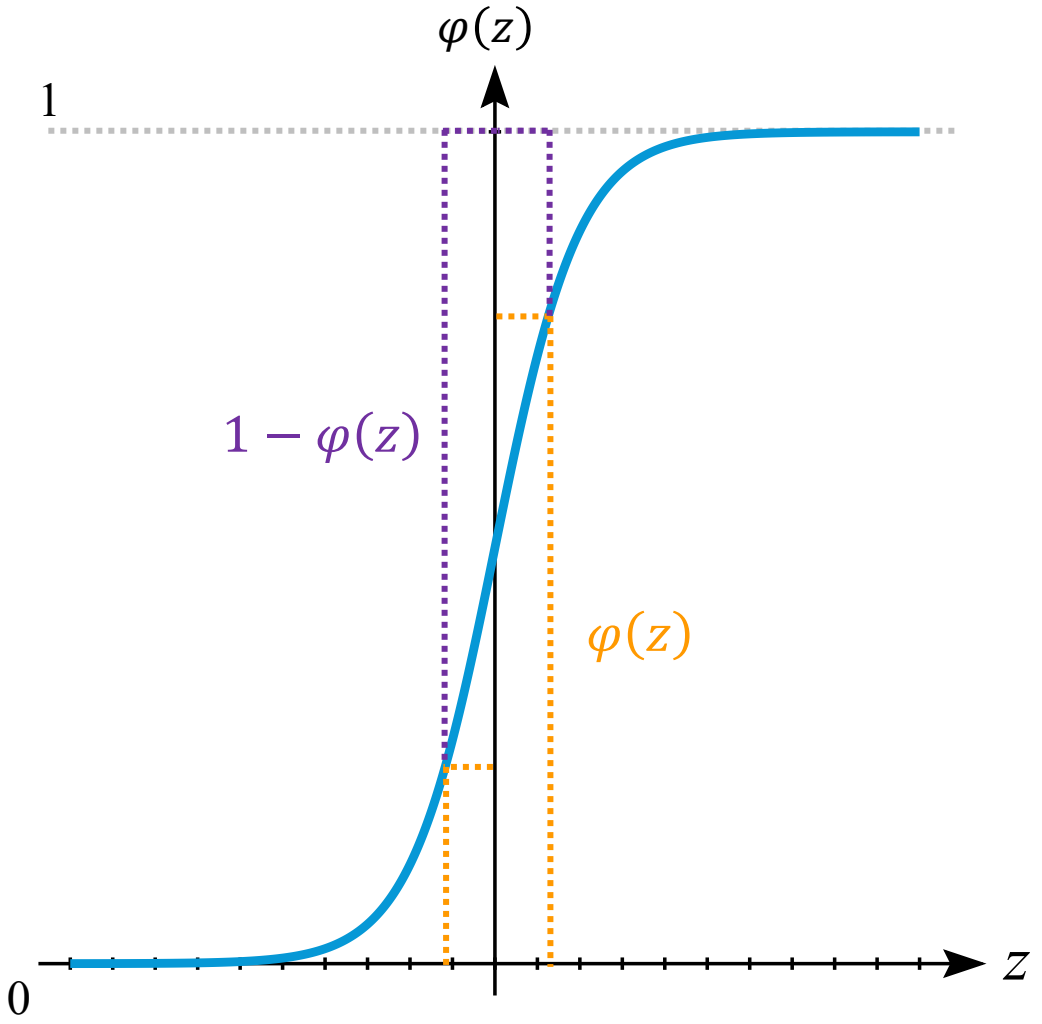
$\varphi\left(z^{(k)}\right)$ est la **probabilité** que l'individu k appartienne à la classe 1



Interprétation

- $\varphi(z)$ est un taux d'appartenance à la classe 1
- $\varphi(z) \in]0;1[$
- φ est continue sur $\mathbb{R}$
- $\varphi\left(z^{(k)}\right)$ est la probabilité que l'individu k appartienne à la classe 1

$1 - \varphi\left(z^{(k)}\right)$ est la **probabilité** que l'individu k appartienne à la classe 0



Définition[Perceptron logistique]

Un perceptron logistique est un perceptron ayant pour fonction d'activation φ la fonction logistique (sigmoïde) et une sortie y définie par:

$$y = \begin{cases} 1 \; si \; \varphi(z) \geq 0.5 \\ 0 \; si \; \varphi(z) < 0.5 \end{cases}$$

Rappel: $z = \sum_{i=1}^{n} x_i w_i + b$

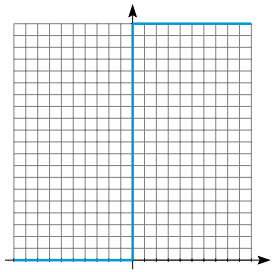
$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

Deux perceptrons

$$z = \sum_{i=1}^{n} x_i w_i + b$$

Rosenblatt

$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



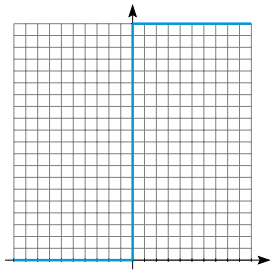
$$y = \varphi(z)$$

Deux perceptrons

$$z = \sum_{i=1}^{n} x_i w_i + b$$

Rosenblatt

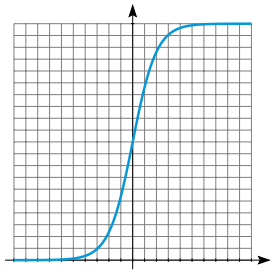
$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



$$y = \varphi(z)$$

Logistique

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$



$$y = \begin{cases} 1 \; si \; \varphi(z) \geq 0.5 \\ 0 \; si \; \varphi(z) < 0.5 \end{cases}$$

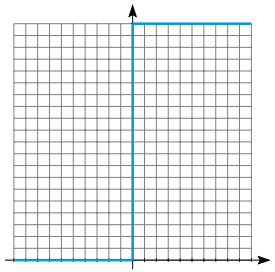
Deux perceptrons

$$z = \sum_{i=1}^{n} x_i w_i + b$$

Agrégation

Rosenblatt

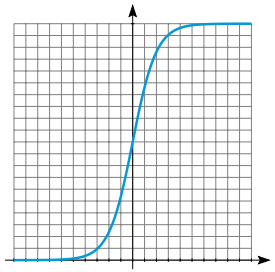
$$\varphi(z) = \begin{cases} 1 \; si \; z > 0 \\ 0 \; si \; z < 0 \end{cases}$$



$$y = \varphi(z)$$

Logistique

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$



$$y = \begin{cases} 1 \; si \; \varphi(z) \geq 0.5 \\ 0 \; si \; \varphi(z) < 0.5 \end{cases}$$

Activation

Sortie

Définition[Probabilité d'appartenance]

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble d'individus et $\mathcal{C} = \{c_1, c_2\}$ un ensemble de deux classes partitionnant $\mathcal{I}$.

$\mathcal{I}$	$\mathcal{C}$
1	Toxique
2	
3	
4	Non toxique
5	
6	

Définition[Probabilité d'appartenance]

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble d'individus et $\mathcal{C} = \{c_1, c_2\}$ un ensemble de deux classes partitionnant $\mathcal{I}$.

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données où $S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_n^{(k)}\right)$ est l'exemple représentant $I^{(k)}$ avec $t^{(k)} = 1 \; si \; I^{(k)} \in c_1$ et $t^{(k)} = 0$ sinon.

Partition
(classes disjointes)

$\mathcal{D}$

$\mathcal{I}$	$\mathcal{C}$	t	x_1	x_2
1	Toxique	1	0.5	2.0
2		1	1.1	2.1
3		1	0.7	2.6
4	Non toxique	0	2.0	1.0
5		0	2.1	0.7
6		0	2.2	0.3

Définition[Probabilité d'appartenance]

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble d'individus et $\mathcal{C} = \{c_1, c_2\}$ un ensemble de deux classes partitionnant $\mathcal{I}$.

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données où $S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_n^{(k)}\right)$ est l'exemple représentant $I^{(k)}$ avec $t^{(k)} = 1 \; si \; I^{(k)} \in c_1$ et $t^{(k)} = 0$ sinon.

Soit un perceptron où φ est la fonction logistique (sigmoïde).

Définition[Probabilité d'appartenance]

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble d'individus et $\mathcal{C} = \{c_1, c_2\}$ un ensemble de deux classes partitionnant $\mathcal{I}$.

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données où $S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_n^{(k)}\right)$ est l'exemple représentant $I^{(k)}$ avec $t^{(k)} = 1 \; si \; I^{(k)} \in c_1$ et $t^{(k)} = 0$ sinon.

Soit un perceptron où φ est la fonction logistique (sigmoïde).

La **probabilité** que $I^{(k)}$ **appartienne** à la classe $c \in \mathcal{C}$, notée $\boldsymbol{P\left(I^{(k)} \in c\right)}$, est définie par:

$$\boldsymbol{P\left(I^{(k)} \in c\right) = \varphi\left(z^{(k)}\right)^{t^{(k)}} \left(1 - \varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}}$$

Définition[Probabilité d'appartenance]

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble d'individus et $\mathcal{C} = \{c_1, c_2\}$ un ensemble de deux classes partitionnant $\mathcal{I}$.

Soit $\mathcal{D} = \{S^{(k)}\}, 1 \leq k \leq m$ un jeu de données où $S^{(k)} = \left(t^{(k)}, x_1^{(k)}, \dots, x_n^{(k)}\right)$ est l'exemple représentant $I^{(k)}$ avec $t^{(k)} = 1 \; si \; I^{(k)} \in c_1$ et $t^{(k)} = 0$ sinon.

Soit un perceptron où φ est la fonction logistique (sigmoïde).

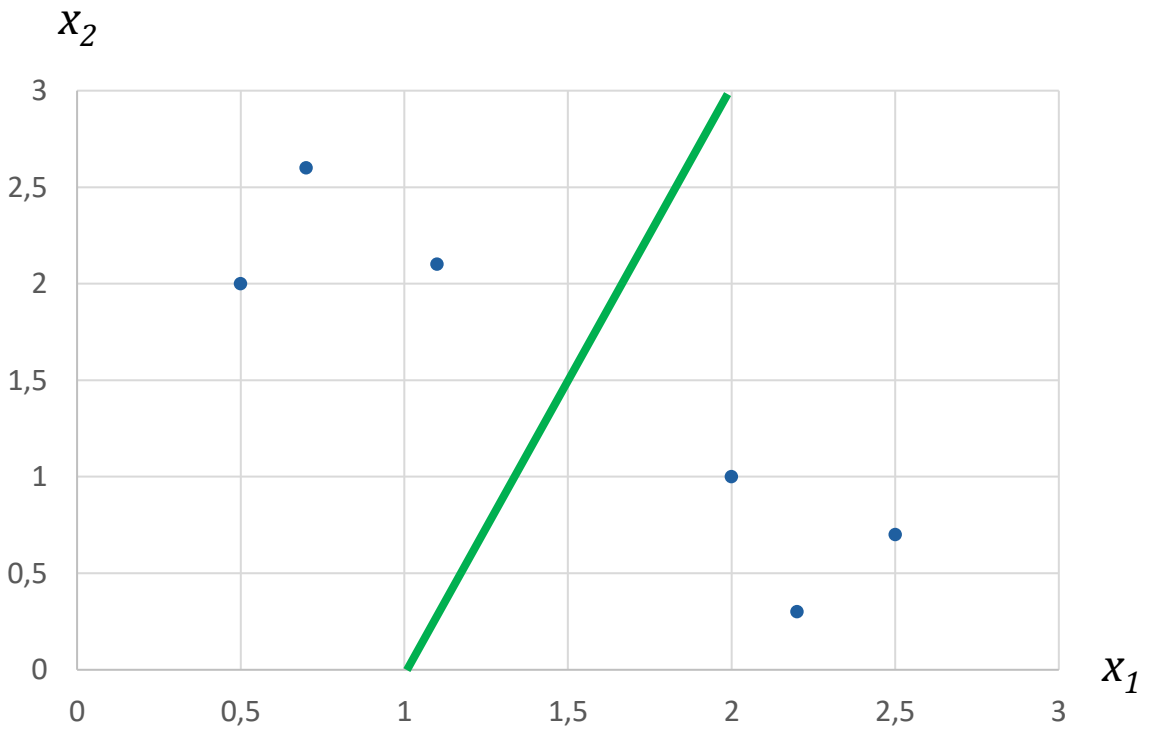
La **probabilité** que $I^{(k)}$ **appartienne** à la classe $c \in \mathcal{C}$, notée $\boldsymbol{P\left(I^{(k)} \in c\right)}$, est définie par:

$$\boldsymbol{P\left(I^{(k)} \in c\right) = \varphi\left(z^{(k)}\right)^{t^{(k)}} \left(1 - \varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}}$$

Loi de Bernoulli

Exemple

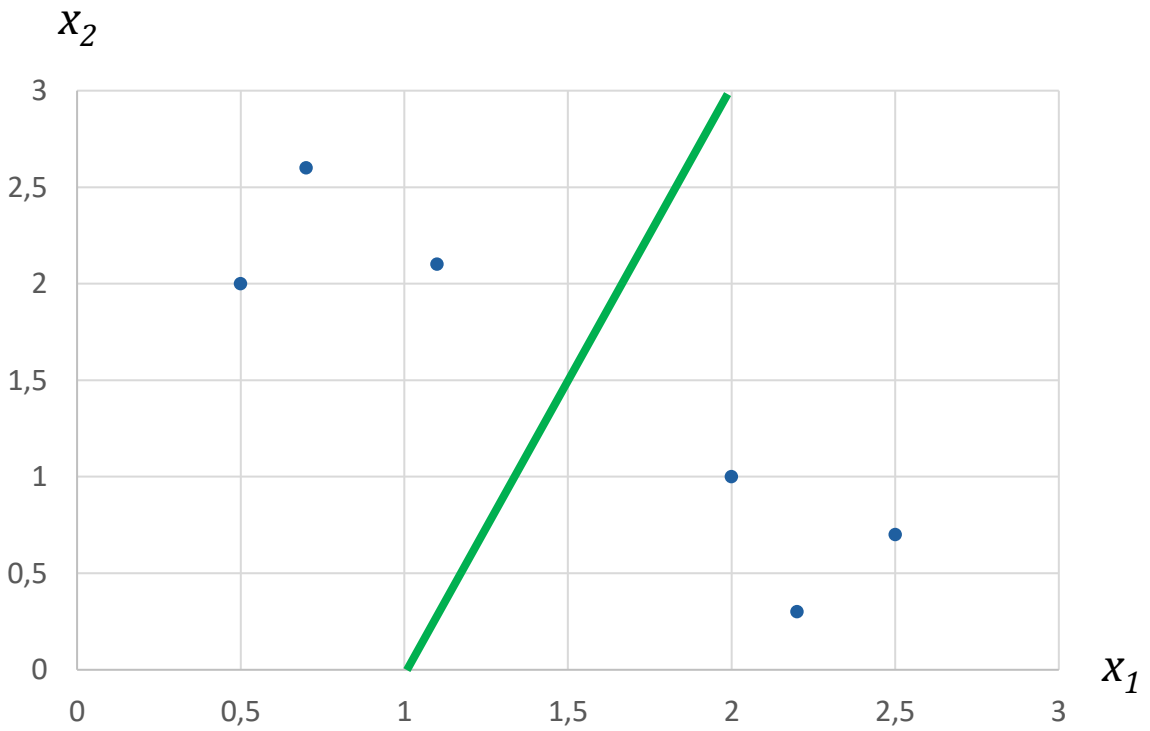
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$
1	1	0.5	2.0	1,25	0,777
2	1	1.1	2.1	1,10	0,750
3	1	0.7	2.6	2,05	0,885
4	0	2.0	1.0	-1,00	0,268
5	0	2.5	0.7	-1,70	0,154
6	0	2.2	0.3	-2,15	0,104



Exemple

- $P\left(I^{(k)} \in 0\right) = \varphi\left(z^{(k)}\right)^{0} \left(1 - \varphi\left(z^{(k)}\right)\right)^{1-0}$

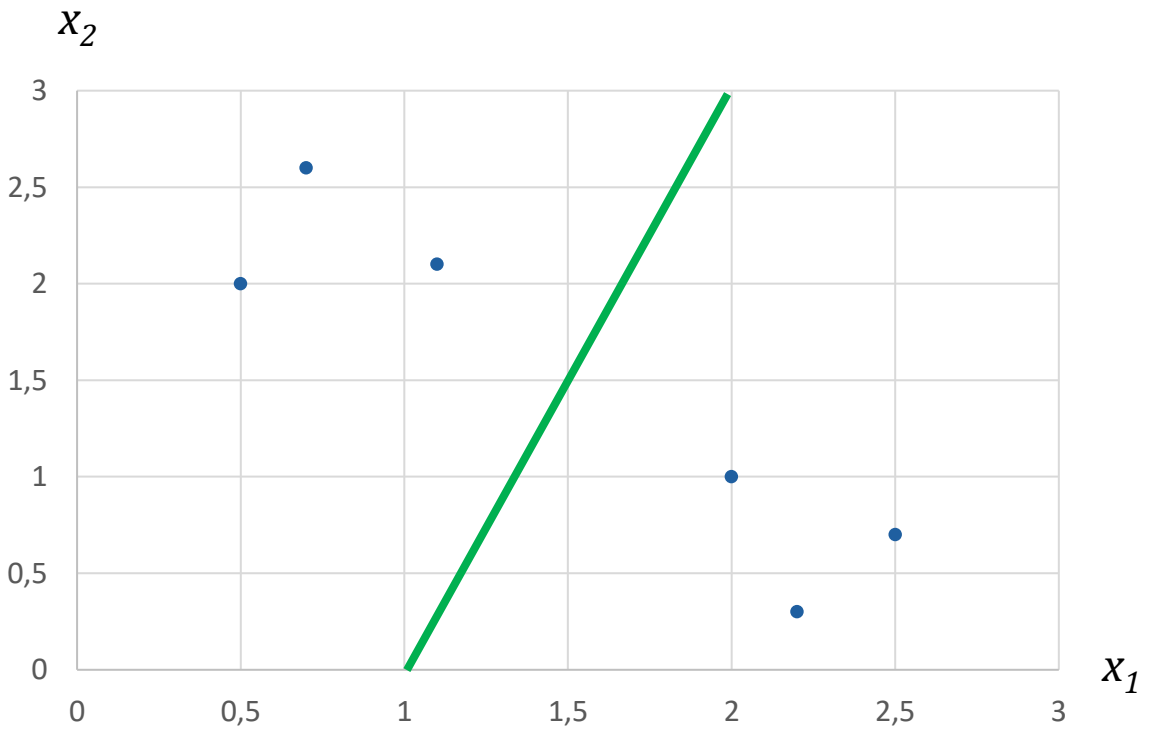
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$
1	1	0.5	2.0	1,25	0,777
2	1	1.1	2.1	1,10	0,750
3	1	0.7	2.6	2,05	0,885
4	0	2.0	1.0	-1,00	0,268
5	0	2.5	0.7	-1,70	0,154
6	0	2.2	0.3	-2,15	0,104



Exemple

- $P\left(I^{(k)} \in 0\right) = \varphi\left(z^{(k)}\right)^{0}\left(1-\varphi\left(z^{(k)}\right)\right)^{1-0} = 1 \times \left(1-\varphi\left(z^{(k)}\right)\right)$

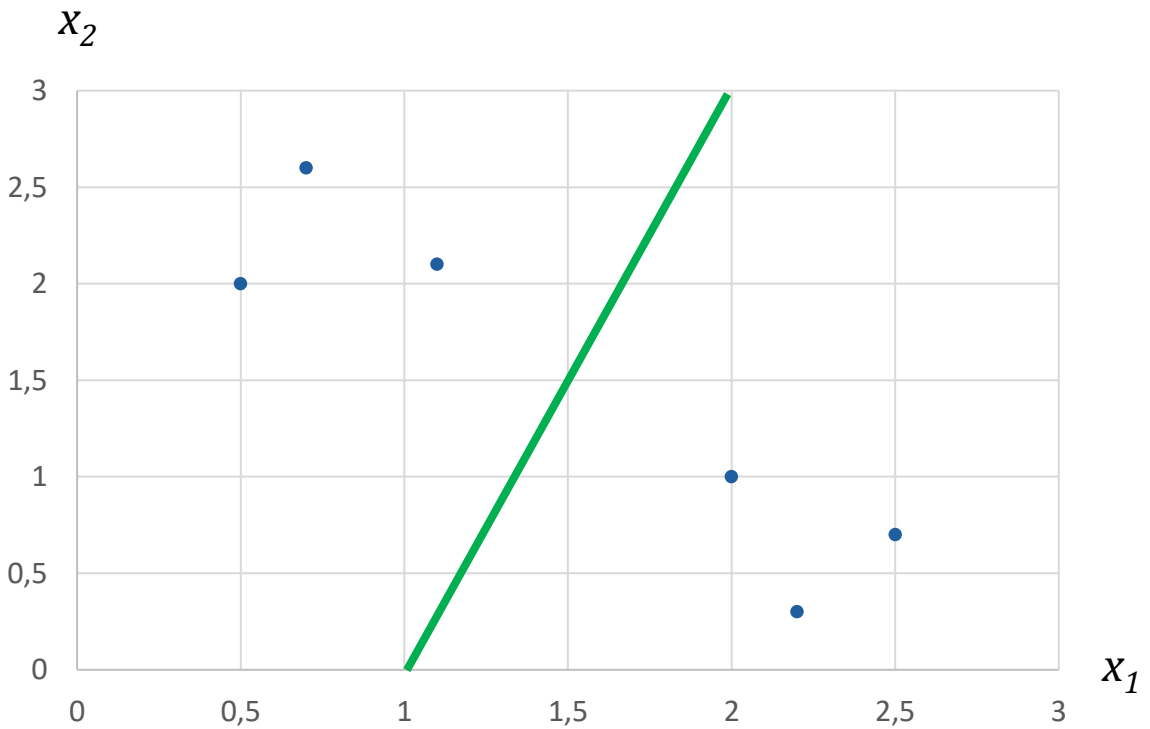
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$
1	1	0.5	2.0	1,25	0,777
2	1	1.1	2.1	1,10	0,750
3	1	0.7	2.6	2,05	0,885
4	0	2.0	1.0	-1,00	0,268
5	0	2.5	0.7	-1,70	0,154
6	0	2.2	0.3	-2,15	0,104



Exemple

- $P\left(I^{(k)} \in 0\right) = \varphi\left(z^{(k)}\right)^{0}\left(1-\varphi\left(z^{(k)}\right)\right)^{1-0} = 1 \times \left(1-\varphi\left(z^{(k)}\right)\right) = 1-\varphi\left(z^{(k)}\right)$

$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$
1	1	0.5	2.0	1,25	0,777
2	1	1.1	2.1	1,10	0,750
3	1	0.7	2.6	2,05	0,885
4	0	2.0	1.0	-1,00	0,268
5	0	2.5	0.7	-1,70	0,154
6	0	2.2	0.3	-2,15	0,104

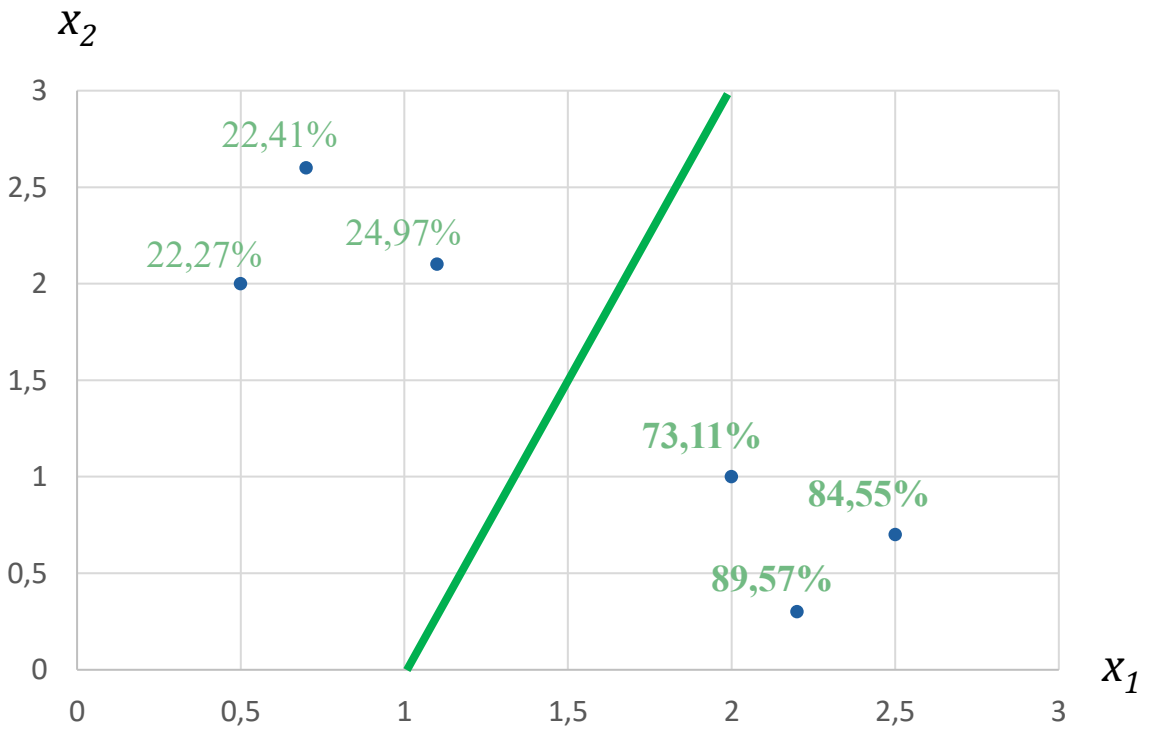


Exemple

- $P\left(I^{(k)} \in 0\right) = 1 - \varphi\left(z^{(k)}\right)$

Ecriture des valeurs de probabilité en % par convention

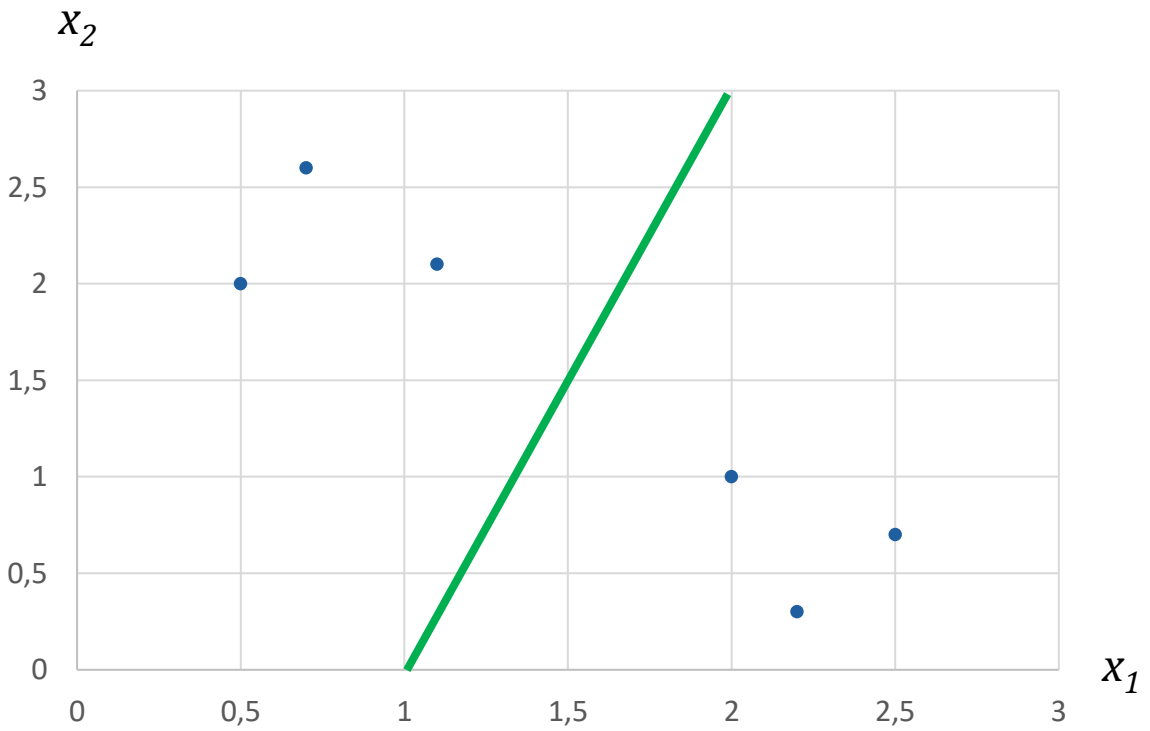
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$
1	1	0.5	2.0	1,25	0,777	22,27%
2	1	1.1	2.1	1,10	0,750	24,97%
3	1	0.7	2.6	2,05	0,885	22,41%
4	0	2.0	1.0	-1,00	0,268	73,11%
5	0	2.5	0.7	-1,70	0,154	84,55%
6	0	2.2	0.3	-2,15	0,104	89,57%



Exemple

- $P\left(I^{(k)} \in 0\right) = 1 - \varphi\left(z^{(k)}\right)$
- $P\left(I^{(k)} \in 1\right) = \varphi\left(z^{(k)}\right)^{1}\left(1 - \varphi\left(z^{(k)}\right)\right)^{1-1}$

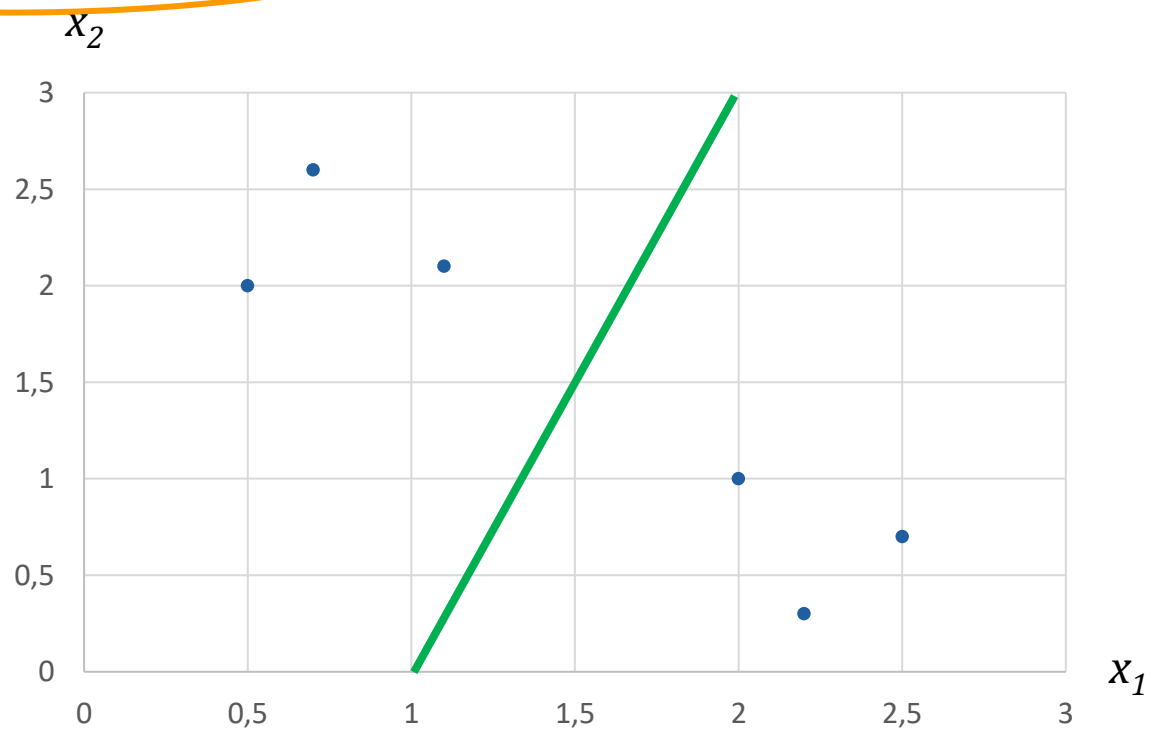
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$
1	1	0.5	2.0	1,25	0,777	22,27%
2	1	1.1	2.1	1,10	0,750	24,97%
3	1	0.7	2.6	2,05	0,885	22,41%
4	0	2.0	1.0	-1,00	0,268	**73,11%**
5	0	2.5	0.7	-1,70	0,154	**84,55%**
6	0	2.2	0.3	-2,15	0,104	**89,57%**



Exemple

- $P\left(I^{(k)} \in 0\right) = 1 - \varphi\left(z^{(k)}\right)$
- $P\left(I^{(k)} \in 1\right) = \varphi\left(z^{(k)}\right)^{1}\left(1 - \varphi\left(z^{(k)}\right)\right)^{1-1} = \varphi\left(z^{(k)}\right) \times 1$

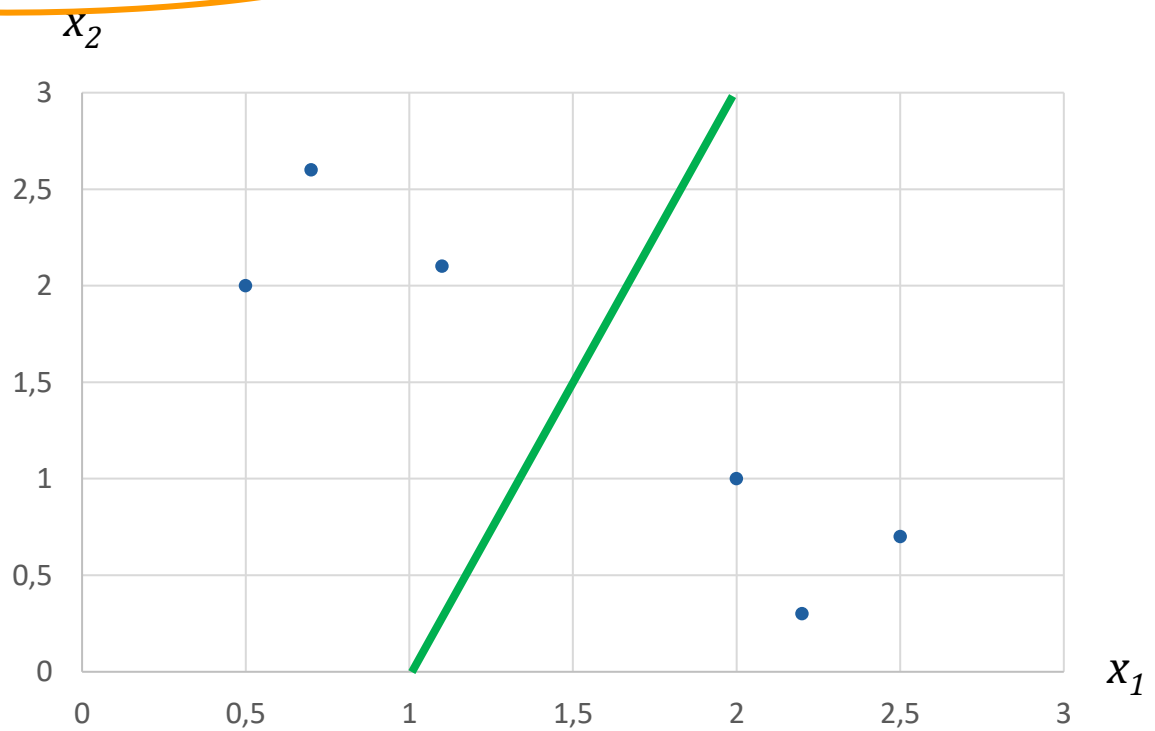
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$
1	1	0.5	2.0	1,25	0,777	22,27%
2	1	1.1	2.1	1,10	0,750	24,97%
3	1	0.7	2.6	2,05	0,885	22,41%
4	0	2.0	1.0	-1,00	0,268	**73,11%**
5	0	2.5	0.7	-1,70	0,154	**84,55%**
6	0	2.2	0.3	-2,15	0,104	**89,57%**



Exemple

- $P\left(I^{(k)} \in 0\right) = 1 - \varphi\left(z^{(k)}\right)$
- $P\left(I^{(k)} \in 1\right) = \varphi\left(z^{(k)}\right)^{1}\left(1 - \varphi\left(z^{(k)}\right)\right)^{1-1} = \varphi\left(z^{(k)}\right) \times 1 = \varphi\left(z^{(k)}\right)$

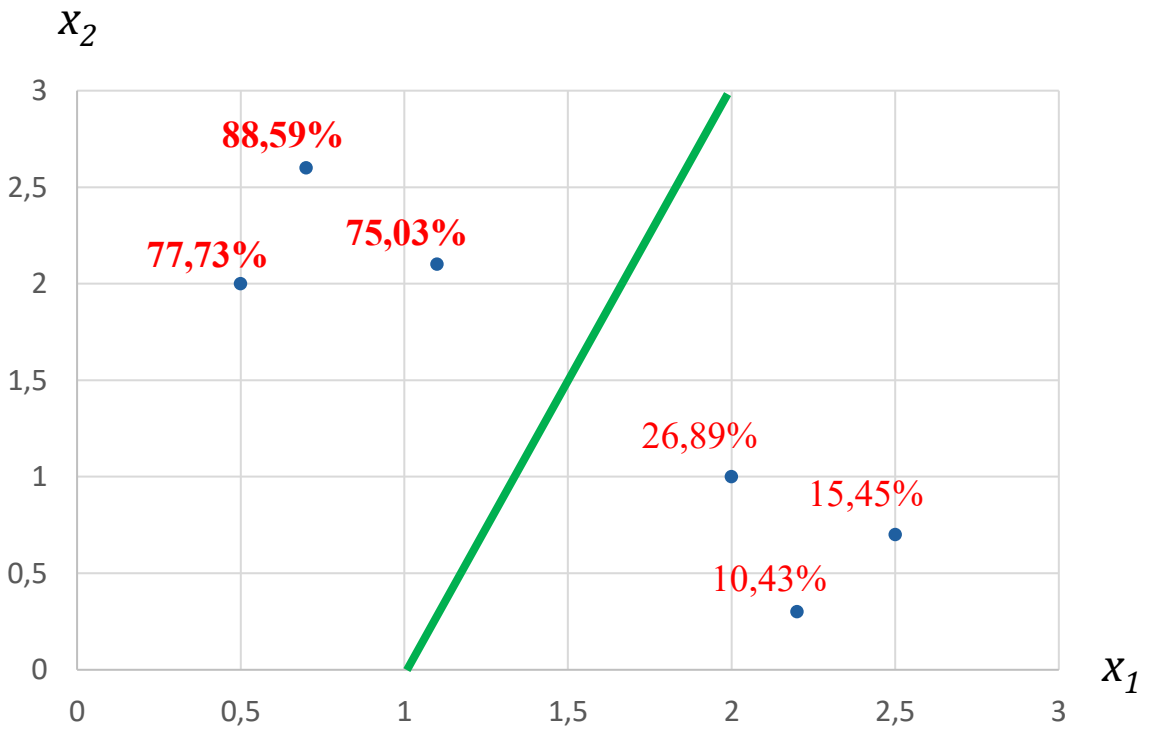
$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$
1	1	0.5	2.0	1,25	0,777	22,27%
2	1	1.1	2.1	1,10	0,750	24,97%
3	1	0.7	2.6	2,05	0,885	22,41%
4	0	2.0	1.0	-1,00	0,268	**73,11%**
5	0	2.5	0.7	-1,70	0,154	**84,55%**
6	0	2.2	0.3	-2,15	0,104	**89,57%**



Exemple

- $P\left(I^{(k)} \in 0\right) = 1 - \varphi\left(z^{(k)}\right)$
- $P\left(I^{(k)} \in 1\right) = \varphi\left(z^{(k)}\right)$

$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

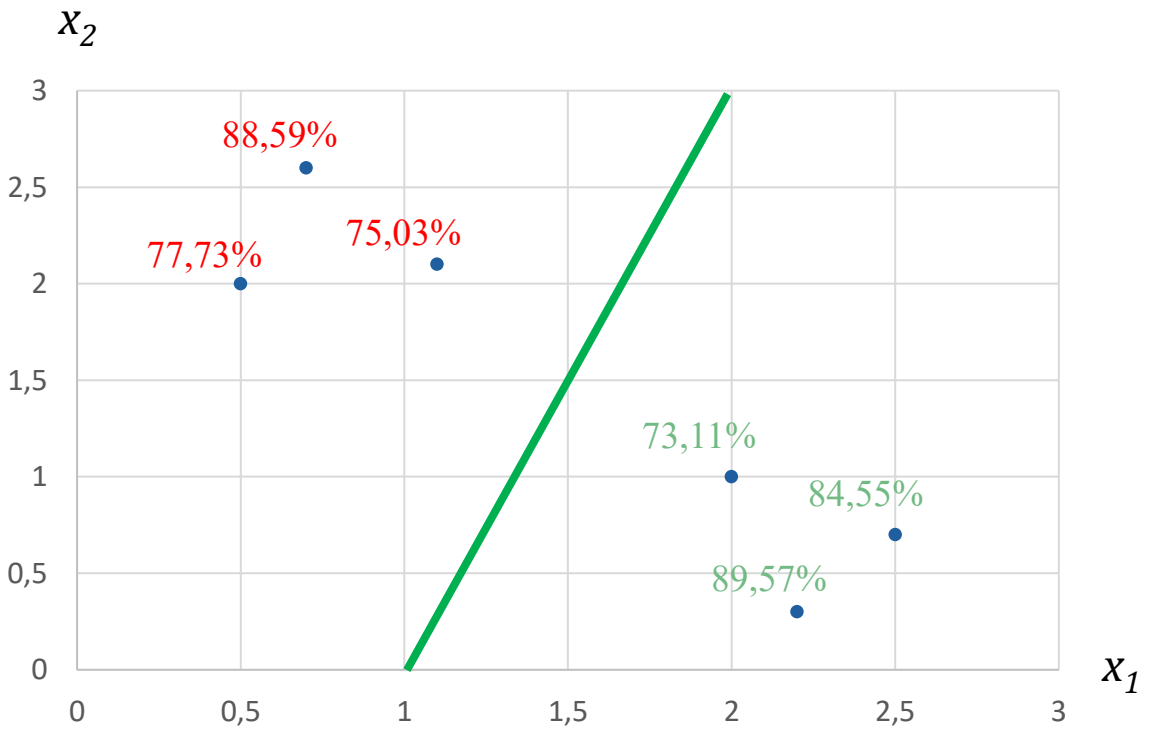


Exemple

- $P\left(I^{(k)} \in 0\right) = 1 - \varphi\left(z^{(k)}\right)$
- $P\left(I^{(k)} \in 1\right) = \varphi\left(z^{(k)}\right)$

Probabilité d'appartenir à la « bonne » classe

$\mathcal{I}$	t	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%



Qualité / Confiance

- Comment savoir si un modèle est « bon »
- Qu’est-ce qu’un « bon »modèle ?
- Comment évaluer un modèle dans sa globalité ?

Concept[Vraisemblance]

En apprentissage machine, la **vraisemblance** est la plausibilité du modèle vis-à-vis de données vérifiées.

Concept[Vraisemblance]

En apprentissage machine, la **vraisemblance** est la plausibilité du modèle vis-à-vis de données vérifiées.



Comment la quantifier ?

Définition[Vraisemblance]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble représentant 2 classes disjointes.

Définition[Vraisemblance]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble représentant 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Définition[Vraisemblance]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble représentant 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Soit un modèle associant à chaque $I^{(k)}$ la probabilité $P\left(I^{(k)} \in c\right)$ pour $I^{(k)}$ d'appartenir à la classe $c \in \mathcal{C}$.

Définition[Vraisemblance]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble représentant 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Soit un modèle associant à chaque $I^{(k)}$ la probabilité $P(I^{(k)} \in c)$ pour $I^{(k)}$ d'appartenir à la classe $c \in \mathcal{C}$.

La **vraisemblance** du modèle , notée L, est définie par:

$$L = \prod_{k=1}^{m} P(I^{(k)} \in c)$$

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p(I^{(k)} \in 0)$	$p(I^{(k)} \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p(I^{(k)} \in 0)$	$p(I^{(k)} \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p(I^{(k)} \in 0)$	$p(I^{(k)} \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right) \times P\left(I^{(5)} \in 0\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right) \times P\left(I^{(5)} \in 0\right) \times P\left(I^{(6)} \in 0\right)$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p(I^{(k)} \in 0)$	$p(I^{(k)} \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right) \times P\left(I^{(5)} \in 0\right) \times P\left(I^{(6)} \in 0\right)$$

$$= 0{,}7773 \times 0{,}7503 \times 0{,}8859 \times 0{,}7311 \times 0{,}8455 \times 0{,}8957$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p(I^{(k)} \in 0)$	$p(I^{(k)} \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right) \times P\left(I^{(5)} \in 0\right) \times P\left(I^{(6)} \in 0\right)$$

$$= 0{,}7773 \times 0{,}7503 \times 0{,}8859 \times 0{,}7311 \times 0{,}8455 \times 0{,}8957$$

$$= 0{,}2860 = \mathbf{28}\%$$ Vraisemblance du modèle

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right) \times P\left(I^{(5)} \in 0\right) \times P\left(I^{(6)} \in 0\right)$$

$$= 0{,}7773 \times 0{,}7503 \times 0{,}8859 \times 0{,}7311 \times 0{,}8455 \times 0{,}8957$$

$$= 0{,}2860 = \mathbf{28}\%$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Permet de quantifier globalement la performance du modèle

Exemple

Vraisemblance:

$$L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right) = P\left(I^{(1)} \in 1\right) \times P\left(I^{(2)} \in 1\right) \times P\left(I^{(3)} \in 1\right) \times P\left(I^{(4)} \in 0\right) \times P\left(I^{(5)} \in 0\right) \times P\left(I^{(6)} \in 0\right)$$

$$= 0{,}7773 \times 0{,}7503 \times 0{,}8859 \times 0{,}7311 \times 0{,}8455 \times 0{,}8957$$

$$= 0{,}2860 = \boxed{\mathbf{28\%}}$$

$\mathcal{I}$	c	x_1	x_2	z	$\varphi(z)$	$p\left(I^{(k)} \in 0\right)$	$p\left(I^{(k)} \in 1\right)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Très pénalisante et diminue quand le nombre de k_i augmente

(multiplication de nombres < 1)

Vraisemblance

- $L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right)$
- Tend trop rapidement vers 0 dès que m augmente

Vraisemblance

- $L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right)$
- Tend trop rapidement vers 0 dès que m augmente
- Nécessité d'aplatir la courbe des valeurs

Quelle fonction permet cela ?

Vraisemblance logarithmique

- $L = \prod_{k=1}^{m} P\left(I^{(k)} \in c\right)$
- Tend trop rapidement vers 0 dès que m augmente
- Nécessité d'aplatir la courbe des valeurs
- Utilisation du logarithme: $log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in y_i\right)\right)$

Définition[Vraisemblance logarithmique]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble de 2 classes disjointes.

Définition[Vraisemblance logarithmique]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble de 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Définition[Vraisemblance logarithmique]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble de 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Soit un modèle associant à chaque $I^{(k)}$ la probabilité $P\left(I^{(k)} \in c\right)$ pour $I^{(k)}$ d'appartenir à la classe $c \in \mathcal{C}$ et soit L sa vraisemblance.

Définition[Vraisemblance logarithmique]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble de 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Soit un modèle associant à chaque $I^{(k)}$ la probabilité $P(I^{(k)} \in c)$ pour $I^{(k)}$ d'appartenir à la classe $c \in \mathcal{C}$ et soit L sa vraisemblance.

La **vraisemblance logarithmique** du modèle, notée L_l, est définie par:

$$\boldsymbol{L_l = log(L) = log\left(\prod_{k=1}^{m} P(I^{(k)} \in c)\right)}$$

Définition[Vraisemblance logarithmique]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble de 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Soit un modèle associant à chaque $I^{(k)}$ la probabilité $P(I^{(k)} \in c)$ pour $I^{(k)}$ d'appartenir à la classe $c \in \mathcal{C}$ et soit L sa vraisemblance.

La **vraisemblance logarithmique** du modèle, notée L_l, est définie par:

$$L_l = log(L) = log\left(\prod_{k=1}^{m} P(I^{(k)} \in c)\right) = \sum_{k=1}^{m} log\left(P(I^{(k)} \in c)\right)$$

$$log(a \times b) = log(a) + log(b)$$

Définition[Vraisemblance logarithmique]

Soit $\mathcal{C} = \{c_1, c_2\}$ un ensemble de 2 classes disjointes.

Soit $\mathcal{I} = \{I^{(k)}\}, 1 \leq k \leq m$ un ensemble de m individus tel que chaque $I^{(k)}$ est associé à une et une seule classe $c \in \mathcal{C}$.

Soit un modèle associant à chaque $I^{(k)}$ la probabilité $P(I^{(k)} \in c)$ pour $I^{(k)}$ d'appartenir à la classe $c \in \mathcal{C}$ et soit L sa vraisemblance.

La **vraisemblance logarithmique** du modèle, notée L_l, est définie par:

$$L_l = log(L) = log\left(\prod_{k=1}^{m} P(I^{(k)} \in c)\right) = \sum_{k=1}^{m} log\left(P(I^{(k)} \in c)\right)$$

Il est courant d'assimiler vraisemblance et vraisemblance logarithmique

Exemple

Vraisemblance:

$$L = \sum_{k=1}^{m} log\left(P\left(I^{(k)} \in c\right)\right) = \log(0{,}7773) + \log(0{,}7503) + \log(0{,}8859) + \log(0{,}7311) + \log(0{,}8455) + \log(0{,}8957)$$

$$= \mathbf{-1{,}2516}$$

k	y	x_1	x_2	z	$\varphi(z)$	$p(k \in 0)$	$p(k \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Exemple

Vraisemblance:

$$L = \sum_{k=1}^{m} log\left(P\left(I^{(k)} \in c\right)\right) = \log(0{,}7773) + \log(0{,}7503) + \log(0{,}8859) + \log(0{,}7311) + \log(0{,}8455) + \log(0{,}8957)$$

$$= \mathbf{-1,2516}$$

Comment interpréter ?

Quelle utilité ?

k	y	x_1	x_2	z	$\varphi(z)$	$p(k \in 0)$	$p(k \in 1)$
1	1	0.5	2.0	1,25	0,777	22,27%	**77,73%**
2	1	1.1	2.1	1,10	0,750	24,97%	**75,03%**
3	1	0.7	2.6	2,05	0,885	22,41%	**88,59%**
4	0	2.0	1.0	-1,00	0,268	**73,11%**	26,89%
5	0	2.5	0.7	-1,70	0,154	**84,55%**	15,45%
6	0	2.2	0.3	-2,15	0,104	**89,57%**	10,43%

Vraisemblance logarithmique

- $L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$

Vraisemblance logarithmique

- $L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$
- L_l est monotone croissante

Vraisemblance logarithmique

- $L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$
- L_l est monotone croissante
- $L^1 < L^2 \leftrightarrow \log(L^1) < \log(L^2)$

Vraisemblance logarithmique

- $L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$
- L_l est monotone croissante
- $L^1 < L^2 \leftrightarrow \log(L^1) < \log(L^2) \leftrightarrow L_l^1 < L_l^2$

Conservation de l'ordre entre des vraisemblances

Vraisemblance logarithmique

- $L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$
- L_l est monotone croissante
- $L^1 < L^2 \leftrightarrow L_l^1 < L_l^2$
- $\lim_{\prod_{k=0}^{m} P\left(I^{(k)} \in c\right) \to 1} L_l = 0$

Vraisemblance maximale
(les probabilités P tendent vers 1)

Vraisemblance logarithmique

- $L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$
- L_l est monotone croissante
- $L^1 < L^2 \leftrightarrow L_l^1 < L_l^2$
- $\lim_{\prod_{k=0}^{m} P\left(I^{(k)} \in c\right) \to 1} L_l = 0$

  Vraisemblance maximale
  (les probabilités P tendent vers 1)
- $\lim_{\prod_{k=0}^{m} P\left(I^{(k)} \in c\right) \to 0} L_l = -\infty$

  Vraisemblance minimale
  (les probabilités P tendent vers 0)

Recherche du meilleur modèle

- Le meilleur modèle est celui qui maximise la vraisemblance

Recherche du meilleur modèle

- Le meilleur modèle est celui qui maximise la vraisemblance
- Maximiser la vraisemblance revient à maximiser la vraisemblance logarithmique

$$L_l = \log(L) = \log\left(\prod_{k=1}^{m} P\left(I^{(k)} \in c\right)\right) = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$$

La relation d'ordre sur les L
est conservée sur les L_l

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$$

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$$

$$P\left(I^{(k)} \in c\right) = \varphi\left(z^{(k)}\right)^{t^{(k)}} \left(1 - \varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}$$

$$L_l = \sum_{k=1}^{m} \log\left(\varphi\left(z^{(k)}\right)^{t^{(k)}} \left(1 - \varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}\right)$$

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \sum_{k=1}^{m} \log\left(P\left(I^{(k)} \in c\right)\right)$$

$$L_l = \sum_{k=1}^{m} \log\left(\varphi\left(z^{(k)}\right)^{t^{(k)}} \left(1 - \varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}\right)$$

$$\log(a \times b) = \log(a) + \log(b)$$

$$L_l = \sum_{k=1}^{m} \log\left(\varphi\left(z^{(k)}\right)^{t^{(k)}}\right) + \log\left(\left(1 - \varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}\right)$$

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \sum_{k=1}^{m} \log\left(\varphi\left(z^{(k)}\right)^{t(k)} \left(1-\varphi\left(z^{(k)}\right)\right)^{1-t(k)}\right)$$

$$L_l = \sum_{k=1}^{m} \log\left(\varphi\left(z^{(k)}\right)^{t^{(k)}}\right) + \log\left(\left(1-\varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}\right)$$

$$\log\left(a^b\right) = b\log(a)$$

$$L_l = \sum_{k=1}^{m} t^{(k)} \log\left(\varphi\left(z^{(k)}\right)\right) + \left(1-t^{(k)}\right) \log\left(1-\varphi\left(z^{(k)}\right)\right)$$

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \sum_{k=1}^{m} \log\left(\varphi\left(z^{(k)}\right)^{t^{(k)}}\right) + \log\left(\left(1-\varphi\left(z^{(k)}\right)\right)^{1-t^{(k)}}\right)$$

$$L_l = \sum_{k=1}^{m} t^{(k)} \log\left(\varphi\left(z^{(k)}\right)\right) + \left(1-t^{(k)}\right) \log\left(1-\varphi\left(z^{(k)}\right)\right)$$

Normalisation par $\frac{1}{m}, 0 < \frac{1}{m} \leq 1$

$$L_l = \frac{1}{m} \sum_{k=1}^{m} t^{(k)} \log\left(\varphi\left(z^{(k)}\right)\right) + \left(1-t^{(k)}\right) \log\left(1-\varphi\left(z^{(k)}\right)\right)$$

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \sum_{k=1}^{m} t^{(k)} \log\left(\varphi\left(z^{(k)}\right)\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi\left(z^{(k)}\right)\right)$$

$$L_l = \frac{1}{m} \sum_{k=1}^{m} t^{(k)} \log\left(\varphi\left(z^{(k)}\right)\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi\left(z^{(k)}\right)\right)$$

Notation: $\varphi^{(k)} = \varphi\left(z^{(k)}\right)$

$$L_l = \frac{1}{m} \sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

But: maximisation de la vraisemblance

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

But: maximisation de la vraisemblance

Problème: La recherche de maximum est souvent coûteuse

Recherche du meilleur modèle

- Cas du perceptron

$$L_l = \frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

But: maximisation de la vraisemblance

Problème: La recherche de maximum est souvent coûteuse

Solution: maximiser $f(x)$ = minimiser $-f(x)$

Recherche du meilleur modèle

- Maximiser la vraisemblance logarithmique

$$L_l = \frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

- Minimiser

$$-L_l = -\frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

Définition[Fonction de coût / Loss function]

Soit L une fonction de vraisemblance. On appelle **fonction de coût**, ou **Loss Function**, notée $\mathcal{L}$, une fonction dont la minimisation permet de maximiser L.

Définition[Fonction de coût / Loss function]

Soit L une fonction de vraisemblance. On appelle **fonction de coût**, ou **Loss Function**, notée $\mathcal{L}$, une fonction dont la minimisation permet de maximiser L.

Exemple[Fonction de coût]

- Fonction de vraisemblance logarithmique

$$L_l = \frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

- Fonction de coût logarithmique (*Log Loss*)

$$\mathcal{L} = -\frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

Recherche du meilleur modèle

- Maximiser la vraisemblance logarithmique

$$L_l = \frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

- Minimiser la fonction de coût

$$\mathcal{L} = -\frac{1}{m}\sum_{k=1}^{m} t^{(k)} \log\left(\varphi^{(k)}\right) + \left(1 - t^{(k)}\right) \log\left(1 - \varphi^{(k)}\right)$$

Comment y arriver ?

Pour aller plus loin

- Machine Learnia – *Bases du Deep Learning*
- https://www.youtube.com/watch?v=XUFLq6dKQok

- Machine Learnia – *Le perceptron*
- https://www.youtube.com/watch?v=VlMm4VZ6lk4

A suivre…